宁波大学

本科实验报告

姓名：	梁航锋
学院：	信息科学与工程学院
系：	计算机科学与技术系
专业：	计算机科学与技术
学号：	216001912
指导教师：	董理、王艺睿

2024 年 3 月 14 日

宁波大学实验报告

课程名称：机器学习 实验类型：验证性

实验项目名称：实验六：贝叶斯分类器

学生姓名：梁航锋 专业：计算机科学与技术 学号：216001912

同组学生姓名：

指导老师：董理

实验地点：计算机组成实验室 201 实验日期：2024 年 5 月 21 日

一、实验目的和要求（必填）

1. 掌握贝叶斯定理的基本内容；
2. 掌握极大似然估计法的基本原理与应用场景；
3. 掌握朴素贝叶斯分类器的实现思想与方法，并使用朴素贝叶斯分类器进行西瓜数据集的训练与判别；
4. 熟悉 Python 集成开发环境的使用方法。

二、实验内容和原理（必填）

1. 使用 Python 实现朴素贝叶斯分类器，并在西瓜数据集 3.0 上完成训练；
2. 对测试样本“测 1”进行分类。

三、实验环境（必填）

操作系统：

Windows 11 Version 22H2

集成开发环境：

1. Anaconda3 with Jupyter Notebook
2. PyCharm 2022.2.2 (Professional Edition)

相关 Python 库：

1. python3.9

2. numpy

3. matplotlib（3.8.3）

4. sklearn（scikit-learn1.4.1）

四、操作方法与实验步骤

1. 数据集加载

实验所用数据由实验指导文件给出，其中训练数据集为西瓜数据集 3.0，为一个 csv 文件，测试数据集包含一个样本，需要判断其是否为好瓜。

使用 pandas 导入该数据集，为了方便处理，将其转换为 numpy 数组。

2. 类先验概率计算

根据训练数据集进行类先验概率 P(c)的计算，进行拉普拉斯平滑，计算公式如下。其中 N 为种类数目，D 为样本集，Dc 为类别为 c 的样本集。

$$P(c)=\frac{|D_c|+1}{|D|+N}$$

3. 类条件概率计算

根据训练数据集进行类条件概率 P(x|c)的计算，进行拉普拉斯平滑，计算公式如下,其中 Ni 表示属性 i 可能的取值数目。这里假设了样本的不同属性之间的独立性，各自计算各个属性之间的条件概率。当训练集越大时，拉普拉斯修正引入的影响越来越小。

$$\mathrm{P}(x_i|c)=\frac{|D_{c,x_i}|+1}{|D_c|+N_i}$$

如果为连续性随机变量，计算公式如下：

$$P(x_i|c)=\frac{1}{\sqrt{2\pi}\sigma_{c,i}}\exp(-\frac{(x_i-\mu_{c,i})^2}{2\sigma_{c,i}^2})$$

对于贝叶斯分类器，模型的训练就是参数估计，因此可以事先将所有的概率储存好，当有新样本需要判定时，直接查表计算即可，代码中即可以先预处理出所有的条件概率。

4. 分类

计算各类别的概率，由于证据因子相同，因此只需要计算类先验概率和所有类条件概率的乘积即可。最后取具有最大概率的类别作为判别结果即可。

五、实验数据记录和处理

该部分将按照代码逻辑与以上实验步骤进行代码的划分

1. 导入涉及到的头文件与库函数

```
import numpy as np
import pandas as pd
from math import *
```

2. 导入数据并转换

```
df_train = pd.read_csv('watermelon3_0_En.csv')
train_data = df_train.to_numpy()[:, 1:]
df_test = pd.read_csv('test.csv')
test_data = df_test.to_numpy()[:, 1:]
```

3. 类先验概率计算

```
# P(c)
def pre_prob(datasets):
    pos_prob = 1.0 * (np.sum(datasets[:, -
1] == 1.0) + 1) / (np.shape(datasets)[0] + 2)
    neg_prob = 1.0 * (np.sum(datasets[:, -
1] == 0.0) + 1) / (np.shape(datasets)[0] + 2)
    return [pos_prob, neg_prob]
```

4. 类条件概率计算

```
def cond_attr_prob(datasets, test_data):
    # shape[属性数,类别数]，表示P(x_i|c)
    cond_result = np.zeros([np.shape(datasets)[1] - 1, 2])
    pos_data = datasets[datasets[:, -1] == 1.0, :]
    neg_data = datasets[datasets[:, -1] == 0.0, :]
    for i in range(6):
        # P(x_i|1)
        cond_result[i, 1] = 1.0 * (np.sum(pos_data[:, i] == test_data
[0, i]) + 1) / (np.sum(datasets[:, -1] == 1.0) + 2)
        # P(x_i|0)
        cond_result[i, 0] = 1.0 * (np.sum(neg_data[:, i] == test_data
[0, i]) + 1) / (np.sum(datasets[:, -1] == 0.0) + 2)
    for i in range(6, 8):
        pos_mean = np.mean(datasets[(datasets[:, -1] == 1.0), i])
        pos_std = np.std(datasets[(datasets[:, -1] == 1.0), i])
        neg_mean = np.mean(datasets[(datasets[:, -1] == 0.0), i])
        neg_std = np.std(datasets[(datasets[:, -1] == 0.0), i])
        cond_result[i, 1] = 1.0 / (sqrt(2.0 * np.pi) * pos_std) * \
                            np.exp(-
1 * (test_data[0, i] - pos_mean) ** 2 / (2 * pos_std ** 2))
```

```
        cond_result[i, 0] = 1.0 / (sqrt(2.0 * np.pi) * neg_std) * \
                            np.exp(-
1 * (test_data[0, i] - neg_mean) ** 2 / (2 * neg_std ** 2))
    return cond_result
```

5. 概率计算并分类

```
def classify_data(cond_result, pre_result):
    pos_result = pre_result[1]
    neg_result = pre_result[0]
    for i in range(np.shape(cond_result)[0]):
        pos_result *= cond_result[i, 1]
        neg_result *= cond_result[i, 0]
    if pos_result > neg_result:
        print('好瓜')
    else:
        print('坏瓜')
    print('好瓜分数: ', pos_result)
    print('坏瓜分数: ', neg_result)
```

6. 主函数内容

```
def main():
    df_train = pd.read_csv('watermelon3_0_En.csv')
    train_data = df_train.to_numpy()[:, 1:]
    df_test = pd.read_csv('test.csv')
    test_data = df_test.to_numpy()[:, 1:]
    # 类先验概率计算
    pre_result = pre_prob(train_data)
    # 类条件概率计算
    cond_result = cond_attr_prob(train_data, test_data)
    # 分类
    classify_data(cond_result, pre_result)
```

六、实验结果与分析（必填）

1. 数据的导入

导入数据，并将其转换为 Numpy 数组，打印显示数据信息，发现第一列为 ID 信息，这对模型的训练并没有帮助，因此可以将其去除，最终的数据如下图 1 所示。其中可以发现，前六个属性为离散型的变量，后两个属性为连续性的变量，数据的最后一列为分类标签。

对于测试数据集，仅包含一个样本，简化了类条件概率分布的计算过程。

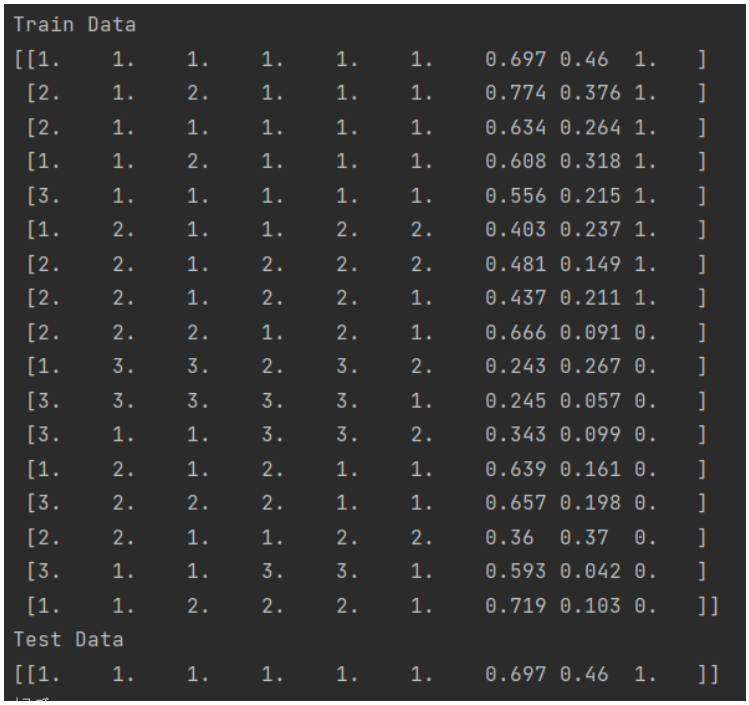


图 1. 数据内容

2. 分类结果

运行代码，最终输出结果如图 2 所示，可以看到分类为好瓜，并且可以看到对于测试样本为好瓜的相对概率（类先验概率×类条件概率）约为 0.034，为坏瓜的相对概率为 0.0000683，远小于前者，因此将其分类为好瓜具有较高的可信性。

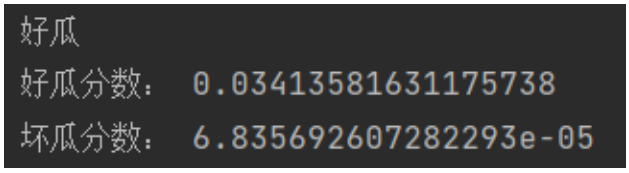


图 2. 分类结果

七、讨论、心得

本次实验基于 Python 代码实现了简易的朴素贝叶斯分类器，并在西瓜数据集 3.0 上进行新样本的预测，得到了正确的结果。对于贝叶斯分类器，是一种在概率框架下的统计学习分类器，其通过一些已知概率的情况下通过这些概率进行样本分类的判断，贝叶斯分类器是一种典型的生成式模型，通过先对联合概率分布 P(x,c)进行建模计算，最终进一步求解 P(c|x)。通过贝叶斯定理和极大似然估计的思想，对于任意给定的样本，我们可以知道 P(x)、P(c)，并能够计算得到类条件概率 P(x|c)，其中 P(x)与类标签无关，因此只需要考虑类先验

概率 P(c)和类条件概率 P(x|c)，计算得到类后验概率 P(c|x),并寻找最大的后验概率对应的类别即可完成分类。本实验通过代码的编写，按照步骤进行数据导入、类先验概率计算、类条件概率计算，寻找最大后验概率类别以实现分类，对贝叶斯定理的基本原理有了深度的理解。