宁波大学

本科实验报告

姓名：	梁航锋
学院：	信息科学与工程学院
系：	计算机科学与技术系
专业：	计算机科学与技术
学号：	216001912
指导教师：	董理、王艺睿

2024 年 3 月 14 日

宁波大学实验报告

课程名称：机器学习 实验类型：验证性

实验项目名称：实验八：PCA 降维

学生姓名：梁航锋 专业：计算机科学与技术 学号：216001912

同组学生姓名：

指导老师：董理

实验地点：计算机组成实验室 201 实验日期：2024 年 6 月 18 日

一、实验目的和要求（必填）

1. 掌握常见的降维方法（PCA 降维）的基本原理与使用场景；
2. 使用鸢尾花数据集进行 PCA 降维操作，并进行适当的可视化操作，以增进对 PCA 降维的理解；
3. 熟悉 Python 集成开发环境的使用方法。

二、实验内容和原理（必填）

1. 使用 Python 实现在给定的鸢尾花数据集上进行降维操作；
2. 选取最佳的 PCA 降维维度 n_components；
3. 基于 Python 代码实现 PCA 降维操作，并与机器学习库 sklearn 中的 PCA 进行对比；
4. 对数据降维结果进行可视化绘图操作。

三、实验环境（必填）

操作系统：

Windows 11 Version 22H2

集成开发环境：

1. Anaconda3 with Jupyter Notebook
2. PyCharm 2022.2.2 (Professional Edition)

相关 Python 库：

1. python3.9
2. numpy
3. matplotlib（3.8.3）
4. sklearn（scikit-learn1.4.1）

四、操作方法与实验步骤

1. 数据集加载

本次实验选用的数据集为鸢尾花数据集，共包含 150 个样本，每个样本有 4 个特征。该数据集可以从机器学习库 sklearn 中的 datasets.load_iris()函数进行数据集的加载，数据集以字典的形式给出，其中 data 包含了[150,4]的数据特征，target 包含了[150,1]的标签。

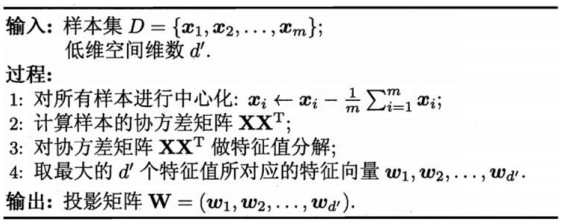
2. 目标特征数目的选择

在前面的实验中以及尝试了使用相关矩阵进行特征降维的方法，本次实验使用 PCA 方法进行降维，而目标特征的维数需要人为给出，考虑使用累积可解释方差贡献率作为评价指标，用于衡量保留的主成分能够解释原始数据方差的累积比例。它对于选择合适的主成分个数至关重要，因为当累积贡献率达到某个阈值（如 85%）时，可以认为已经保留了原始数据中的大部分信息。

因此在实验中，考虑绘制各个降维数目下的累积可解释方差贡献率，并绘制曲线以寻找一个合适的目标特征数目。对于 sklearn 中实现的 PCA 模型的实例来说，可以通过 explained_variance_ratio_属性访问得到各个特征数目下的累积可解释方差贡献率值。

3. 实现 PCA 降维

自定义函数以实现 PCA 降维，函数的传入参数为数据集与目标特征维数，首先需要对数据进行标准化操作，即每个样本的每个特征都减去对应特征的样本均值，随后计算协方差矩阵，矩阵应为一个 m 阶方阵（m 为原特征数目），再计算协方差矩阵的特征值及其特征向量，并对特征值进行排序，获取前 n 个最大的特征值所对应的特征向量，再在此基础上作用于原数据集得到降维结果。上述过程均可以使用 numpy 库实现计算，复杂度为 O(N^3)。算法的伪代码如图 1 所示。实现代码详见第五节。



输入： 样本集 $D=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\ldots,\boldsymbol{x}_m\}$;
低维空间维数 d'.

过程：

1: 对所有样本进行中心化: $\boldsymbol{x}_i \leftarrow \boldsymbol{x}_i - \frac{1}{m}\sum_{i=1}^{m}\boldsymbol{x}_i$;
2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$;
3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ 做特征值分解;
4: 取最大的 d' 个特征值所对应的特征向量 $\boldsymbol{w}_1,\boldsymbol{w}_2,\ldots,\boldsymbol{w}_{d'}$.

输出： 投影矩阵 $\mathbf{W}=(\boldsymbol{w}_1,\boldsymbol{w}_2,\ldots,\boldsymbol{w}_{d'})$.

图 1. PCA 降维算法

4. 对降维结果进行绘图

根据累积可解释方差贡献率确定目标特征数目为 2，同时也便于数据图像的绘制，将使用自写的函数进行特征降维后的数据进行散点绘制，同时也使用机器学习库 sklearn 的降维方法进行数据降维，并绘制图像。对比两种降维方法之间的差异。详见第六节。

5. 总结分析

对实验涉及理论方法进行总结与回顾。

五、实验数据记录和处理

该部分将按照代码逻辑与以上实验步骤进行代码的划分，包括数据的导入、目标维数的选定、PCA 的实现、降维结果绘图与对比。

1.导入涉及到的头文件与库函数

```
import matplotlib.pyplot as plt
import numpy as np
from sklearn.datasets import load_iris
from sklearn.decomposition import PCA
import matplotlib
matplotlib.rcParams['font.family'] = 'SimHei'
```

2.数据导入与目标维数的确定

```
    X = np.array(load_iris()['data'])
    y = np.array(load_iris()['target'])
    print(X.shape)
    print(y.shape)
    pca_line = PCA().fit(X)
    plt.plot([1,2,3,4],np.cumsum(pca_line.explained_variance_ratio_))
    plt.xticks([1, 2, 3, 4])
    plt.xlabel("降维后的特征数量")
    plt.ylabel("可解释方差贡献率")
    plt.show()
```

3. PCA 的实现

```
def self_pca(data, n_components):
    # 每个样本特征减去特征的平均值
    data = data - np.mean(data, axis=0, keepdims=True)
    # m 为样本数
    m, _ = data.shape
    # 计算协方差矩阵
    cov_mat = 1.0 / m * np.matmul(data.T, data)
    print(cov_mat.shape) # shape[4,4]
    # 计算协方差矩阵特征值及其对应的特征向量
    eig_values, eig_vector = np.linalg.eig(cov_mat)
    print(eig_values)
    # 对特征值进行排序，获取前 n_components 组特征的索引
    _index = np.argsort(-eig_values)[:n_components]
    # 获取对应的特征向量
    picked_eig_vector = eig_vector[:, _index]
    # 处理原数据集
    data_ndim = np.matmul(data, picked_eig_vector)
    print(data_ndim.shape)
    return data_ndim
```

4. 两种降维方法的绘图对比

```
    data_2d1 = self_pca(X, n_components=2)
    plt.figure(figsize=(15, 4))
    plt.subplot(121)
    plt.title("my_pca")
    plt.scatter(data_2d1[:, 0], data_2d1[:, 1], c=y)

    sklearn_pca = PCA(n_components=2)
    data_2d2 = sklearn_pca.fit_transform(X)
    plt.subplot(122)
    plt.title("sklearn_pca")
    plt.scatter(data_2d2[:, 0], data_2d2[:, 1], c=y)
    plt.show()
```

六、实验结果与分析（必填）

1. 数据的导入

实验使用鸢尾花数据集，使用 load_iris()函数导入数据，数据的样本数为 150，每个样本含有 4 个特征与 1 个标签。

2. 目标特征维数确定

使用累积可解释方差贡献率作为评价指标进行特征数目的确定，贡献率越大则代表越能够代表原数据集，该数值随着目标特征数目的降低而降低，曲线如图 2 所示，可以看到，当目标特征维数选定为 2 时，使用累积可解释方差贡献率约为 0.98，能够很大程度地代表原数据集，因此在后续的降维操作中，选定目标特征维数为 2，即 n_components=2。

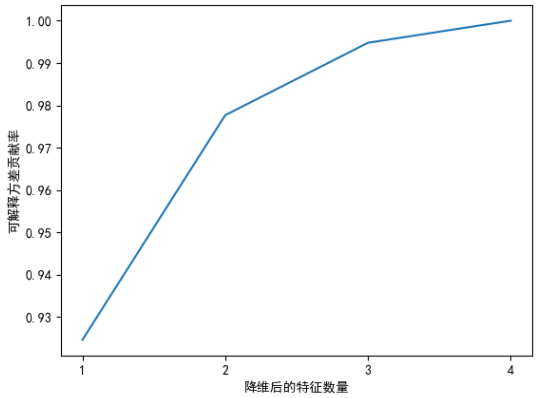


图 2. 累计可解释方差贡献率曲线

3. 降维可视化与对比

根据图 1 所示的算法，结合 numpy 库可以实现 PCA 函数，对数据进行降维操作，具体的实现代码见前文，由于目标特征数目为 2，可以考虑使用二维散点图进行数据样本的绘制，并且将同一类别的数据使用同一种颜色进行表示。为对比自行编写的 PCA 函数与 sklearn 库中的 PCA 方法之间的差异，进行绘图对比，如图 3 和图 4 所示。

可以看到，经过降维后的数据分布一致，但数值发生了变化，这可能是因为存在不同的归一化或标准化操作，使得样本特征进行了一定比例的缩放，但不影响数值的整体分布，可以发现数据点基本呈现对称状态，由此可以说明两种 PCA 降维方法最终都选定了同样的两个特征，符合实验预期。

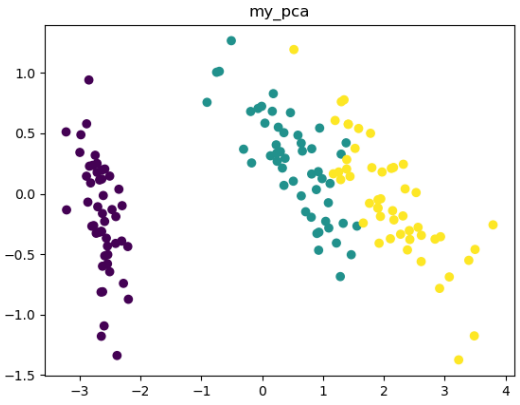


图 3. 降维结果（使用自编写的 PCA 降维函数）

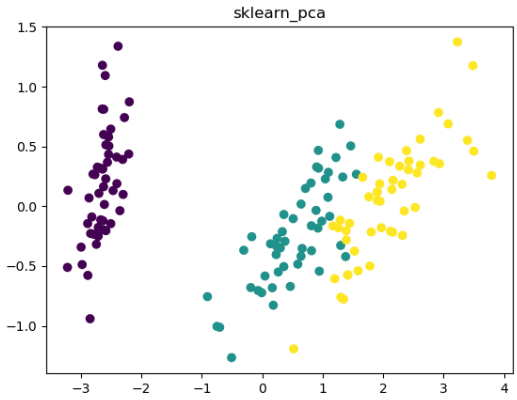


图 4. 降维结果（使用 sklearn 的 PCA 降维）

七、讨论、心得

本次实验基于 Python 的 sklearn 机器学习库实现了使用 PCA 方法进行降维，同时也基于 numpy 库进行了 PCA 降维算法的实现，最终都在给定的鸢尾花数据集上进行了数据降维，并通过可视化绘制直观地理解了降维的结果。

在前面的实验中曾经进行了基于相关性矩阵的特征选择操作，这本质上也是一种数据降维，通过排除相关性较大的特征以减少特征维度，从而降低计算开销，而 PCA 降维通过方差作为衡量指标，选择能够尽可能保留原数据性质的特征作为降维结果。为进一步选定目标维数，实验中使用了累积可解释方差贡献率作为定量的衡量指标，最终确定目标维数为 2 较优，能够在降维的基础上最大程度保留原数据集的特点。

最后，实验通过可视化绘图的方式将自己实现的 PCA 算法和 sklearn 中的 PCA 方法进行对比，结果显示选择的特征一致，符合实验预期。