一、绪 论

考试形式

15% 平时

45% 实验

课程大作业：以不多于3人为一组，完成一个数据给定1但结论开放的项目，包含开发计划报告（约第5周）和总结报告（约第15周）。

40% 期末考试

实践工具：Python——Anaconda

- Anaconda是什么？
  - Anaconda 是一种Python语言的免费增值开源发行版，用于进行大规模数据处理, 预测分析, 和科学计算, 致力于简化包的管理和部署。Anaconda使用软件包管理系统Conda进行包管理
- 官网：
  - https://www.anaconda.com/

实践工具：Python—— Anaconda

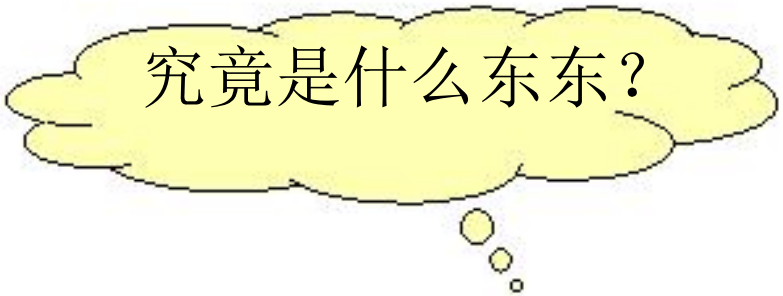
- Anaconda 组件：Jupyter Notebook
- 主要目的
  - Jupyter Notebook是基于网页的用于交互计算的应用程序。其可被应用于全过程计算：开发、文档编写、运行代码和展示结果。
  - 主要用于代码调试
- 在终端中输入以下命令：
  - 用cd命令到达预期路径
  - 输入jupyter notebook

实践工具： C++——Visual Studio

- 官网：
  - https://visualstudio.microsoft.com/zh-hans/vs/community/

机器学习

（Machine Learning）



机器学习是从人工智能中产生的一个重要学科分支，是实现智能化的关键

经典定义：利用经验改善系统自身的性能



经验 → 数据



随着该领域的发展，目前主要研究智能数据分析的理论和算法，并已成为智能数据分析技术的源泉之一

图灵奖连续授予在该方面取得突出成就的学者



Leslie Valiant
(1949 -)
(Harvard Univ.)

2011年度

“计算学习理论”奠基人

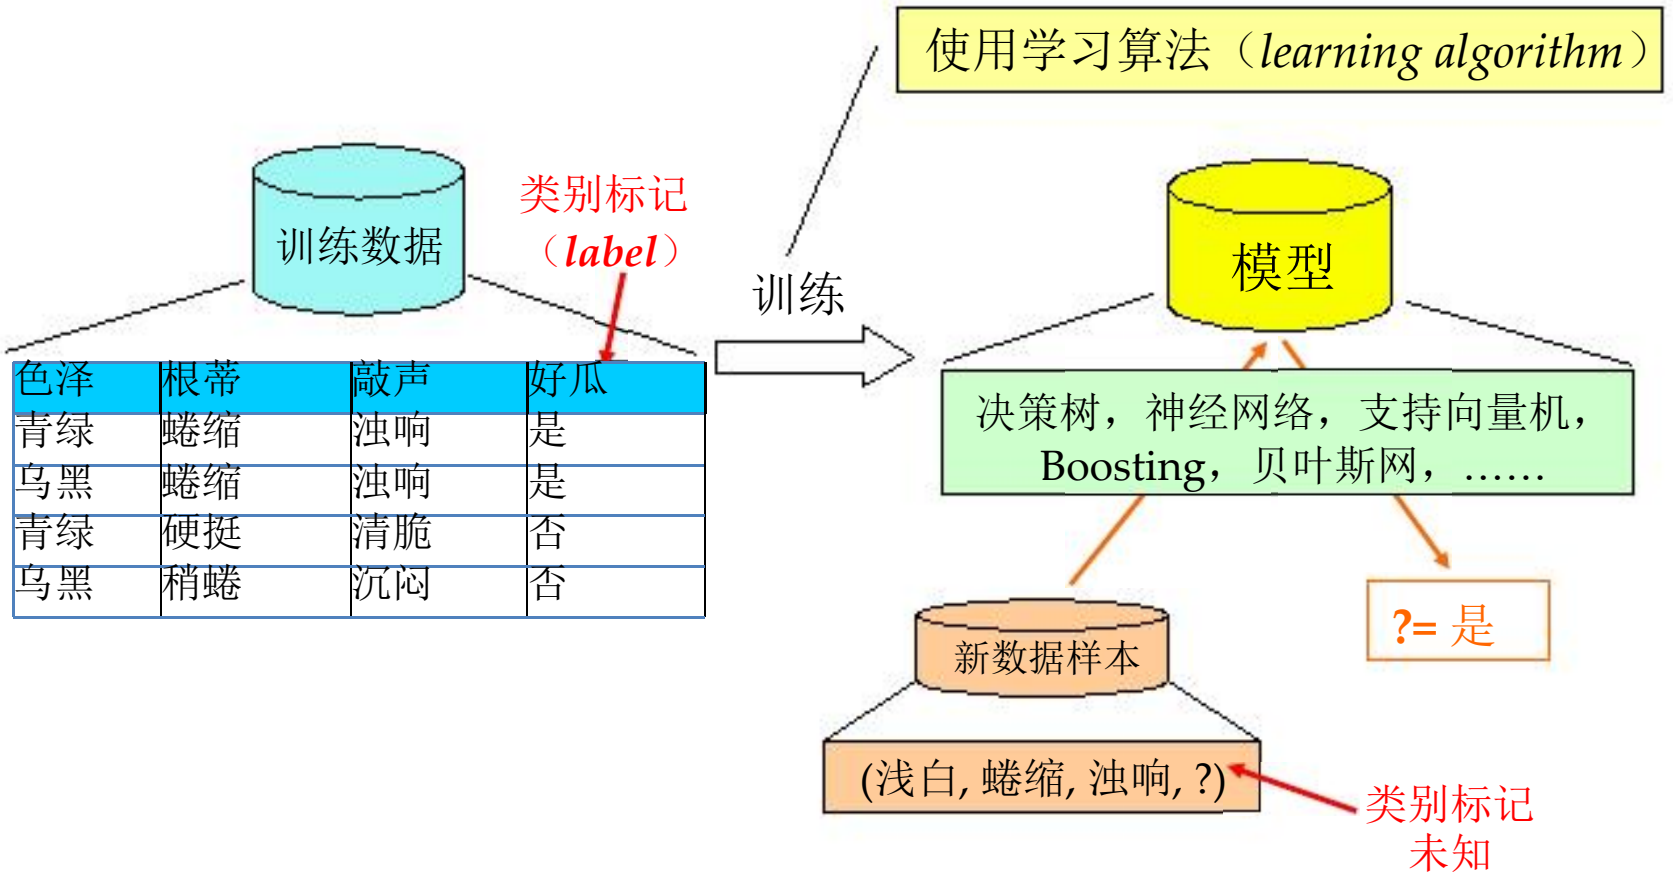


Judea Pearl
(1936 -)
(UCLA)

2012年度

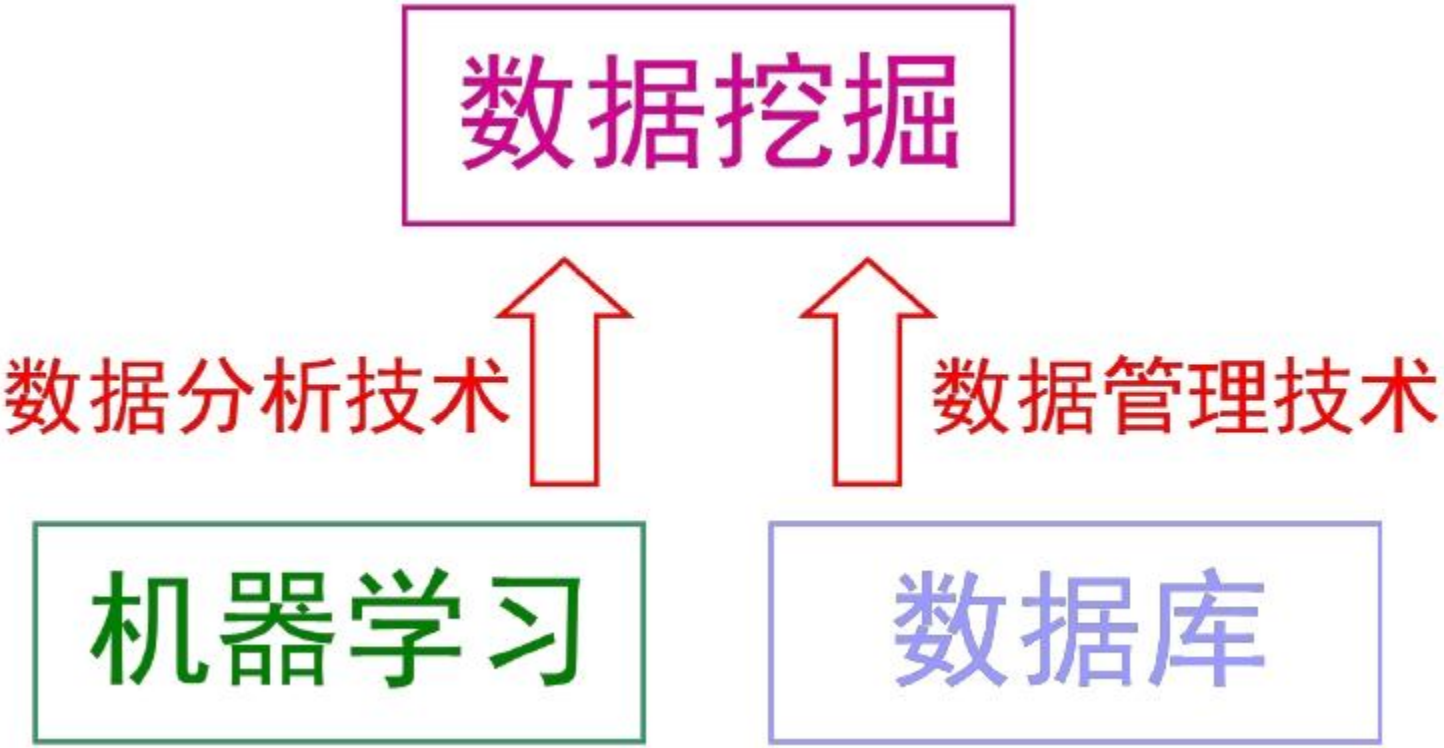
“图模型学习方法”先驱

典型的机器学习过程

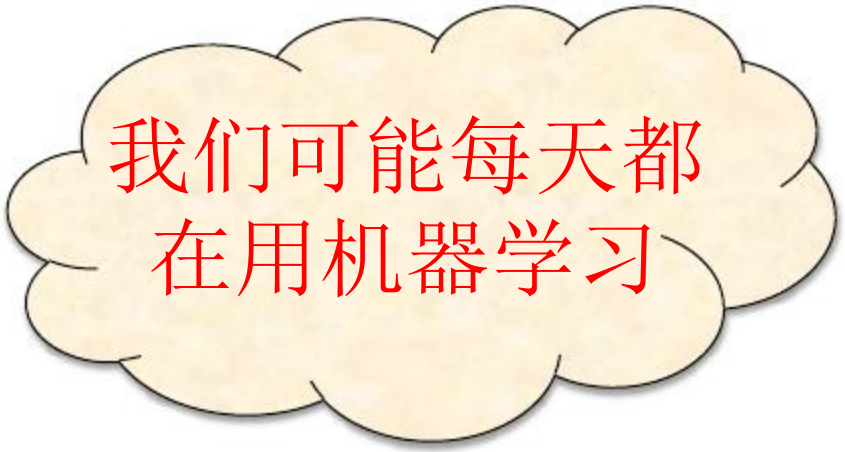


色泽	根蒂	敲声	好瓜
青绿	蜷缩	浊响	是
乌黑	蜷缩	浊响	是
青绿	硬挺	清脆	否
乌黑	稍蜷	沉闷	否

机器学习与数据挖掘

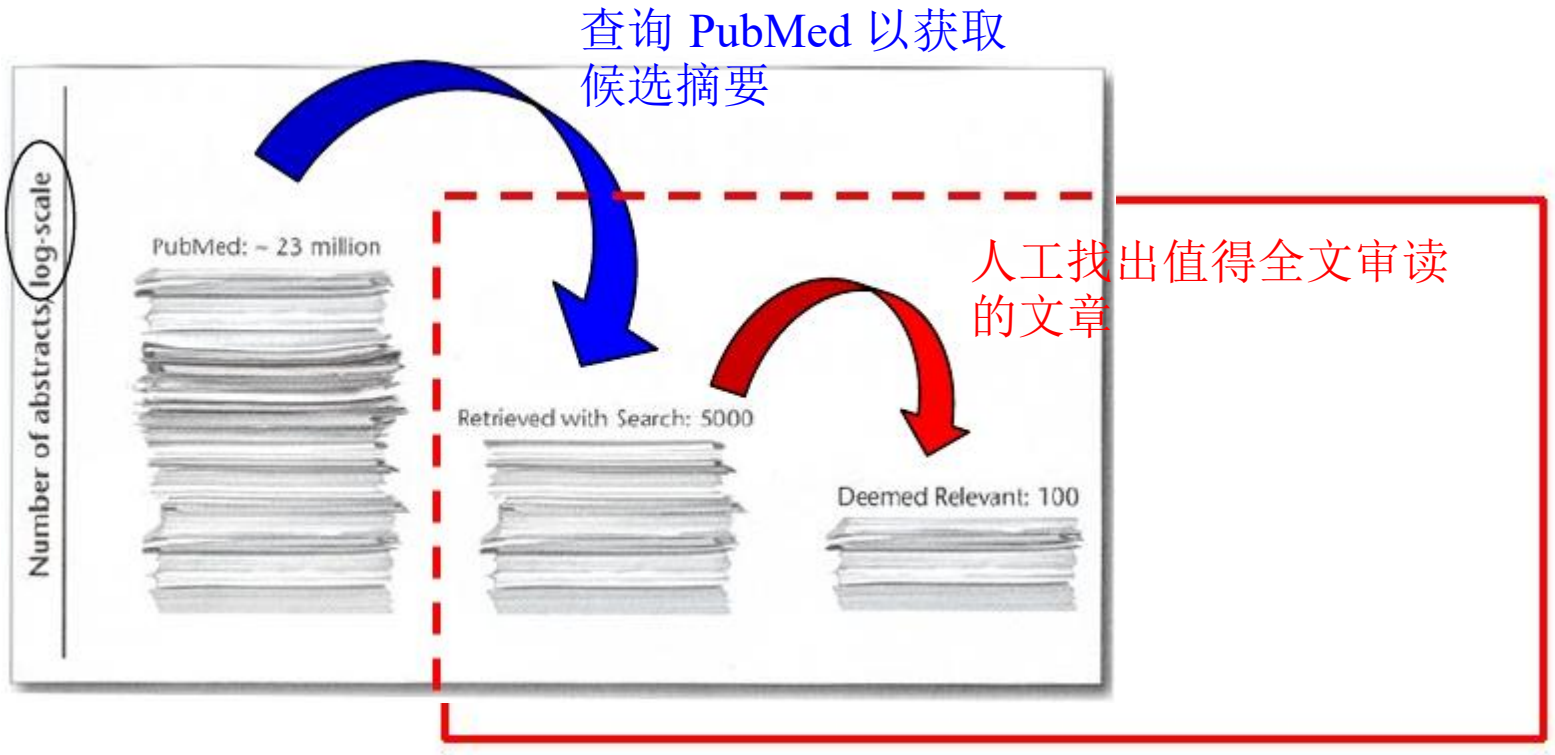


机器学习能做什么？



“文献筛选”的故事

在“循证医学”（evidence-based medicine）中，针对特定的临床问题，先要对相关研究报告进行详尽评估



[C. Brodley et al., AI Magazine 2012]

“文献筛选”的故事

在一项关于婴儿和儿童残疾的研究中，美国Tufts医学中心筛选了约 33,000 篇摘要



a portion of the 33,000 abstracts

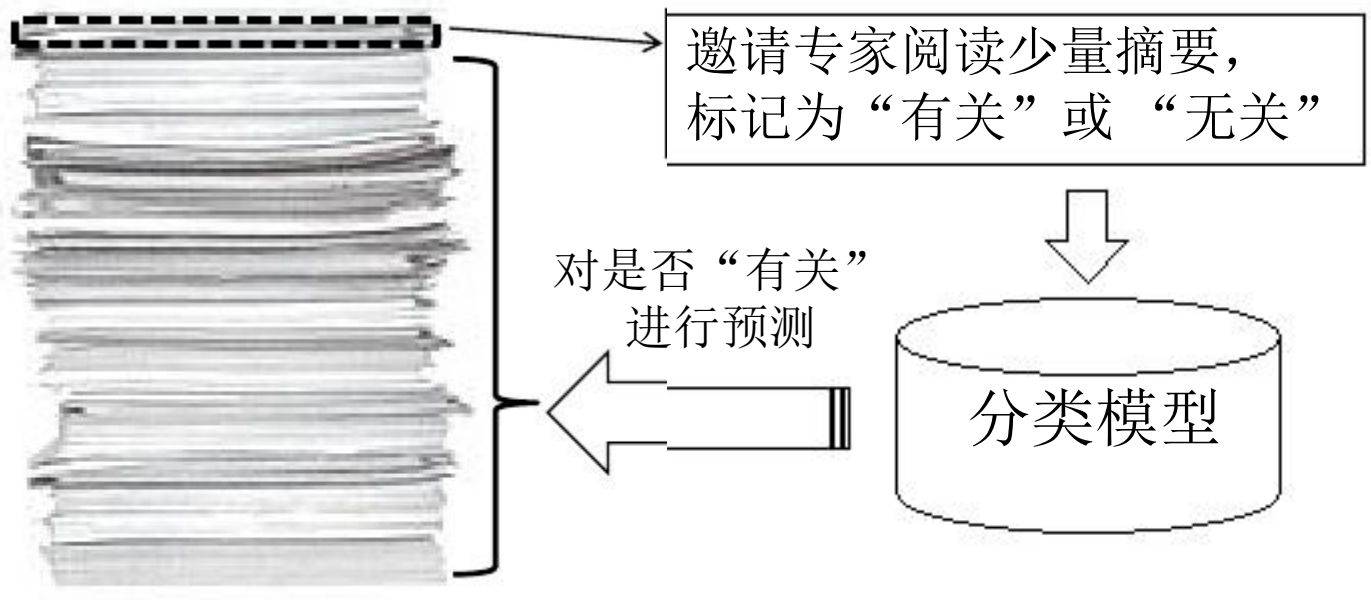
尽管Tufts医学中心的专家效率很高，对每篇摘要只需 30 秒钟，但该工作仍花费了 250 小时

每项新的研究都要重复这个麻烦的过程！

需筛选的文章数在不断显著增长！

“文献筛选”的故事

为了降低昂贵的成本, Tufts医学中心引入了机器学习技术



人类专家只需阅读 **50** 篇摘要，系统的自动筛选精度就达到 **93%**

人类专家阅读 **1,000** 篇摘要，则系统的自动筛选敏感度达到 **95%**

(人类专家以前需阅读 **33,000** 篇摘要才能获得此效果)

例如：文心一言

请分析一下机器学习的意义

机器学习是人工智能领域中的一个重要分支，其意义在于使计算机系统能够自动地学习和改进，从而实现对未知数据的预测和决策。以下是关于机器学习意义的具体分析：

1. 提升决策精度和效率：机器学习通过对大量数据的处理和分析，能够自动发现数据中的规律和模式，进而为决策提供有力支持。无论是商业决策、医疗诊断还是金融风险评估，机器学习都能帮助人们更准确地理解数据背后的含义，从而做出更明智的决策。
2. 推动自动化和智能化进程：随着机器学习技术的不断发展，越来越多的任务可以由计算机系统自动完成，如自动驾驶、智能客服、语音识别等。这不仅提高了工作效率，减少了人工错误，还为人们提供了更便捷、更

3 请写一段机器学习代码

4 当然，我可以为您提供一段简单的机器学习代码示例。这里我们将使用Python的scikit-learn库来执行一个简单的线性回归任务。线性回归是一种用于预测数值型目标变量的监督学习算法。

首先，请确保您已经安装了scikit-learn库。如果没有安装，可以通过pip来安装：

bash 复制代码

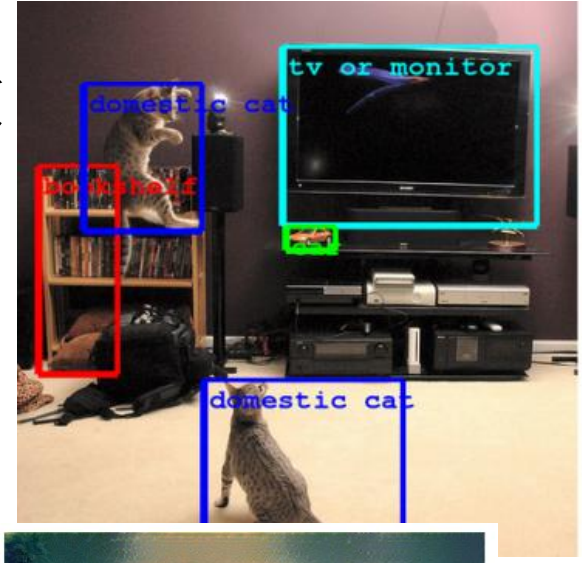
```
1  pip install scikit-learn
```

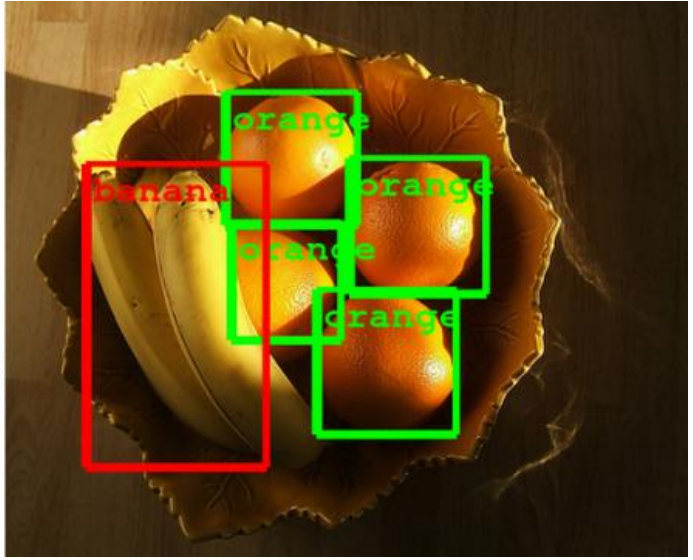
接下来是Python代码示例：

python 复制代码

```
1  import numpy as np
```

例如：计算机视觉


tv or monitor
domestic cat
domestic cat


orange
banana
orange
orange
orange

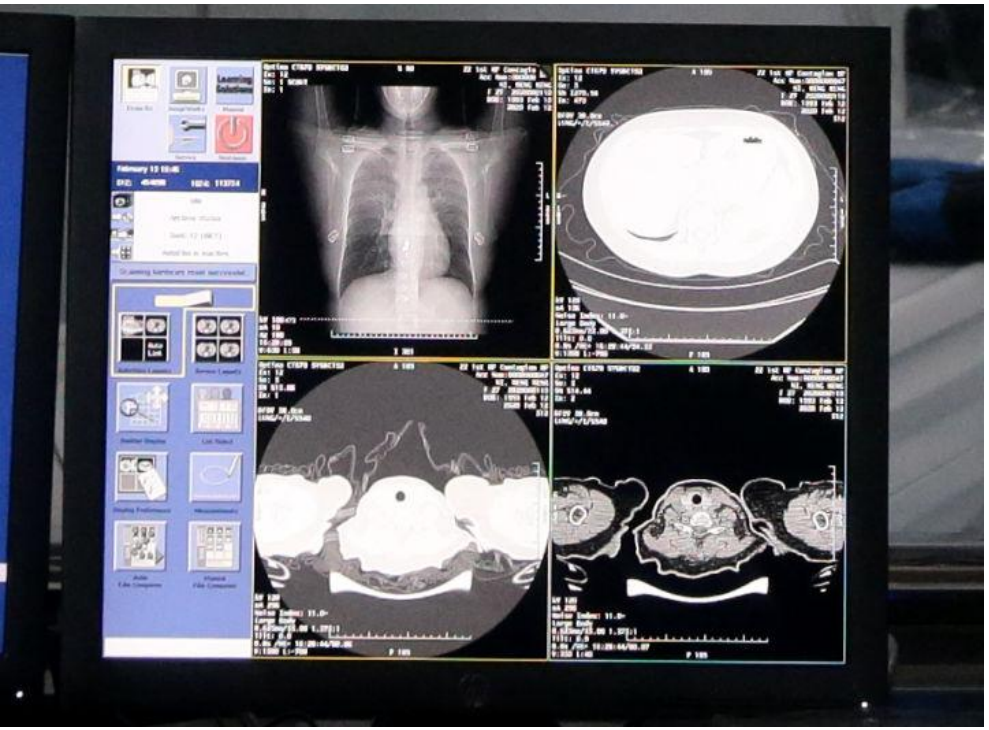

A
B


C


D

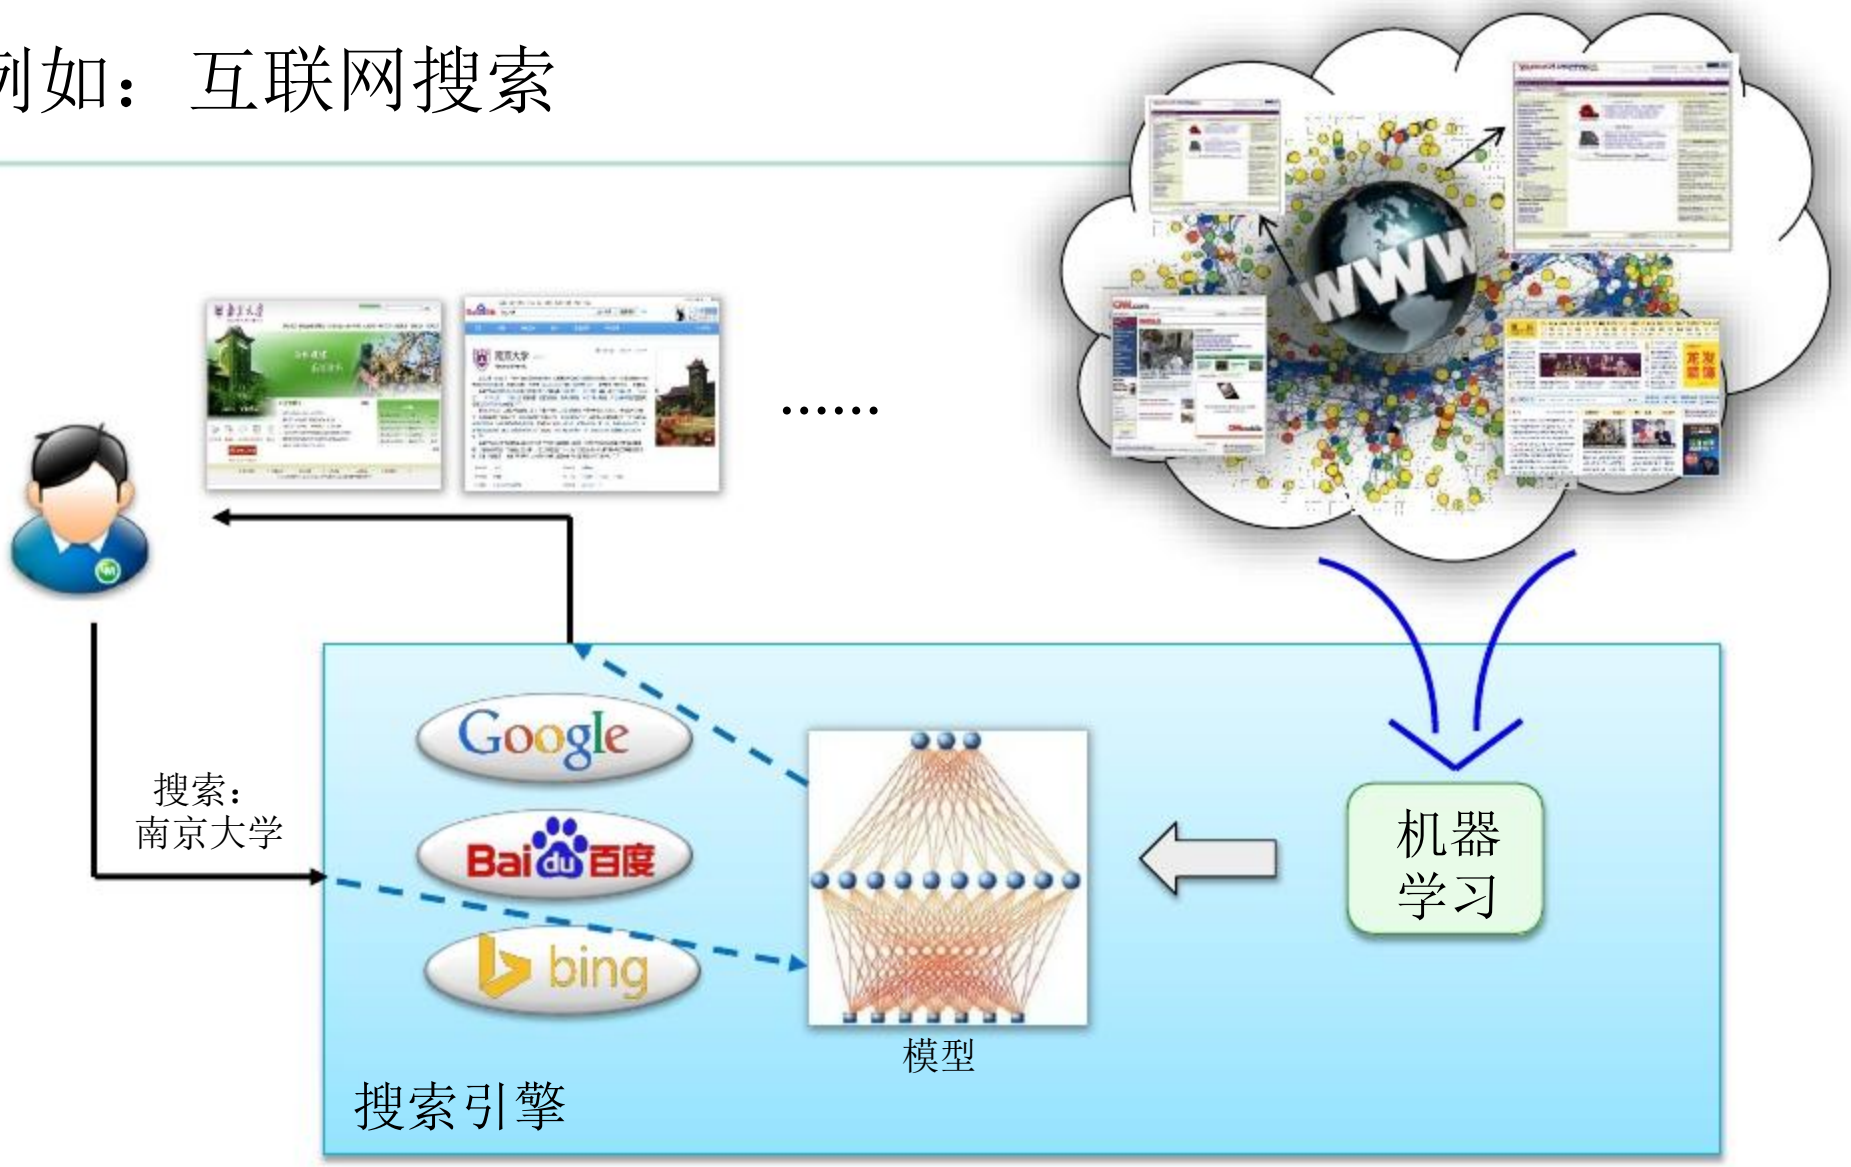
例如：新型冠状病毒症状分析

- **一位病人的CT影像大概在300张左右，平均一个病例医生靠肉眼分析需要5-15分钟**
- 达摩院基于**5000多个病例的CT影像样本**研发出的医疗AI，**分析只需要20秒就能快速完成**，直接算出病灶部位的占比比例



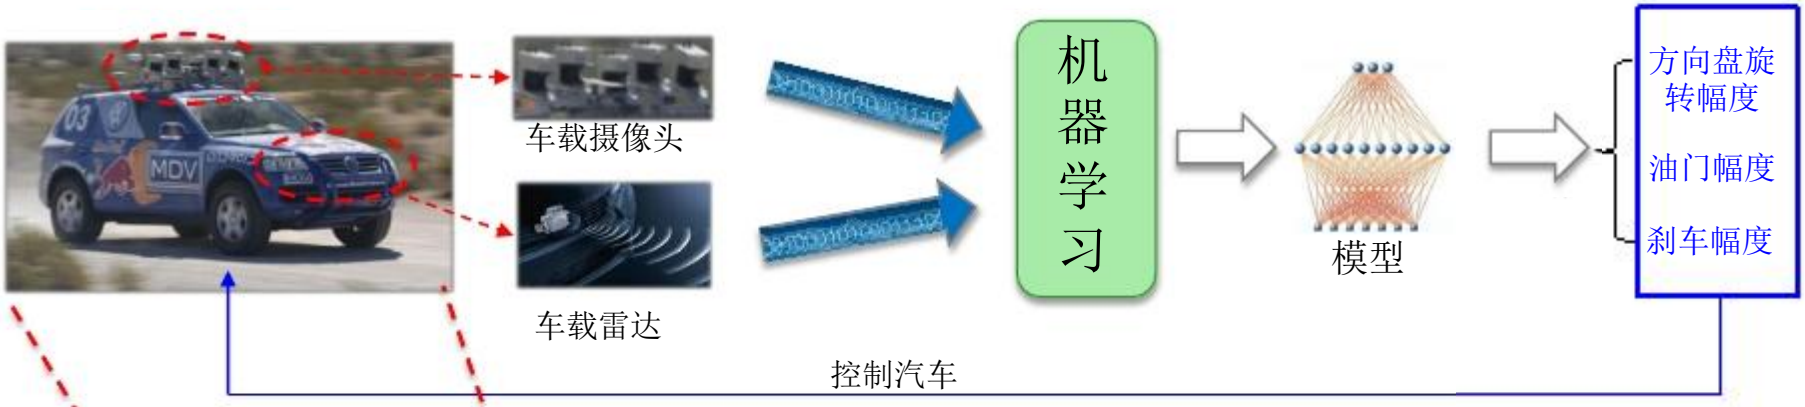


例如：互联网搜索

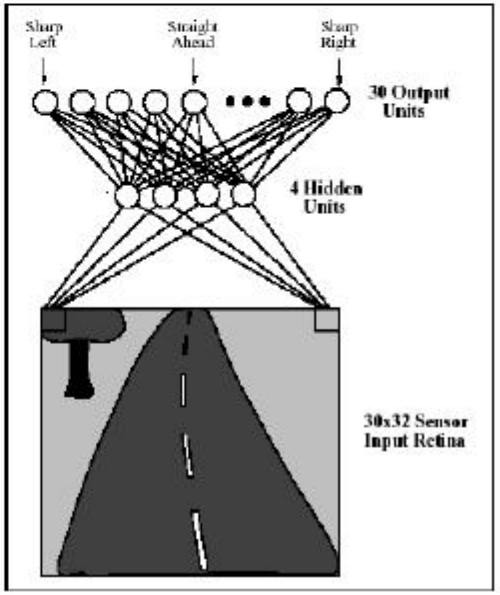


机器学习技术正在支撑着各种搜索引擎

例如：自动汽车驾驶 （即将改变人类生活）

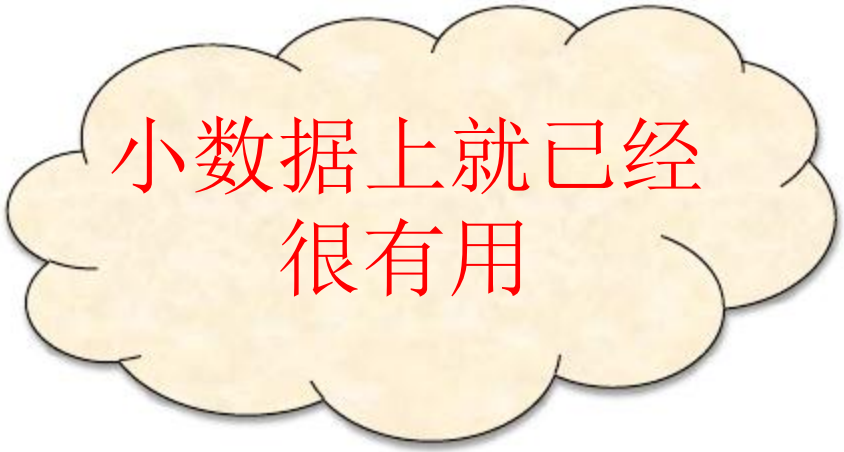






美国在20世纪80年代就开始研究基于机器学习的汽车自动驾驶技术

机器学习能做什么？



例如：画作鉴别 （艺术）

画作鉴别(painting authentication)：确定作品的真伪





勃鲁盖尔（1525-1569）的作品？

出自 [J. Hughes et al., PNAS 2009]

梵高（1853-1890）的作品？

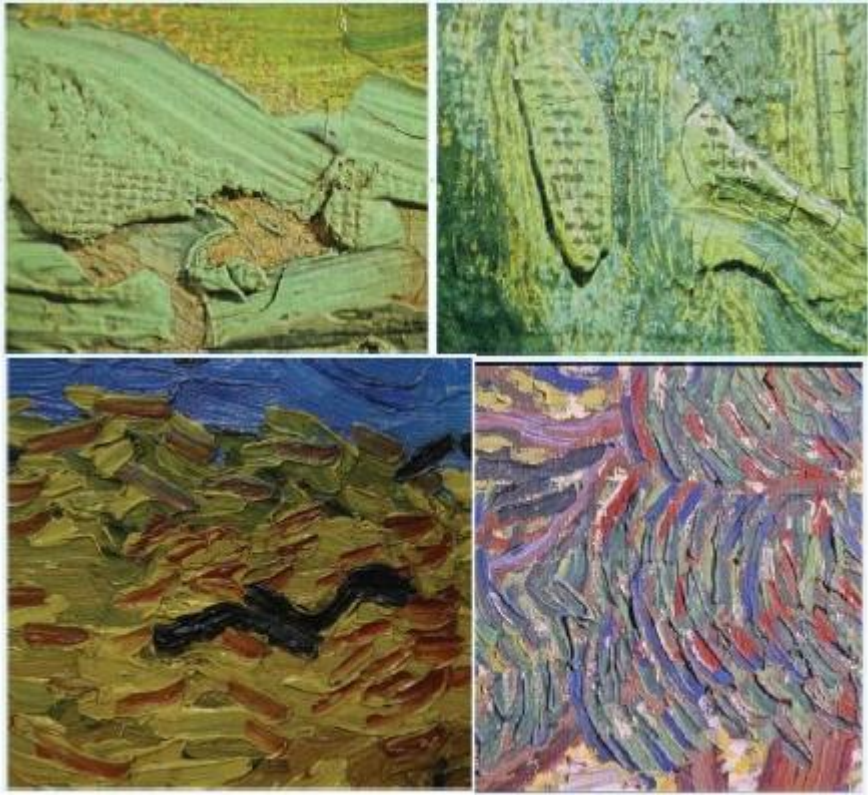






出自 [C. Johnson et al., IEEE-SP, 2008]

例如：画作鉴别 （艺术）



Portions of van Gogh paintings

除专用技术手段外， 笔触分析 (brushstroke analysis) 是画作鉴定的重要工具；它旨在从视觉上判断画作中是否具有艺术家的特有“笔迹”。

该工作对专业知识要求极高

- 具有较高的绘画艺术修养
- 掌握画家的特定绘画习惯

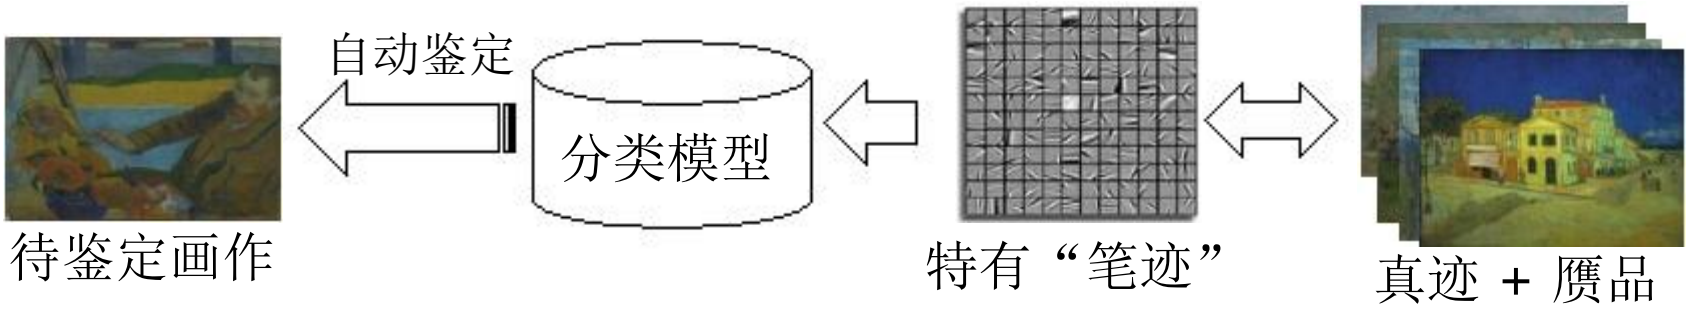
只有少数专家花费很大精力才能完成分析工作！

很难同时掌握不同时期、不同流派多位画家的绘画风格！

[C. Johnson et al., IEEE-SP, 2008]

例如：画作鉴别 （艺术）

为了降低分析成本, 机器学习技术被引入



Kröller Müller美术馆与Cornell等大学的学者对82幅梵高真迹和6幅赝品进行分析，自动鉴别精度达 **95%** [C. Johnson et al., IEEE-SP, 2008]

Dartmouth学院、巴黎高师的学者对8幅勃鲁盖尔真迹和5幅赝品进行分析，自动鉴别精度达 **100%** [J. Hughes et al., PNAS 2009][J. Mairal et al., PAMI'12]

(对用户要求低、准确高效、适用范围广)

例如：古文献修复 （文化）

古文献是进行历史研究的重要素材，但是其中很多损毁严重

Dead Sea Scrolls (死海古卷)

- 1947年出土
- 超过30,000个羊皮纸片段

Cairo Genizah

- 19世纪末被发现
- 超过300,000个片段
- 散布于全球多家博物馆



高水平专家的大量精力
被用于古文献修复

[L. Wolf et al., IJCV 2011]

例如：古文献修复 （文化）

一个重要问题：

原书籍已经变成分散且混杂的多个书页，如何拼接相邻的书页？









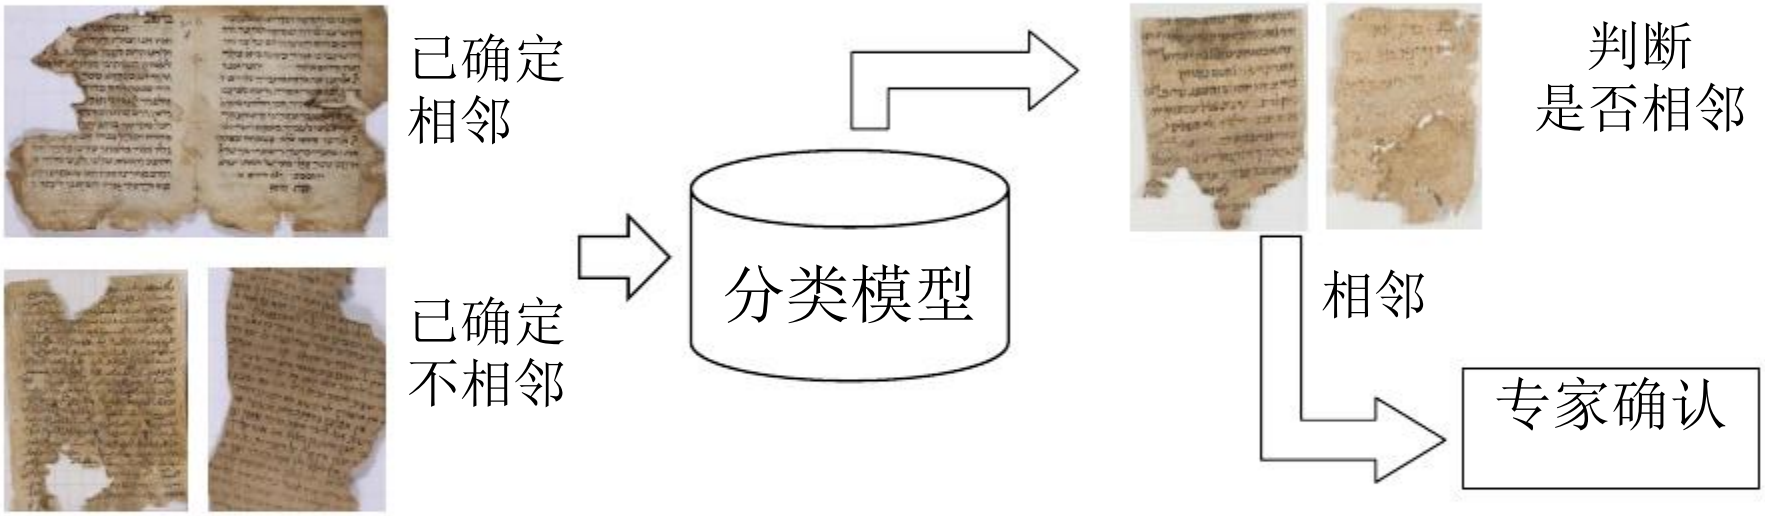
人工完成书页拼接十分困难

- 书页数量大，且分布在多处
- 部分损毁较严重，字迹模糊
- 需要大量掌握古文字的专业人才

近年来，古文献的数字化浪潮给自动文学修复提供了机会

例如：古文献修复 （文化）

以色列特拉维夫大学的学者将机器学习用于自动的书页拼接



在Cairo Genizah测试数据上，系统的自动判断精度超过 **93%**

新完成约 1,000 篇Cairo Genizah文章的拼接

(对比：过去整个世纪，数百人类专家只完成了几千篇文章拼接)

机器学习能做什么？



例如：帮助奥巴马胜选 （政治）

How Obama's data crunchers helped him win

《时代》周刊

TIME By **Michael Scherer**

November 8, 2012 – Updated 1645 GMT (0045 HKT) | Filed under: **Web**



例如：帮助奥巴马胜选 （政治）

通过机器学习模型：

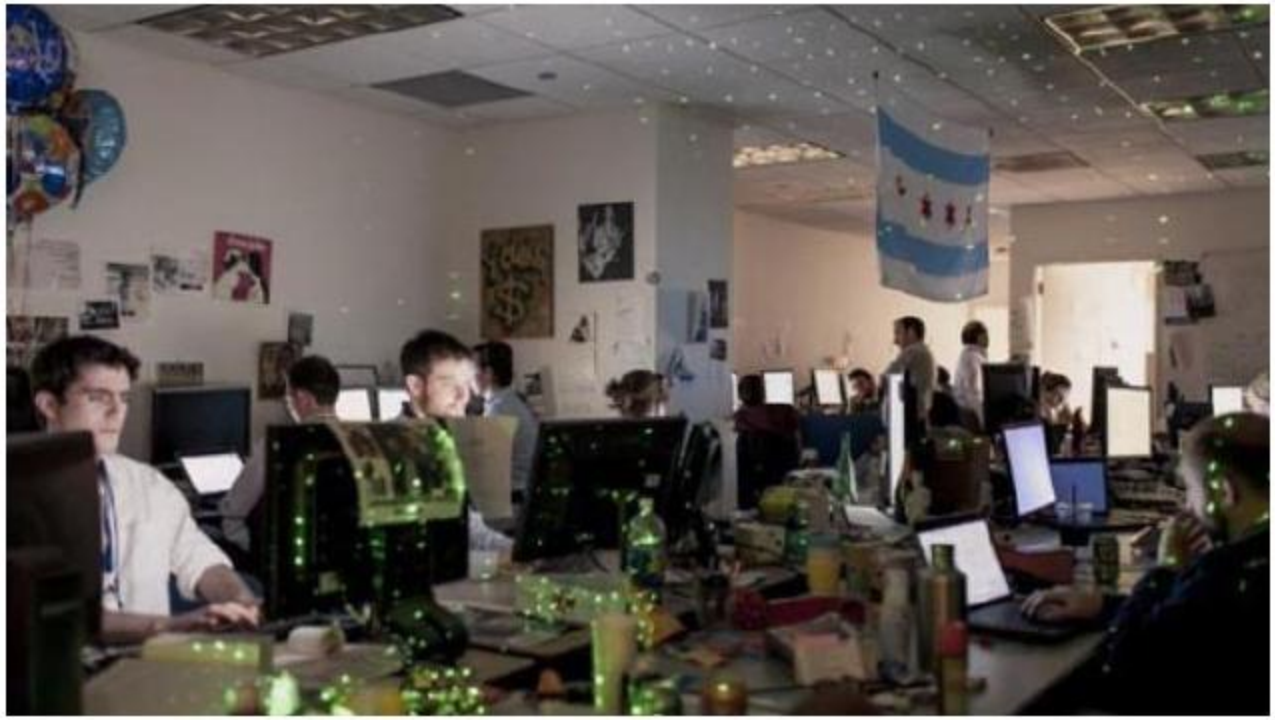
- 在总统候选人第一次辩论后，分析出哪些选民将倒戈，为每位选民找出一个最能说服他的理由
- 精准定位不同选民群体，建议购买冷门广告时段，广告资金效率比2008年提高14%
- 向奥巴马推荐，竞选后期应当在什么地方展开活动 —— 那里有很多争取对象
- 借助模型帮助奥巴马筹集到创纪录的10亿美元

例如：利用模型分析出，明星乔治克鲁尼（George Clooney）对于年龄在40-49岁的美西地区女性颇具吸引力，而她们恰是最愿意为和克鲁尼/奥巴马共进晚餐而掏钱的人 …… 乔治克鲁尼为奥巴马举办的竞选筹资晚宴成功募集到1500万美元



- … …

例如：帮助奥巴马胜选 （政治）





队长：Rayid Ghani

卡内基梅隆大学机器学习系
首任系主任Tom Mitchell
教授的博士生

这个团队行动保密，定期向奥巴马报送结果；
被奥巴马公开称为总统竞选的
“核武器按钮”(“They are our nuclear codes”)

机器学习源自“人工智能”



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖

Artificial Intelligence (AI), 1956 -

1956年夏　　美国达特茅斯学院

J. McCarthy, M. Minsky, N. Lochester, C. E. Shannon,
H.A. Simon, A. Newell, A. L. Samuel 等10余人

达特茅斯会议标志着人工智能这一学科的诞生

John McCarthy (1927 - 2011):

1971年获图灵奖, 1985年获IJCAI终身成就奖。人工智能之父。他提出了“人工智能”的概念，设计出函数型程序设计语言Lisp，发展了递归的概念，提出常识推理和情境演算。出生于共产党家庭，从小阅读《10万个为什么》，中学时自修CalTech的数学课程，17岁进入CalTech时免修两年数学，22岁在Princeton获博士学位，37岁担任Stanford大学AI实验室主任。

第一阶段：推理期

1956-1960s: Logic Reasoning

- 出发点: “数学家真聪明！”
- 主要成就: 自动定理证明系统 (例如，西蒙与纽厄尔的“Logic Theorist”系统)

渐渐地，研究者们意识到，仅有逻辑推理能力是不够的 ...



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

第二阶段：知识期



爱德华 费根鲍姆
(1936-)
1994年图灵奖

1970s -1980s: Knowledge Engineering

- 出发点: “知识就是力量！”
- 主要成就: 专家系统 (例如，费根鲍姆等人的“DENDRAL”系统)

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 ...

第三阶段：学习期

1990s -now: Machine Learning

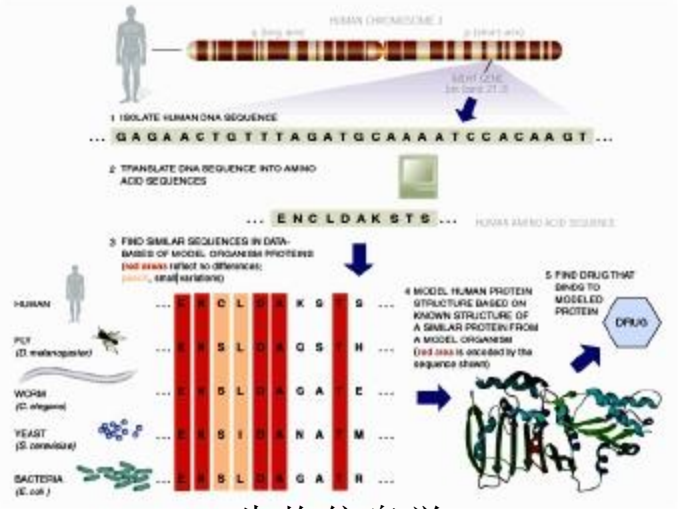
- 出发点: “让系统自己学！”
- 主要成就: .....

机器学习是作为“突破知识工程瓶颈”之利器而出现的



恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切

机器学习已经“无处不在”



生物信息学



Web搜索



入侵检测



汽车自动驾驶
(DARPA Grand Challenge)



火星机器人 (JPL)



决策助手(DARPA)

今天的“机器学习”已经是一个广袤的学科领域

例如，这是第32届国际机器学习大会的“主题领域”

2006年，美国CMU(卡内基梅隆大学)成立“机器学习系”

- Active Learning
- Approximate Inference
- Bayesian Nonparametric Methods
- Bioinformatics
- Causal Inference
- Clustering
- Computational Social Sciences
- Cost-Sensitive Learning
- Digital Humanities
- Ensemble Methods
- Feature Selection and Dimensionality Reduction
- Finance
- Gaussian Processes
- Graphical Models
- Inductive Logic Programming and Relational Learning
- Information Retrieval
- Kernel Methods
- Large-Scale Machine Learning
- Latent Variable Models
- Learning for Games
- Learning Theory
- Manifold Learning
- Network and Graph Analysis
- Neural Networks and Deep Learning
- Planning and Control
- Privacy, Anonymity, and Security
- Ranking and Preference Learning
- Recommender Systems
- Reinforcement Learning
- Robotics
- Rule and Decision Tree Learning
- Semi-Supervised Learning
- Sparsity and Compressed Sensing
- Spectral Methods
- Speech Recognition
- Statistical Relational Learning
- Structured Output Prediction
- Supervised Learning
- Sustainability, Climate, and Environment
- Time-Series Analysis

经常被谈到的“深度学习”(Deep Learning)仅是机器学习中的一个小分支

大数据时代的关键技术

奥巴马提出“大数据计划”后，美国NSF进一步加强资助UC Berkeley研究如何整合将”数据”转变为”信息”的三大关键技术——机器学习、云计算、众包(crowd sourcing)

National Science Foundation: In addition to funding the Big Data solicitation, and keeping with its focus on basic research, NSF is implementing a comprehensive, long-term strategy that includes new methods to derive knowledge from data; infrastructure to manage, curate, and serve data to communities; and new approaches to education and workforce development. Specifically, NSF is:

整合三大关键技术

- Encouraging research universities to develop interdisciplinary graduate programs to prepare the next-generation Expeditions in Computing project based at the University of California, Berkeley, that will integrate three powerful approaches for turning data into information - machine learning, cloud computing, and crowd sourcing;
- Funding the first round of grants to support "EarthCube" – a system that will allow geoscientists to access, analyze and share information about our planet;
- Providing the first round of grants to support "EarthCube" – a system that will allow geoscientists to access, analyze and share information about our planet;
- Issuing a $2 million award for a research training group to support training for undergraduates to use graphical and visualization techniques for complex data.
- Providing $1.4 million in support for a focused research group of statisticians and biologists to determine protein structures and biological pathways.
- Convening researchers across disciplines to determine how Big Data can transform teaching and learning.

大数据时代，机器学习必不可少

收集、传输、存储大数据的目的，

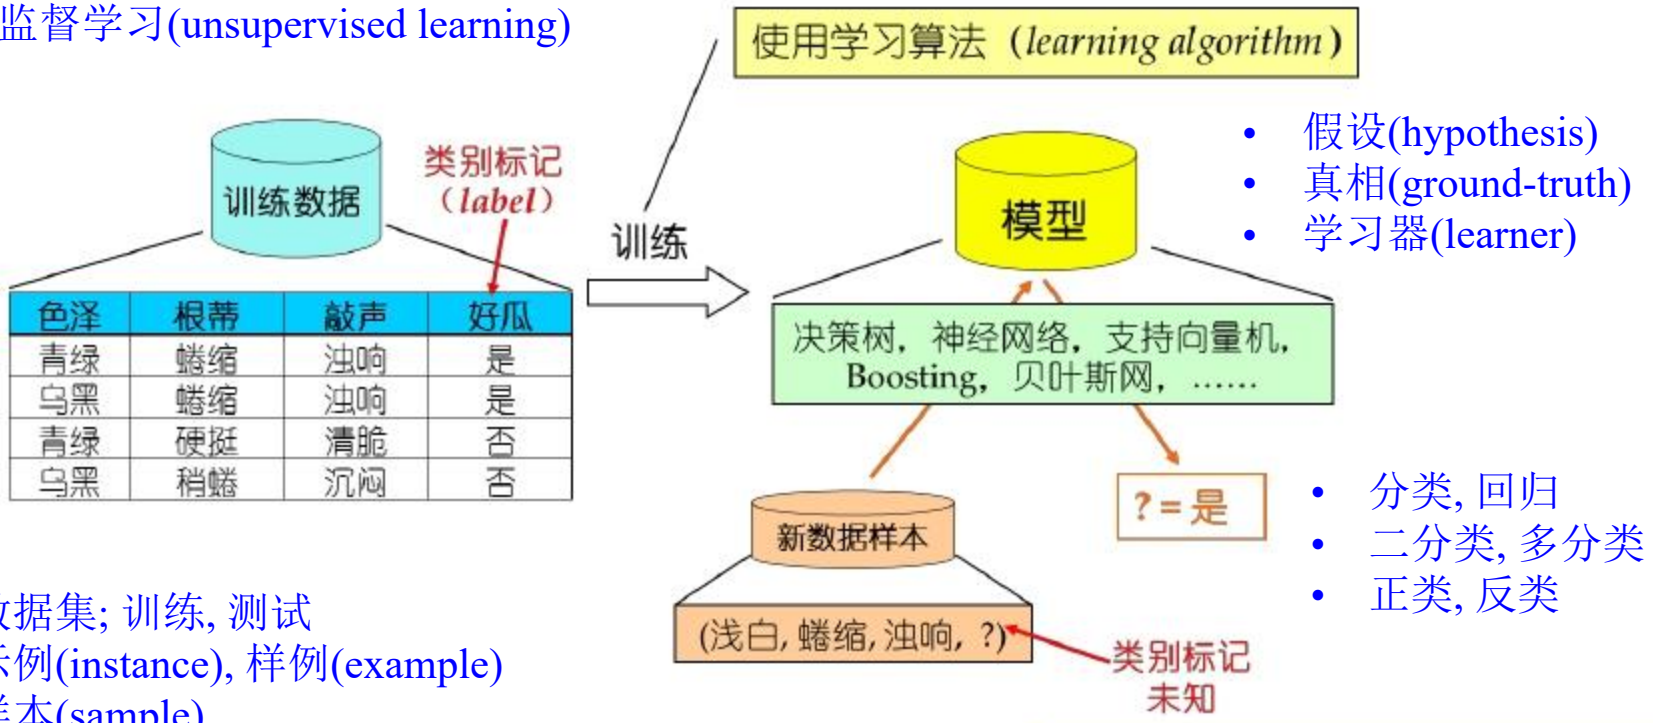
是为了“利用”大数据

没有机器学习技术分析大数据，

“利用”无从谈起

基本术语

- 监督学习(supervised learning)
- 无监督学习(unsupervised learning)



色泽	根蒂	敲声	好瓜
青绿	蜷缩	浊响	是
乌黑	蜷缩	浊响	是
青绿	硬挺	清脆	否
乌黑	稍蜷	沉闷	否

- 假设(hypothesis)
- 真相(ground-truth)
- 学习器(learner)

- 分类, 回归
- 二分类, 多分类
- 正类, 反类

- 数据集; 训练, 测试
- 示例(instance), 样例(example)
- 样本(sample)
- 属性(attribute), 特征(feature); 属性值
- 属性空间, 样本空间, 输入空间
- 特征向量(feature vector)
- 标记空间, 输出空间

- 未见样本(unseen instance)
- 未知“分布”
- 独立同分布(i.i.d.)
- 泛化**(generalization)**

假设空间

表 1.1　西瓜数据集

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

(色泽=?)∧(根蒂=?)∧(敲声=?)↔好瓜

学习过程 → 在所有假设(hypothesis)组成的空间中进行搜索的过程

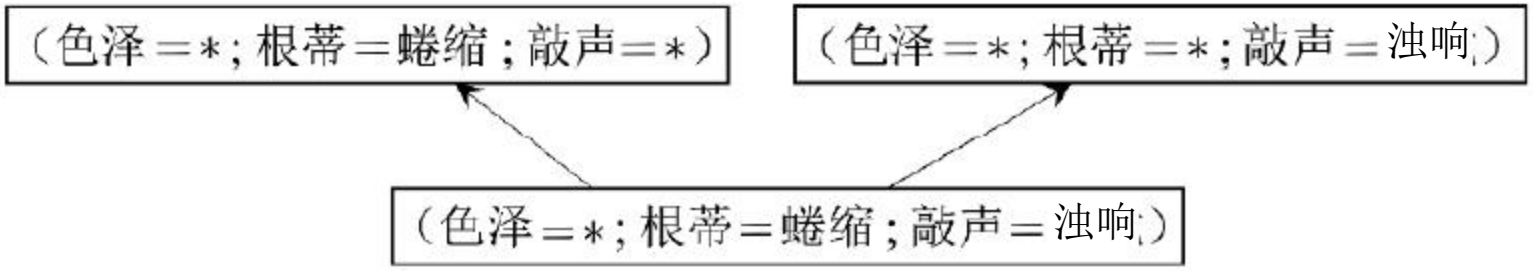
目标: 找到与训练集“匹配”(fit)的假设

假设空间的大小： $n_{色泽} \times n_{根蒂} \times n_{敲声} + 1$

1对应空集

版本空间

版本空间(version space): 与训练集一致的假设集合



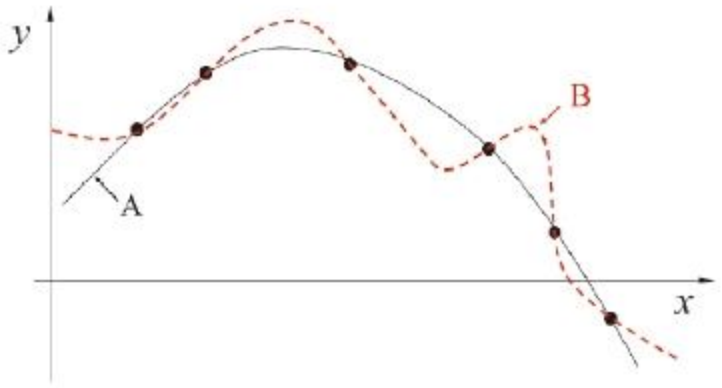
在面临新样本时，会产生不同的输出

例如: (青绿; 蜷缩; 沉闷)

应该采用哪一个模型(假设)?

归纳偏好 (inductive bias)

机器学习算法在学习过程中对某种类型假设的偏好



A更好？
B更好？

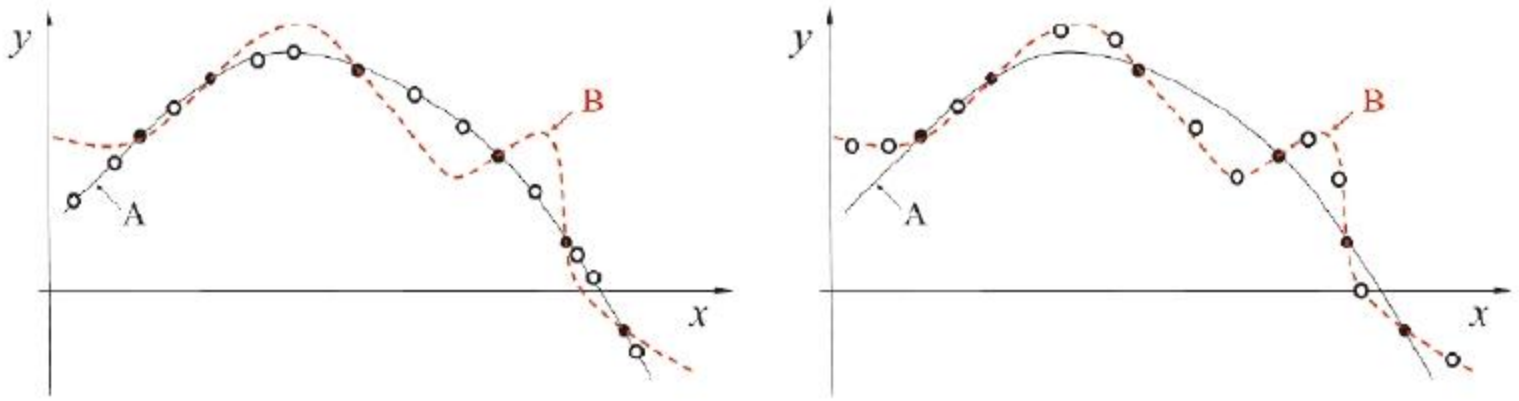
一般原则：
奥卡姆剃刀
(Ocam's razor)

任何一个有效的机器学习算法必有其偏好

学习算法的归纳偏好是否与问题本身匹配，
大多数时候直接决定了算法能否取得好的性能！

哪个算法更好？

没有免费的午餐！



(a) A 优于 B　　(b) B 优于 A

图 1.4　没有免费的午餐. (黑点: 训练样本; 白点: 测试样本)

NFL定理：一个算法 $\mathfrak{L}_a$ 若在某些问题上比另一个算法 $\mathfrak{L}_b$ 好，必存在另一些问题，$\mathfrak{L}_b$ 比 $\mathfrak{L}_a$ 好。

NFL定理

简单起见，假设样本空间 $\mathcal{X}$ 和假设空间 $\mathcal{H}$ 离散,令 $P(h|X,\mathfrak{L}_a)$ 代表算法 $\mathfrak{L}_a$ 基于训练数据 $\boldsymbol{X}$ 产生假设 h 的概率，f 代表要学的目标函数，$\mathfrak{L}_a$ 在训练集之外所有样本上的总误差为

$$E_{ote}(\mathfrak{L}_a|X,f)=\sum_{h}\sum_{\boldsymbol{x}\in\mathcal{X}-X}P(\boldsymbol{x})\,\mathbb{I}\left(h\left(\boldsymbol{x}\right)\neq f\left(\boldsymbol{x}\right)\right)P\left(h\mid X,\mathfrak{L}_a\right)$$

考虑二分类问题，目标函数可以为任何函数 $\mathcal{X}\mapsto\{0,1\}$，函数空间为 $\{0,1\}^{|\mathcal{X}|}$，对所有可能的 f 按均匀分布对误差求和，有

$$\sum_{f}E_{ote}(\mathfrak{L}_a|X,f)=\sum_{f}\sum_{h}\sum_{\boldsymbol{x}\in\mathcal{X}-X}P(\boldsymbol{x})\,\mathbb{I}(h(\boldsymbol{x})\neq f(\boldsymbol{x}))\;P(h\mid X,\mathfrak{L}_a)$$

NFL定理

$$\sum_f E_{ote}(\mathfrak{L}_a|X,f) = \sum_f \sum_h \sum_{\boldsymbol{x}\in\mathcal{X}-X} P(\boldsymbol{x})\,\mathbb{I}(h(\boldsymbol{x})\neq f(\boldsymbol{x}))\,P(h\mid X,\mathfrak{L}_a)$$

$$= \sum_{\boldsymbol{x}\in\mathcal{X}-X} P(\boldsymbol{x}) \sum_h P(h\mid X,\mathfrak{L}_a) \sum_f \mathbb{I}(h(\boldsymbol{x})\neq f(\boldsymbol{x}))$$

$$= \sum_{\boldsymbol{x}\in\mathcal{X}-X} P(\boldsymbol{x}) \sum_h P(h\mid X,\mathfrak{L}_a) \frac{1}{2} 2^{|\mathcal{X}|}$$

$$= \frac{1}{2} 2^{|\mathcal{X}|} \sum_{\boldsymbol{x}\in\mathcal{X}-X} P(\boldsymbol{x}) \sum_h P(h\mid X,\mathfrak{L}_a)$$

$$= 2^{|\mathcal{X}|-1} \sum_{\boldsymbol{x}\in\mathcal{X}-X} P(\boldsymbol{x})\cdot 1$$

总误差与学习算法无关！



所有算法一样好！

NFL定理的寓意

NFL定理的重要前提：

所有“问题”出现的机会相同、或所有问题同等重要

实际情形并非如此；我们通常只关注自己正在试图解决的问题

脱离具体问题，空泛地谈论“什么学习算法更好”
毫无意义！

思考题

1. 机器学习不需要什么？
   A、数据

   B、训练员

   C、算法

   D、计算机

2. 请按范围大小填空：____ > ____ > ____

（每空填入 机器学习，人工智能，深度学习，或数据库）

3. 用“自己的话”解释课本第8页公式（1.1）的意义。

前往第二站……



致谢：南京大学周志华教授