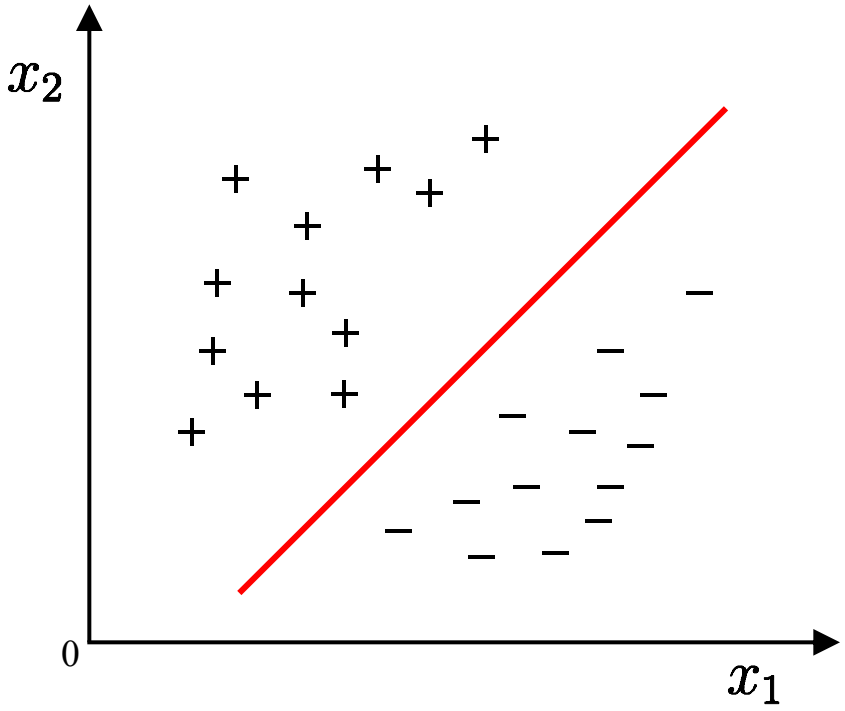
第六章：支持向量机

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

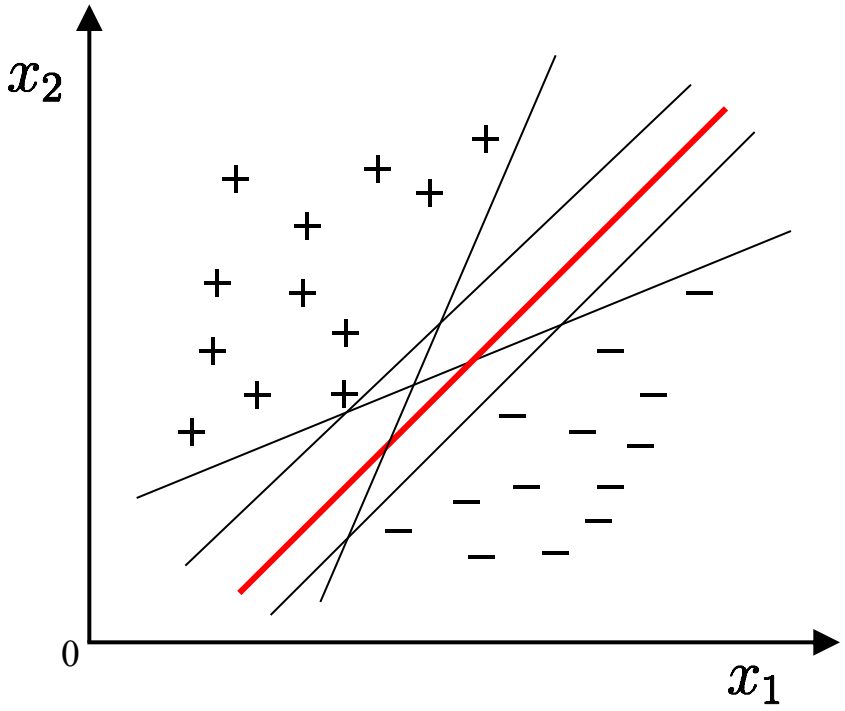
引子

线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开.



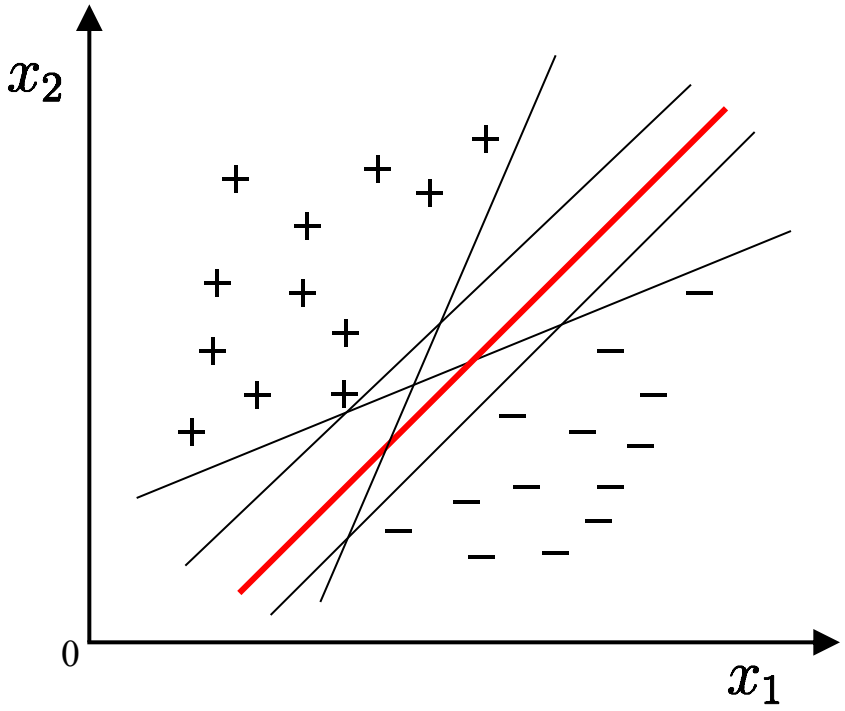
引子

-Q:将训练样本分开的超平面可能有很多，哪一个好呢?



引子

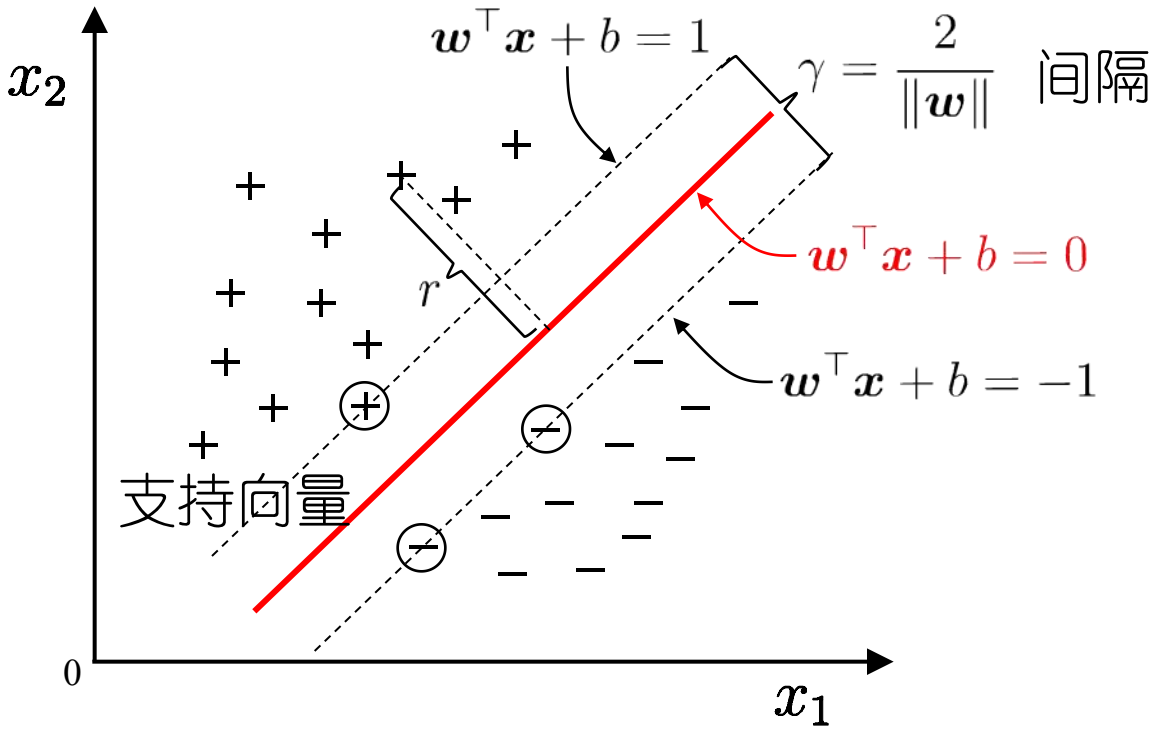
-Q:将训练样本分开的超平面可能有很多，哪一个好呢?



-A:应选择"正中间"，容忍性好，鲁棒性高，泛化能力最强.

间隔与支持向量

超平面方程：$\boldsymbol{w}^\top \boldsymbol{x} + b = 0$



支持向量机基本型

- 最大间隔：寻找参数 $\boldsymbol{w}$ 和 b，使得 γ 最大.

$$\begin{aligned} \arg\max_{\boldsymbol{w},b} \quad & \frac{2}{\|\boldsymbol{w}\|} \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m. \end{aligned}$$



$$\begin{aligned} \arg\min_{\boldsymbol{w},b} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m. \end{aligned}$$

带有约束的优化问题

$$\begin{cases} \min_{x\in D} f(x) \\ \text{s.t. } g_i(x) \le 0, i = 1,2,\ldots,q \\ h_j(x) = 0, j = q+1,\ldots,m \end{cases}$$

其中f(x)是目标函数，g(x)为不等式约束，h(x)为等式约束。

若f(x)，h(x)，g(x)三个函数都是线性函数，则该优化问题称为线性规划。
若任意一个是非线性函数，则称为非线性规划。

若目标函数为二次函数，约束全为线性函数，称为二次规划。

若f(x)为凸函数，g(x)为凸函数，h(x)为线性函数，则该问题称为**凸优化**。
注意这里不等式约束g(x)<=0则要求g(x)为凸函数，若g(x)>=0则要求g(x)为凹函数。

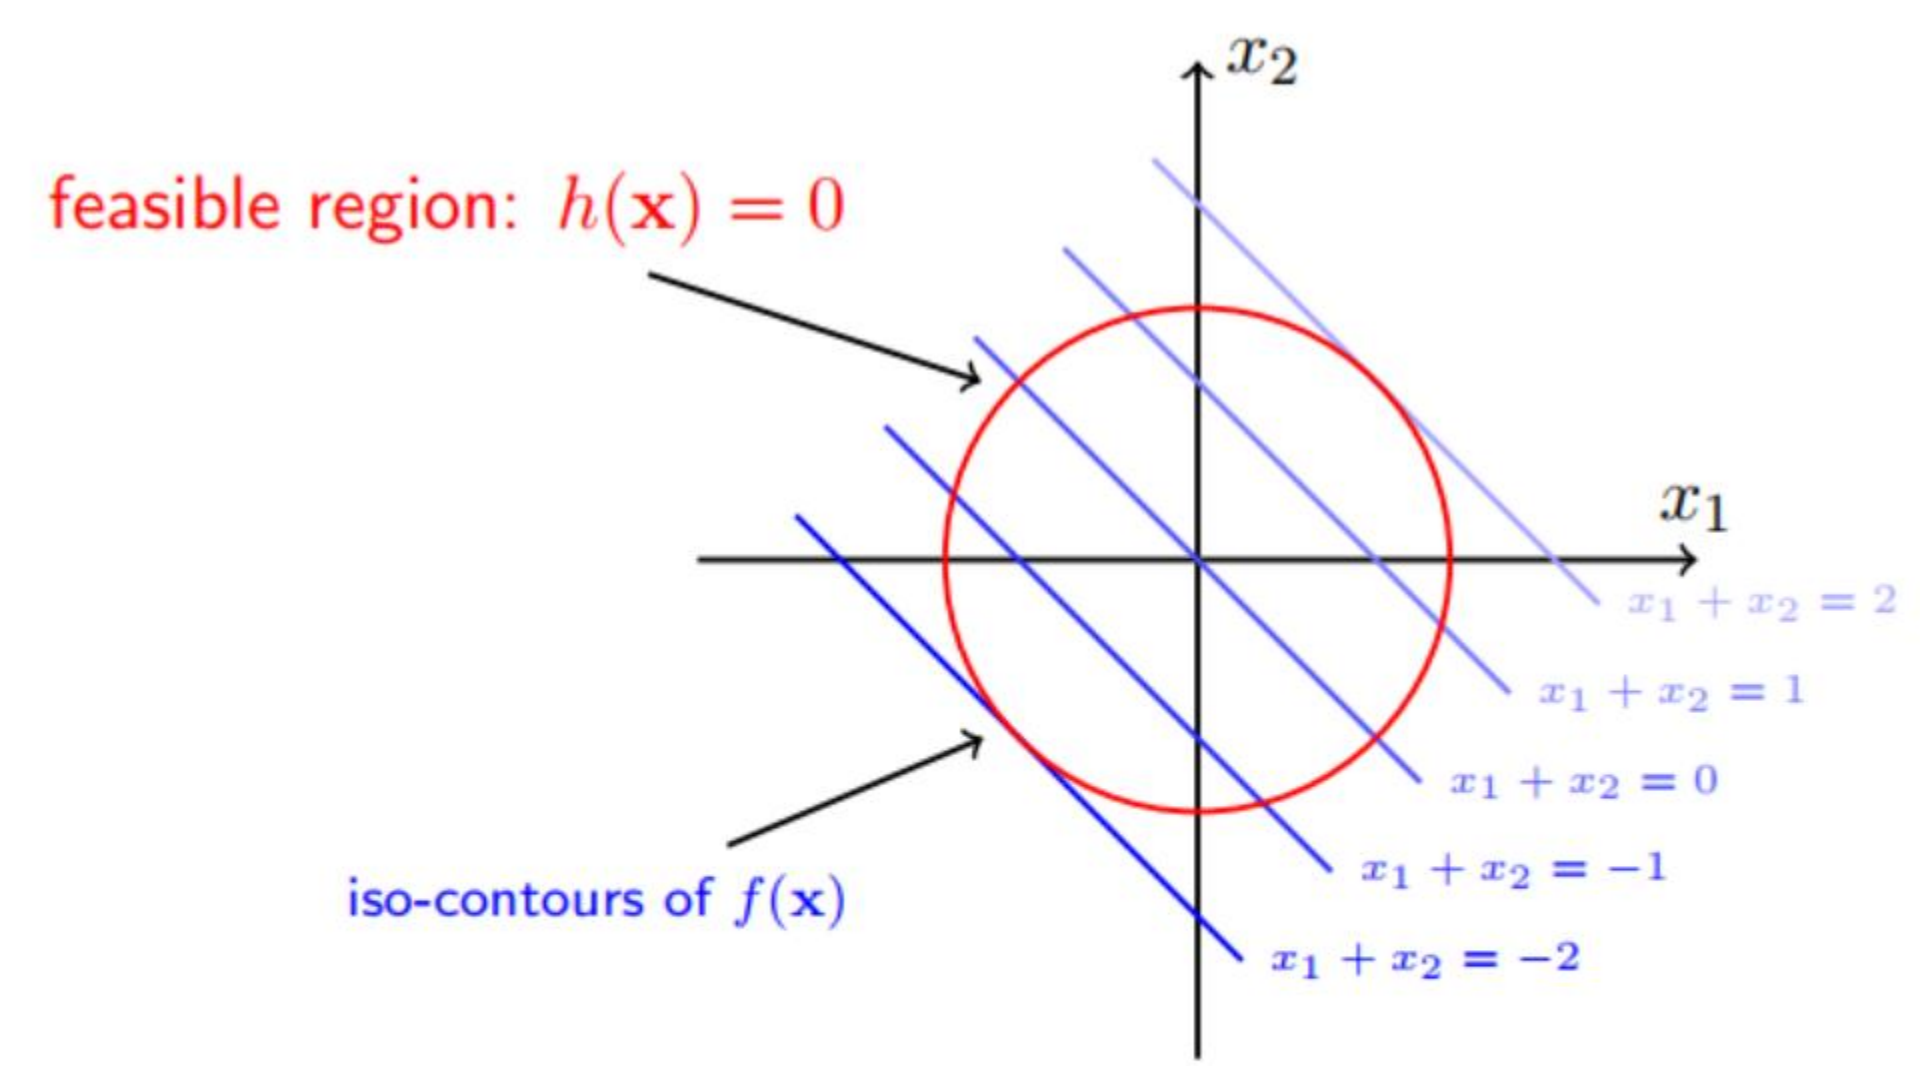
凸优化的任一局部极值点也是全局极值点，局部最优也是全局最优。

等式约束

考虑一个简单的问题目标函数

$$\begin{cases} \min f(x) = x_1 + x_2 \\ h(x) = x_1^2 + x_2^2 - 2 = 0 \end{cases}$$

$f(x) = x_1 + x_2$的等高线(*contour*)是一条条斜率相同的直线：$x_1 + x_2 = C$



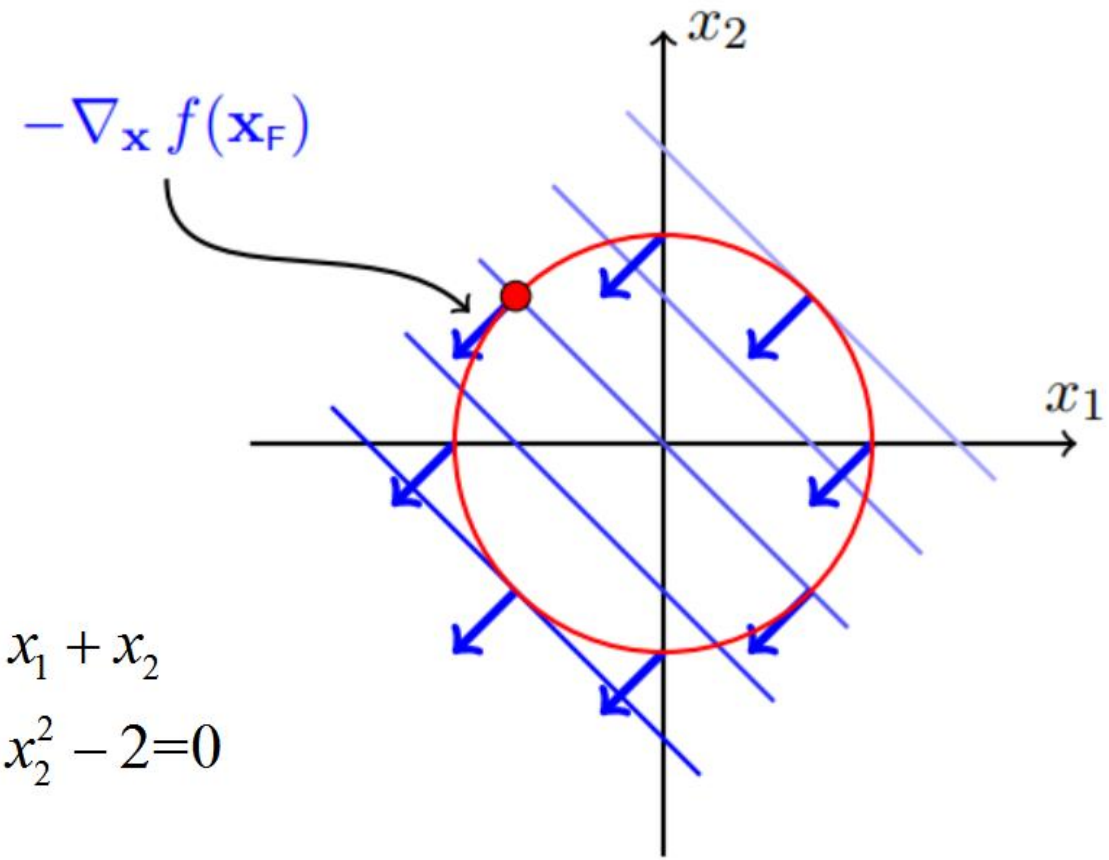
$$\begin{cases} \min f(x) = x_1 + x_2 \\ h(x) = x_1^2 + x_2^2 - 2 = 0 \end{cases}$$

$$h(\mathbf{x}) = x_1^2 + x_2^2 - 2$$

不考虑圆h(x)的限制时，f(x)要得到极小值，需要往f(x)的负梯度（下降最快的方向）方向走，如下左图蓝色箭头。

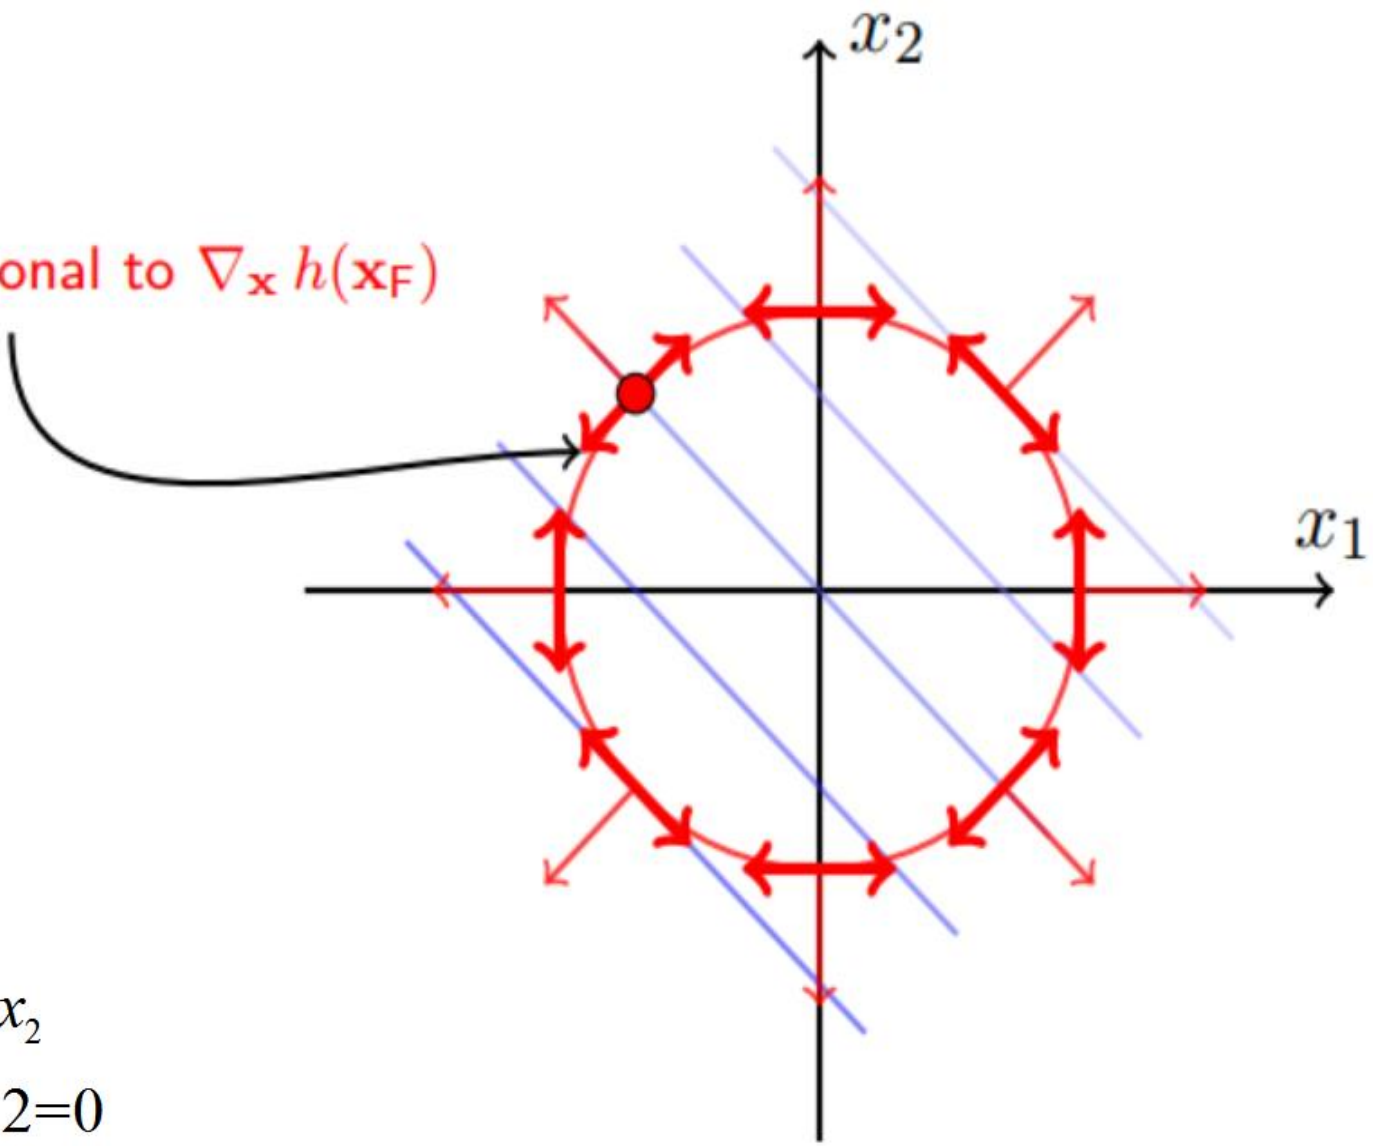
如果考虑圆h(x)的限制，要得到极小值，需要沿着圆的切线方向走，如下右图红色粗箭头。注意这里的方向不是h(x)的梯度，而是正交于h(x)的梯度，h(x)梯度如下右图的红色细箭头。

在极小值点，f(x)和h(x)的等高线是相切的。



$$\begin{cases} \min f(x) = x_1 + x_2 \\ h(x) = x_1^2 + x_2^2 - 2 = 0 \end{cases}$$

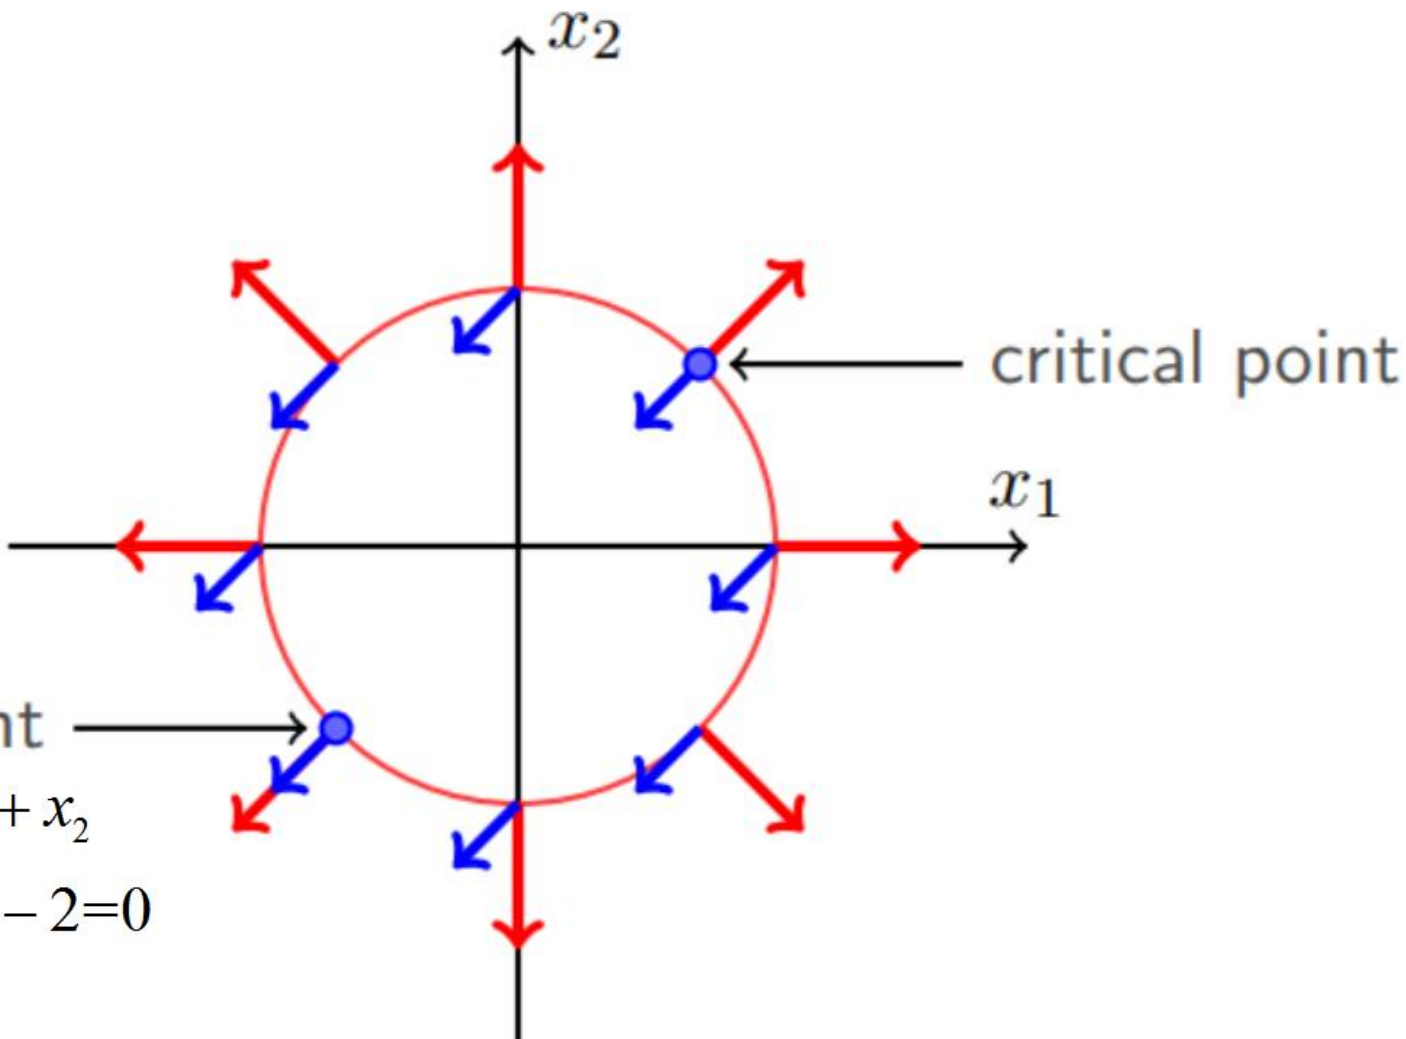
Direction orthogonal to $\nabla_{\mathbf{x}} h(\mathbf{x}_F)$



$$\begin{cases} \min f(x) = x_1 + x_2 \\ h(x) = x_1^2 + x_2^2 - 2 = 0 \end{cases}$$

在关键的极小值点处，f(x)的负梯度和h(x)的梯度在同一直线上，如下图左下方critical point的蓝色和红色箭头所示。

$$\nabla_{\mathbf{x}} f\left(\mathbf{x}^*\right) = \mu \nabla_{\mathbf{x}} h\left(\mathbf{x}^*\right)$$



$$\begin{cases} \min f(x) = x_1 + x_2 \\ h(x) = x_1^2 + x_2^2 - 2 = 0 \end{cases}$$

Remember our constrained optimization problem is

$$\min_{\mathbf{x}\in\mathbb{R}^2} f(\mathbf{x}) \text{ subject to } h(\mathbf{x}) = 0$$

Define the **Lagrangian** as note $\mathcal{L}(\mathbf{x}^*, \mu^*) = f(\mathbf{x}^*)$ ↓

$$\mathcal{L}(\mathbf{x}, \mu) = f(\mathbf{x}) + \mu\, h(\mathbf{x})$$

Then $\mathbf{x}^*$ a local minimum $\iff$ there exists a unique μ^* s.t.

1. $\nabla_{\mathbf{x}}\mathcal{L}(\mathbf{x}^*, \mu^*) = \mathbf{0}$ ← encodes $\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mu^* \nabla_{\mathbf{x}} h(\mathbf{x}^*)$
2. $\nabla_{\mu}\mathcal{L}(\mathbf{x}^*, \mu^*) = 0$ ← encodes the equality constraint $h(\mathbf{x}^*) = 0$

特别注意：优化问题是凸优化的话，通过上图两个条件求得的解就是极小值点（而且是全局极小）。不是凸优化的话，这两个条件只是极小值点的必要条件，还需要附加多一个正定的条件才能变成充要条件，如下图所示。

Remember our constrained optimization problem is

$$\min_{\mathbf{x}\in\mathbb{R}^2} f(\mathbf{x}) \text{ subject to } h(\mathbf{x}) = 0$$

Define the **Lagrangian** as note $\mathcal{L}(\mathbf{x}^*, \mu^*) = f(\mathbf{x}^*)$

$$\mathcal{L}(\mathbf{x}, \mu) = f(\mathbf{x}) + \mu\, h(\mathbf{x})$$

Then $\mathbf{x}^*$ a local minimum $\iff$ there exists a unique μ^* s.t.

1. $\nabla_{\mathbf{x}}\mathcal{L}(\mathbf{x}^*, \mu^*) = \mathbf{0}$ ← encodes $\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mu^* \nabla_{\mathbf{x}} h(\mathbf{x}^*)$
2. $\nabla_{\mu}\mathcal{L}(\mathbf{x}^*, \mu^*) = 0$ ← encodes the equality constraint $h(\mathbf{x}^*) = 0$
3. $\mathbf{y}^t(\nabla^2_{\mathbf{xx}}\mathcal{L}(\mathbf{x}^*, \mu^*))\mathbf{y} \geq 0 \quad \forall \mathbf{y} \text{ s.t. } \nabla_{\mathbf{x}} h(\mathbf{x}^*)^t \mathbf{y} = 0$

↑

Positive definite Hessian tells us we have a local minimum

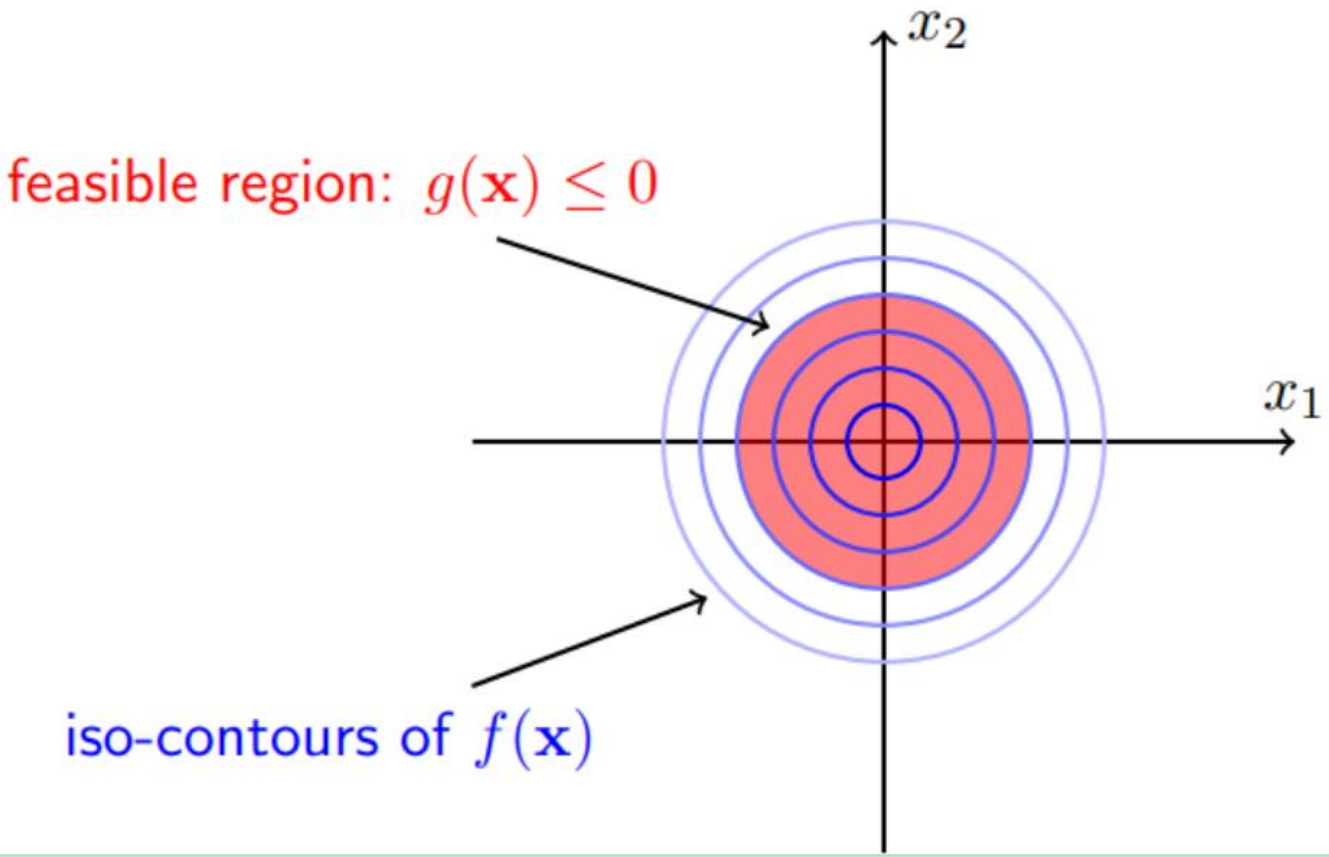
不等式约束

对于不等式约束g(x)<=0和等式约束h(x)=0不一样，h(x)=0可以在平面上画出一条等高线，而g(x)<=0是一个区域，很多个等高线堆叠而成的一块区域，我们把这块区域称为可行域。

极小值点落在可行域内（不包含边界）

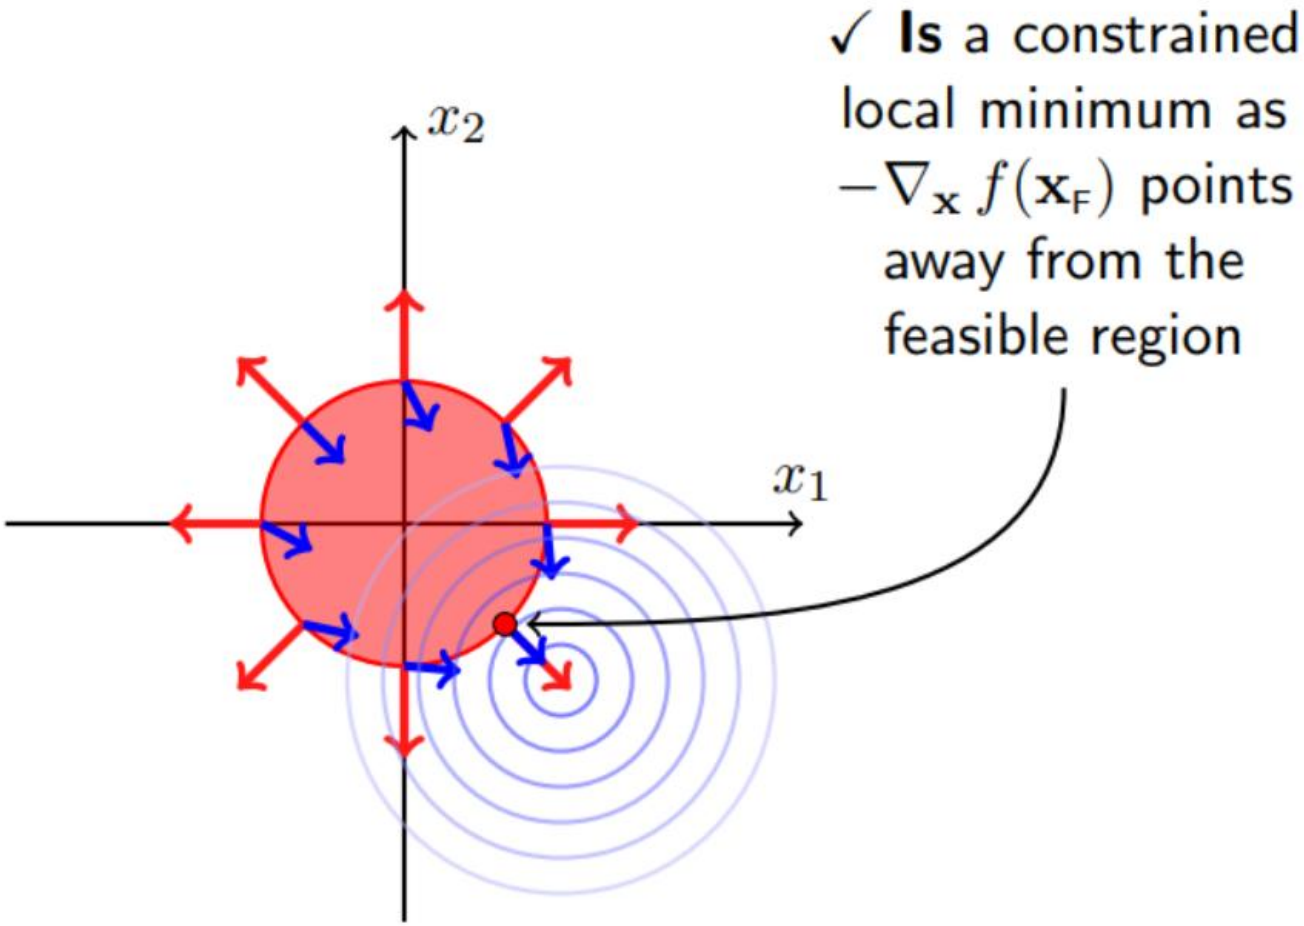
$$\begin{cases} \min f(x) = x_1^2 + x_2^2 \\ g(x) = x_1^2 + x_2^2 - 1 \le 0 \end{cases}$$

⇒ 最小值点为(0, 0)

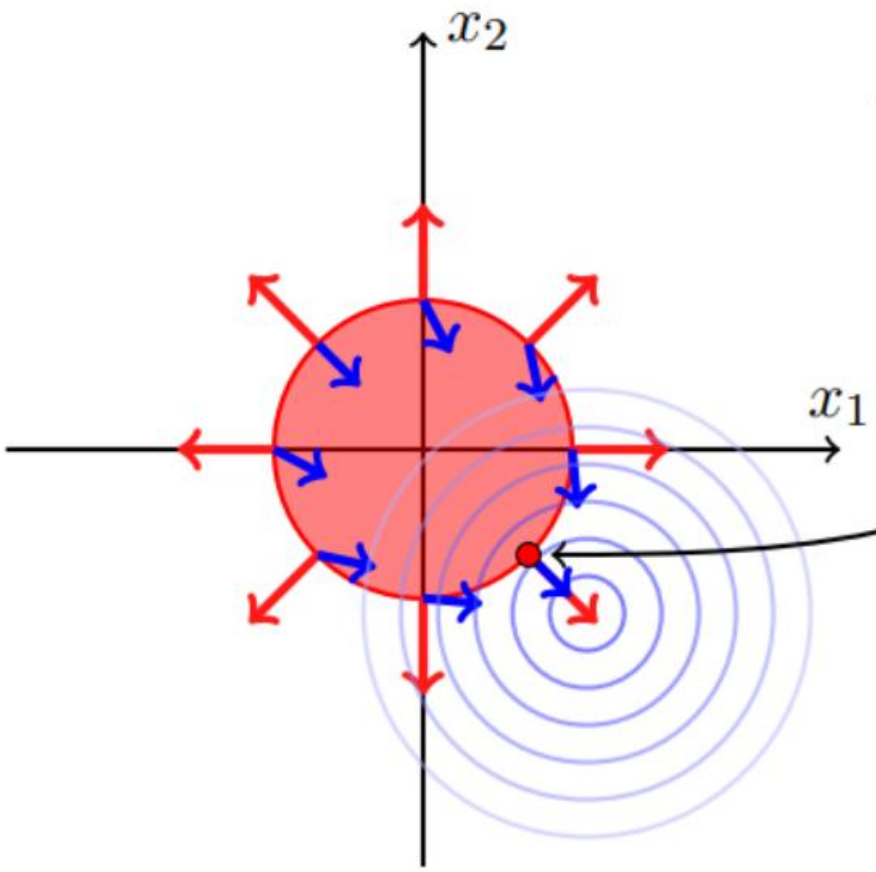


极小值点落在可行域外（包含边界）

$$\begin{cases} \min f(x) = (x_1 - 1.1)^2 + (x_2 + 1.1)^2 \\ g(x) = x_1^2 + x_2^2 - 1 \le 0 \end{cases}$$



对于f(x)而言要沿着f(x)的负梯度方向走，才能走到极小值点，如下图的蓝色箭头。这个时候g(x)的梯度往区域外发散，如下图红色箭头。显然，走到极小值点的时候，g(x)的梯度和f(x)的负梯度同向。因为极小值点在边界上，这个时候g(x)等于0



✓ **Is** a constrained local minimum as $-\nabla_{\mathbf{x}} f(\mathbf{x}_F)$ points away from the feasible region

$\therefore$ Constrained local minimum occurs when $-\nabla_{\mathbf{x}} f(\mathbf{x})$ and $\nabla_{\mathbf{x}} g(\mathbf{x})$ point in the same direction:

$$-\nabla_{\mathbf{x}} f(\mathbf{x}) = \lambda \nabla_{\mathbf{x}} g(\mathbf{x}) \quad \textbf{and} \quad \lambda > 0$$

总结

极小值点落在可行域内（不包含边界）：这个时候可行域的限制不起作用，相当于没有约束，直接f(x)的梯度等于0求解，这个时候g(x极小值点)<0（因为落在可行域内）。
极小值点落在可行域外（包含边界）：可行域的限制起作用，极小值点应该落在可行域边界上即g(x)=0，类似于等值约束，此时有g(x)的梯度和f(x)的负梯度同向。

总结

If $\mathbf{x}^*$ corresponds to a constrained local minimum then

Case 1:
Unconstrained local minimum occurs **in** the feasible region.

1. $g(\mathbf{x}^*) < 0$
2. $\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$

Case 2:
Unconstrained local minimum lies **outside** the feasible region.

1. $g(\mathbf{x}^*) = 0$
2. $-\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \lambda \nabla_{\mathbf{x}} g(\mathbf{x}^*)$ with $\lambda > 0$

对于不等式约束的优化，需要满足三个条件，满足这三个条件的解x*可能的极小值点。
这三个条件就是著名的**KKT条件**，它整合了上面两种情况的条件。

特别注意：

优化问题是凸优化的话，KKT条件就是极小值点（而且是全局极小）存在的充要条件。不是凸优化的话，KKT条件只是极小值点的必要条件，不是充分条件，KKT点是驻点，是可能的极值点。也就是说，就算求得的满足KKT条件的点，也不一定是极小值点，只是说极小值点一定满足KKT条件。

总结

如果有m个不等式约束，就需要讨论 2^m 种情况！需要找到新的方法。

对偶方法

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

对偶问题 拉格朗日乘子法

$$\arg\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2$$
$$\text{s.t.} \ \ y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 + \sum_{i=1}^{m} \alpha_i \left(1 - y_i(\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}_i + b)\right)$$

$$\frac{1}{2} w^T w + \sum_{i=1}^{m} \alpha_i - w^T \sum_{i=1}^{m} \alpha_i y_i x_i - \left(\sum_{i=1}^{m} \alpha_i y_i\right) b$$

- 第二步：令 $L(\boldsymbol{w}, b, \boldsymbol{\alpha})$ 对 $\boldsymbol{w}$ 和 b 的偏导为零可得

$$\boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i \ , \qquad 0 = \sum_{i=1}^{m} \alpha_i y_i$$

$$-\frac{1}{2} w^T \sum_{i=1}^{m} \alpha_i y_i x_i + \sum_{i=1}^{m} \alpha_i$$

- 第三步：回代可得

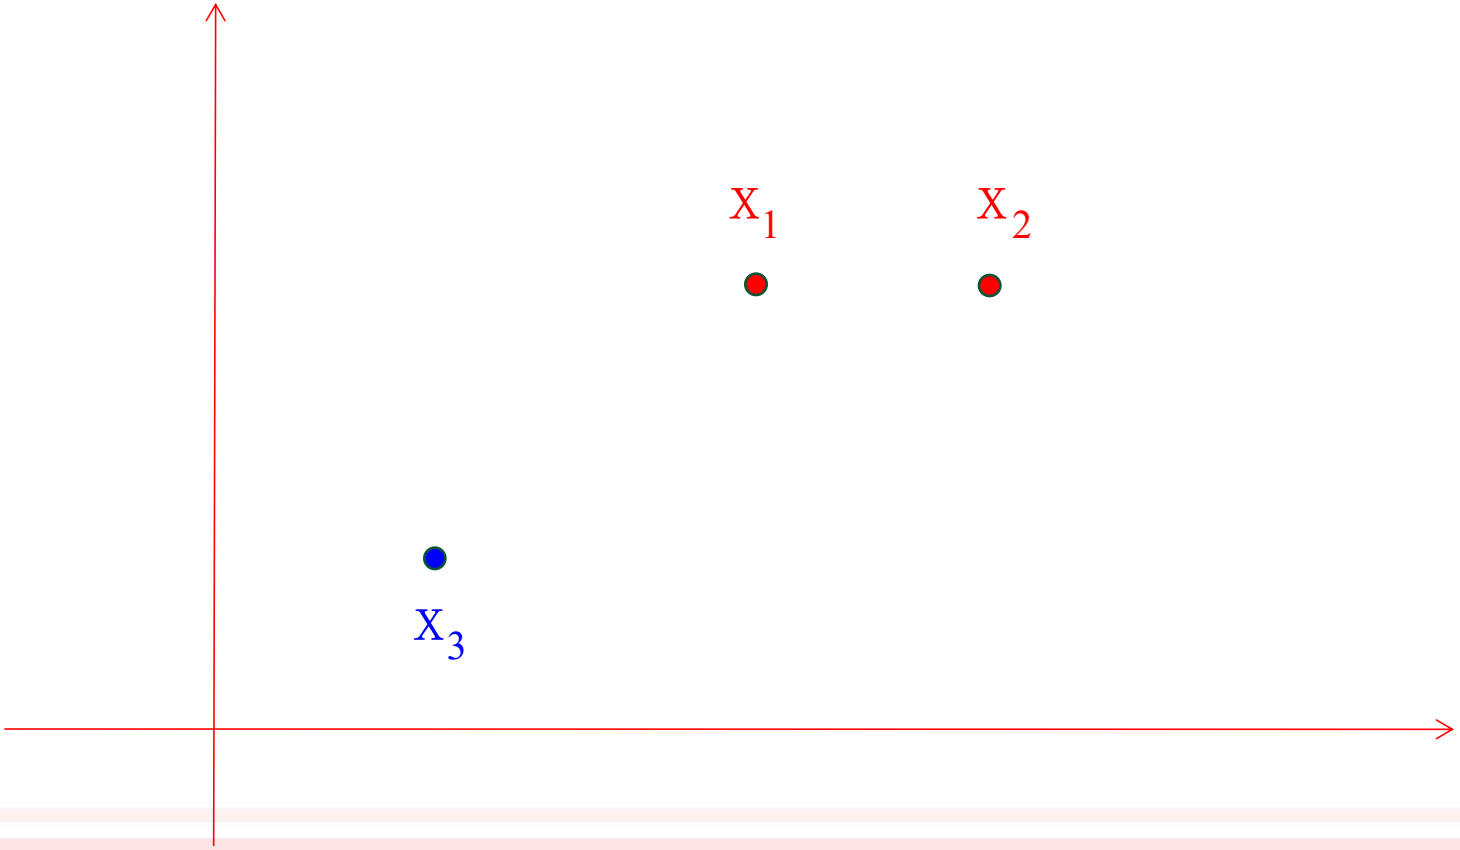
$$\max_{\boldsymbol{\alpha}} \ \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$$

$$\text{s.t.} \ \ \sum_{i=1}^{m} \alpha_i y_i = 0 \ , \ \ \alpha_i \geqslant 0 \ , \ \ \ i = 1, 2, \ldots, m$$

对偶方法重新求解前面的问题

$$\arg\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2$$
$$\text{s.t.} \ \ y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

如图所示的训练数据集，其正实例点是$x_1 = (3,3), x_2 = (4,3)$，负实例$x_3 = (1,1)$，试求其线性可分的支持向量机。



对偶方法重新求解前面的问题

$$\arg\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2$$
$$\text{s.t.} \ \ y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

例：$$\min_{w_1, w_2, b} \frac{1}{2}\left(w_1^2 + w_2^2\right)$$

$$s.t. \begin{cases} 3w_1 + 3w_2 + b \geq 1 \\ 4w_1 + 3w_2 + b \geq 1 \\ w_1 + w_2 + b \leq -1 \end{cases}$$

$$\Rightarrow \quad w_1 = w_2 = \frac{1}{2}, \quad b = -2$$

第一步：转化为对偶问题

$$\min_{\alpha_1,\alpha_2,\alpha_3} -\sum_{i=1}^{3}\alpha_i+\frac{1}{2}\sum_{i=1}^{3}\sum_{j=1}^{3}\alpha_i\alpha_j y_i y_j\left(x_i{}^{\mathrm{T}}x_j\right)$$

$$s.t.\ \begin{cases}\alpha_1+\alpha_2-\alpha_3=0\\ \alpha_1\geq 0,\alpha_2\geq 0,\alpha_3\geq 0\end{cases}$$

$$\min_{\alpha_1,\alpha_2,\alpha_3}\left\{\frac{1}{2}\left(18\alpha_1^2+25\alpha_2^2+2\alpha_3^2+42\alpha_1\alpha_2-12\alpha_1\alpha_3-14\alpha_2\alpha_3\right)-\alpha_1-\alpha_2-\alpha_3\right\}$$

$$s.t.\ \begin{cases}\alpha_1+\alpha_2-\alpha_3=0\\ \alpha_1\geq 0,\alpha_2\geq 0,\alpha_3\geq 0\end{cases}$$

$$\max_{\boldsymbol{\alpha}}\ \sum_{i=1}^{m}\alpha_i-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x}_j$$

$$\text{s.t.}\ \sum_{i=1}^{m}\alpha_i y_i=0\ ,\ \alpha_i\geqslant 0\ ,\quad i=1,2,\ldots,m$$

第二步：代入约束条件 $\alpha_3=\alpha_1+\alpha_2$

目标函数变形为：

$$s(\alpha_1,\alpha_2)=4\alpha_1^2+\frac{13}{2}\alpha_2^2+10\alpha_1\alpha_2-2\alpha_1-2\alpha_2$$

$$\Rightarrow\begin{cases}s_{\alpha_1}(\alpha_1,\alpha_2)=8\alpha_1+10\alpha_2-2\\ s_{\alpha_2}(\alpha_1,\alpha_2)=13\alpha_2+10\alpha_1-2\end{cases}$$

$$\Rightarrow\begin{cases}\alpha_1=\dfrac{3}{2}\\ \alpha_2=-1\end{cases}$$ 不符合要求，从而最小值在边界达到。

$$\max_{\boldsymbol{\alpha}}\ \sum_{i=1}^{m}\alpha_i-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x}_j$$

$$\text{s.t.}\ \ \sum_{i=1}^{m}\alpha_i y_i=0\ ,\ \ \alpha_i\geqslant 0\ ,\ \ \ i=1,2,\ldots,m$$

第三步：利用KKT条件，计算向量w

当 $\alpha_1=0$ 时，

$$s(0,\alpha_2)=\frac{13}{2}\alpha_2^2-2\alpha_2,\quad \text{且 } s(0,\alpha_2)_{\min}\Big|_{\alpha_2=\frac{2}{13}}=-\frac{2}{13}$$

当 $\alpha_2=0$ 时，

$$s(\alpha_1,0)=4\alpha_1^2-2\alpha_1,\quad \text{且 } s(\alpha_1,0)_{\min}\Big|_{\alpha_1=\frac{1}{4}}=-\frac{1}{4}$$

从而：当 $\alpha_1=\frac{1}{4},\ \alpha_2=0,$ 时，$s_{\min}=-\frac{1}{4}.$ 此时 $\alpha_3=\frac{1}{4}.$

故：$w=\alpha_1y_1x_1+\alpha_3y_3x_3=\left(\frac{1}{2},\frac{1}{2}\right)$

第四步：利用KKT条件，计算b

注意到 $\alpha_1 > 0$, 从而 x_1 为支持向量。

从而 $y_1 f(x_1) = 1 \overset{y_1^2=1}{\Longrightarrow} y_1^2 f(x_1) = y_1 \Rightarrow b = y_1 - w' x_1 = -2$

这样我们就得到了支持向量机（分离超平面）

$$\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2 = 0$$

对于新的样本点，我们使用的决策函数为

$$f(x) = \text{sign}\left(\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2\right)$$

如果样本变多，人工计算不现实，需要一种高效的计算算法

高效求解方法 – SMO: sequential minimal optimization

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0 \,, \quad \alpha_i \geqslant 0 \,, \quad i = 1, 2, \ldots, m$$

- 基本思路：不断执行如下两个步骤直至收敛.
  - 第一步：选取一对需更新的变量 α_i 和 α_j.
  - 第二步：固定 α_i 和 α_j 以外的参数，求解对偶问题更新 α_i 和 α_j.

- 仅考虑 α_i 和 α_j 时，对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = -\sum_{k \neq i,j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

用一个变量表示另一个变量，回代入对偶问题可得一个单变量的二次规划，该问题具有闭式解.

- 偏移项 b：通过支持向量来确定.

SMO 变量选择原则

- 第一个变量是在KKT条件不满足的中间选择，直观来看，KKT条件违背的程度越大，则变量更新后可能会使得目标函数的增幅越大，从而选择违背KKT条件程度越大的变量
- 第二个变量应选择使得目标函数增长最快的变量；常用启发式，也就是两样本的间距最大

解的稀疏性

- 解出α后代入直线方程
- 得到最终模型：$f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i^{\top}\boldsymbol{x} + b$
- 由KKT条件可知，对大多数i，α_i值为零：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) \geq 1, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0. \end{cases}$$

⇒ 必有 $\alpha_i = 0$ 或 $y_i f(\boldsymbol{x}_i) = 1$

$$y_i f(\boldsymbol{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关.

重要性质：模型训练完后，大部分的训练样本都不需要保留，最终模型仅仅与支持向量有关

大纲

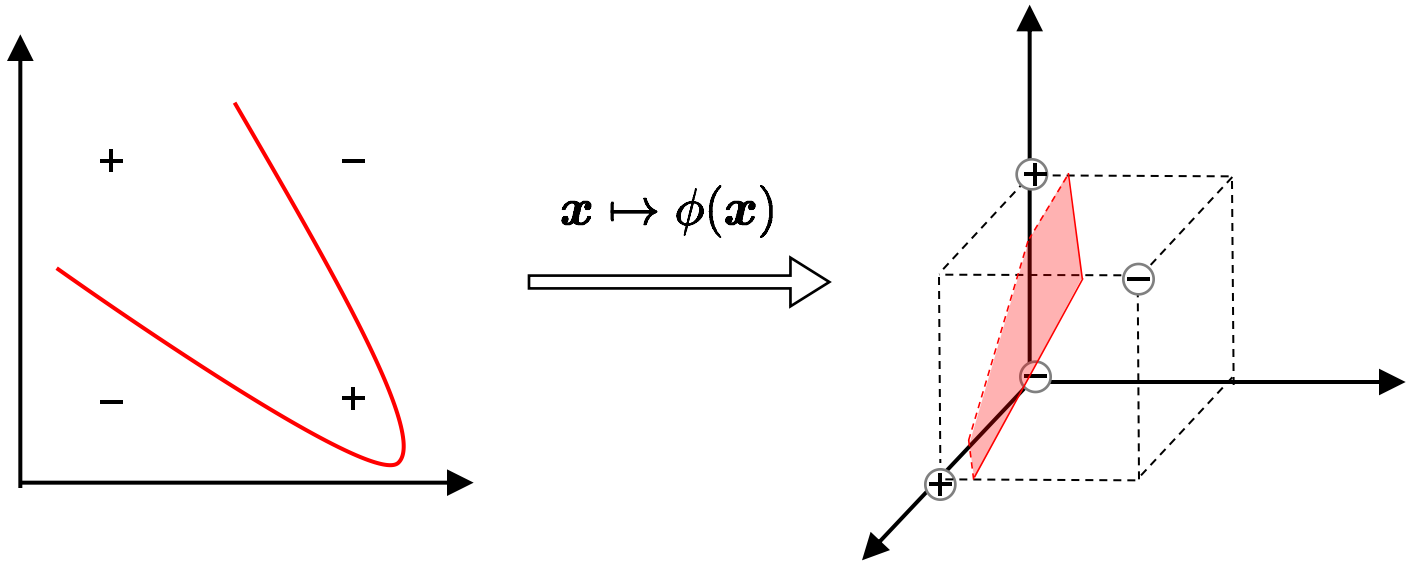
- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

线性不可分

-Q:若不存在一个能正确划分两类样本的超平面，怎么办?

-A:将样本从原始空间映射到一个更高维的特征空间，使得样本在这个特征空间内线性可分.

-核函数的作用：计算样本在高维空间的内积。



核支持向量机

原问题

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i^\top \boldsymbol{x} + b$$

- 设样本$\boldsymbol{x}$映射后的向量为$\phi(\boldsymbol{x})$，划分超平面为$f(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) + b$.

原始问题

$$\begin{aligned} \min_{\boldsymbol{w},b} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^\top \phi(\boldsymbol{x}_i) + b) \geq 1, \ i = 1, 2, \ldots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boxed{\phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)} - \sum_{i=1}^{m} \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^{m} \alpha_i y_i = 0, \ \alpha_i \geq 0, \ i = 1, 2, \ldots, m. \end{aligned}$$

预测

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) + b = \sum_{i=1}^{m} \alpha_i y_i \boxed{\phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x})} + b$$

只以内积的形式出现

核函数

- 基本想法：不显式地设计核映射，而是设计核函数.

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^{\top} \phi(\boldsymbol{x}_j)$$

- 核矩阵：每两个样本之间进行一次核函数影射得到的点的合集。
- Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定，则它就能作为核函数来使用.

$$\text{核矩阵K}=\begin{bmatrix} \kappa(x_1,x_1) & \kappa(x_1,x_2) & \kappa(x_1,x_3) & \cdots & \kappa(x_1,x_m) \\ \kappa(x_2,x_1) & \kappa(x_2,x_2) & \kappa(x_2,x_3) & \cdots & \kappa(x_2,x_m) \\ \kappa(x_3,x_1) & \kappa(x_3,x_2) & \kappa(x_3,x_3) & \cdots & \kappa(x_3,x_m) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \kappa(x_m,x_1) & \kappa(x_m,x_2) & \kappa(x_m,x_3) & \cdots & \kappa(x_m,x_m) \end{bmatrix}$$

核函数

- 基本想法：不显式地设计核映射，而是设计核函数.

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)$$

- Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定，则它就能作为核函数来使用.

- 常用核函数：

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^\top \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^\top \boldsymbol{x}_j)^d$	$d \geq 1$为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2\delta^2}\right)$	$\delta > 0$为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|}{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh(\beta \boldsymbol{x}_i^\top \boldsymbol{x}_j + \theta)$	tanh为双曲正切函数, $\beta > 0, \theta < 0$

核函数

- 预测阶段核函数的使用：
  - 仅计算测试数据和支持向量的核函数

$$f(x) = sgn\left(\sum_i y_i \alpha_i k(x, x_i) + b\right)$$

Here the sum goes over support vectors x_i, α are the lagrangian multiplier and y is 1 for one class and -1 for the other.

核函数的注意事项：

- 核函数选择成为svm的最大变数
- 经验：文本数据使用线性核，情况不明使用高斯核
- 核函数的性质：
- 1 核函数的线性组合仍为核函数
- 2 核函数的直积仍为核函数

$$\kappa_1 \otimes \kappa_2 \left(x_1, x_1 \right) = \kappa_1 \left(x_1, x_2 \right) \kappa_2 \left(x_1, x_2 \right)$$

- 3 设 $\kappa(x_1, x_2)$ 为核函数，则对于任意函数g，

$$g(x_1)\kappa\left(x_1, x_2\right)g(x_2)\text{仍为核函数。}$$

大纲

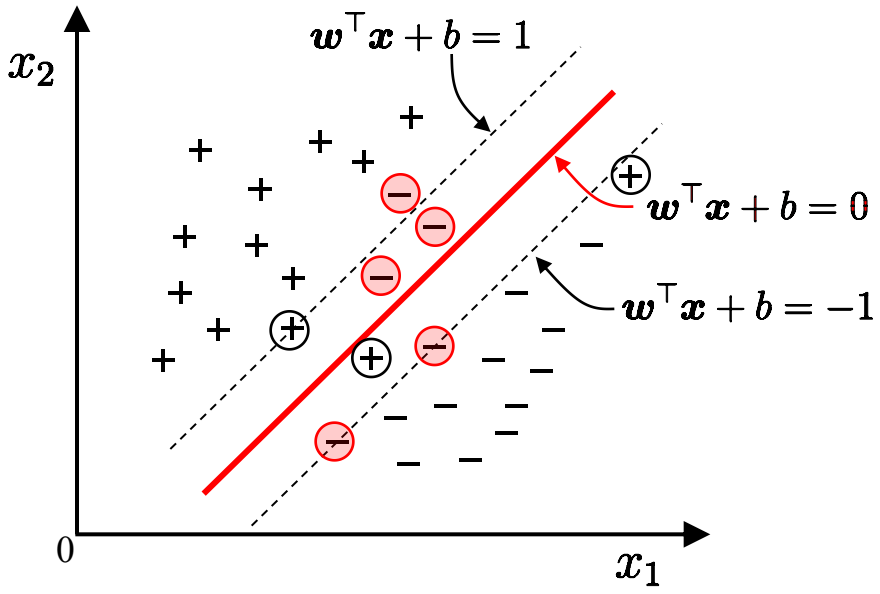
- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

软间隔

-Q:现实中，很难确定合适的核函数使得训练样本在特征空间中线性可分；同时一个线性可分的结果也很难断定是否是有过拟合造成的.

-A:引入"软间隔"的概念，允许支持向量机在一些样本上不满足约束.

不满足约束的样本



0/1损失函数

参考 $\arg\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2$

s.t. $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1,\ i = 1, 2, \ldots, m.$

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少.

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} l_{0/1}\left(y_i(\boldsymbol{w}^\top \phi(\boldsymbol{x}_i) + b) - 1\right)$$

其中 $l_{0/1}$ 是"0/1损失函数"

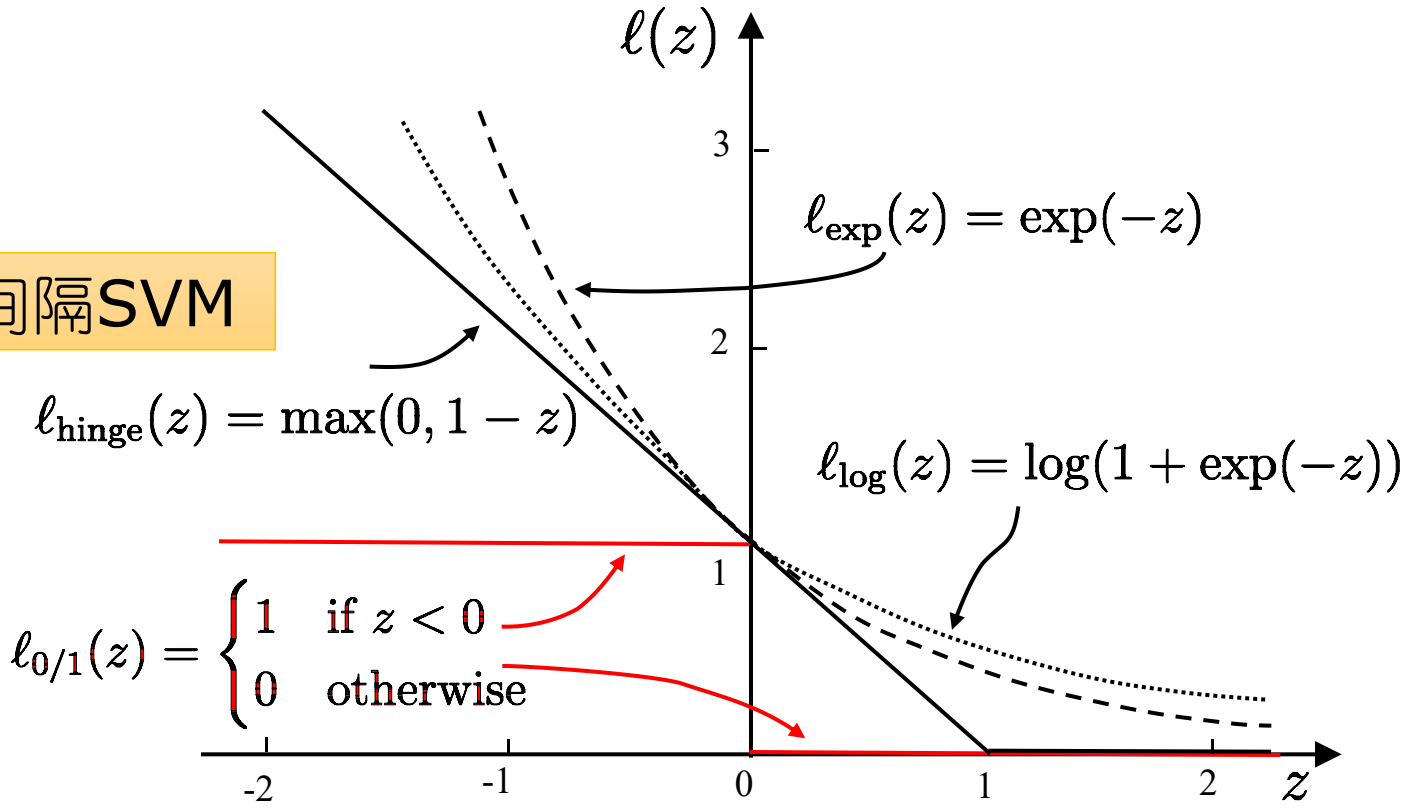
$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

正则化常数 $C > 0$, 如果 $C \to \infty$，则等价于要求所有的样本点都分类正确，否则就允许一部分极少的样本分类错误

- 存在的问题：0/1损失函数非凸、非连续，不易优化！

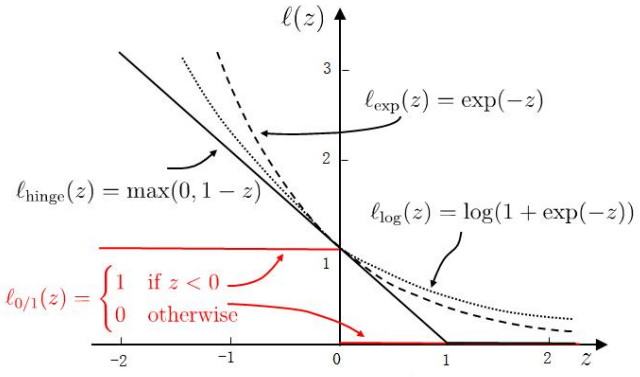
替代损失

软间隔SVM



替代损失函数数学性质较好，一般是0/1损失函数的上界

软间隔支持向量机



以hinge损失为例：

原始问题 $\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} \max\left(0, 1 - y_i(\boldsymbol{w}^\top \phi(\boldsymbol{x}_i) + b)\right)$

引入“松弛变量(Slack Variable)” $\xi \geq 0$，

$$\min_{\mathbf{w},b,\xi_i} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m} \xi_i$$

$$s.t. \quad y_i\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i + b\right) \geq 1 - \xi_i \qquad ---\text{软间隔SVM}$$

$$\xi_i \geq 0, i = 1, 2, \ldots, m$$

注：每一个样本都对应一个松弛变量ξ_i，用以表征该样本不满足约束 $y_i f(x_i) \geq 1$的程度。

求解软间隔问题：

- 构造Lagrange 函数

$$L(\mathbf{w},b,\alpha,\xi,\mu)=\frac{1}{2}\|\mathbf{w}\|^2+C\sum_{i=1}^{m}\xi_i+\sum_{i=1}^{m}\alpha_i\left(1-\xi_i-y_i\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i+b\right)\right)-\sum_{i=1}^{m}\mu_i\xi_i$$

$s.t.\ \alpha_i\geq 0,\mu_i\geq 0$

- 对变量求偏导并令其为0，可得

$$\boldsymbol{w}=\sum_{i=1}^{m}\alpha_i y_i\boldsymbol{x}_i\ ,$$

$$0=\sum_{i=1}^{m}\alpha_i y_i\ ,$$

$$C=\alpha_i+\mu_i\ .$$

$$\begin{aligned}
\min_{\boldsymbol{w},b,\boldsymbol{\xi}} L(\boldsymbol{w},b,\boldsymbol{\alpha},\boldsymbol{\xi},\boldsymbol{\mu}) &= \frac{1}{2}||\boldsymbol{w}||^2+C\sum_{i=1}^{m}\xi_i+\sum_{i=1}^{m}\alpha_i(1-\xi_i-y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b))-\sum_{i=1}^{m}\mu_i\xi_i \\
&= \frac{1}{2}||\boldsymbol{w}||^2+\sum_{i=1}^{m}\alpha_i(1-y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b))+C\sum_{i=1}^{m}\xi_i-\sum_{i=1}^{m}\alpha_i\xi_i-\sum_{i=1}^{m}\mu_i\xi_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\alpha_i y_i\boldsymbol{x}_i^T\sum_{i=1}^{m}\alpha_i y_i\boldsymbol{x}_i+\sum_{i=1}^{m}\alpha_i+\sum_{i=1}^{m}C\xi_i-\sum_{i=1}^{m}\alpha_i\xi_i-\sum_{i=1}^{m}\mu_i\xi_i \\
&= -\frac{1}{2}\sum_{i=1}^{m}\alpha_i y_i\boldsymbol{x}_i^T\sum_{i=1}^{m}\alpha_i y_i\boldsymbol{x}_i+\sum_{i=1}^{m}\alpha_i+\sum_{i=1}^{m}(C-\alpha_i-\mu_i)\xi_i \\
&= \sum_{i=1}^{m}\alpha_i-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j\boldsymbol{x}_i^T\boldsymbol{x}_j
\end{aligned}$$

软间隔支持向量机

原始问题

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}\max\left(0, 1 - y_i(\boldsymbol{w}^\top\phi(\boldsymbol{x}_i) + b)\right)$$

对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \phi(\boldsymbol{x}_i)^\top\phi(\boldsymbol{x}_j) - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ 0 \le \alpha_i \le C, \ i = 1, 2, \ldots, m.$$

根据KKT条件可推得最终模型仅与支持向量有关，也即hinge损失函数依然保持了支持向量机解的稀疏性.

正则化

- 支持向量机学习模型的更一般形式

$$\min_f \ \Omega(f) + C\sum_{i=1}^{m} l(f(\boldsymbol{x}_i), y_i)$$

结构风险，描述模型的某些性质

经验风险，描述模型与训练数据的契合程度

- 通过替换上面两个部分，可以得到许多其他学习模型
  - 对数几率回归(Logistic Regression)
  - 最小绝对收缩选择算子(LASSO)
  - ……

正则化

正则化可理解为一种“罚函数法”，即对不希望得到的结果施以惩罚，从而使得优化过程趋向于希望目标. 从贝叶斯估计的角度来看，正则化项可认为是提供了模型的先验概率.

正则化

L_p 范数 (norm) 是常用的正则化项, 其中 L_2 范数 $\|\boldsymbol{w}\|_2$ 倾向于 $\boldsymbol{w}$ 的分量取值尽量均衡, 即非零分量个数尽量稠密, 而 L_0 范数 $\|\boldsymbol{w}\|_0$ 和 L_1 范数 $\|\boldsymbol{w}\|_1$ 则倾向于 $\boldsymbol{w}$ 的分量尽量稀疏, 即非零分量个数尽量少.

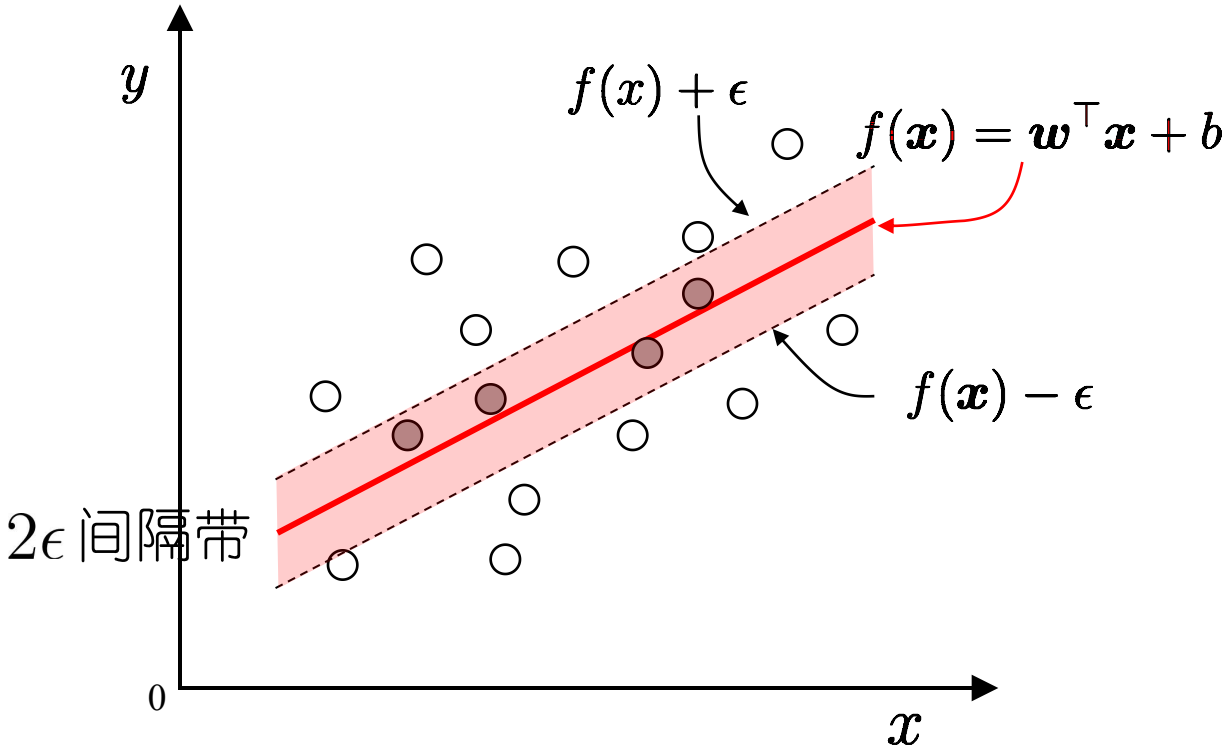
L0范数：是指向量中非0的元素的个数。
L1范数：是指向量中各个元素绝对值之和。
L2范数：是指向量各元素的平方和然后求平方根。

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

支持向量回归

特点：允许模型输出和实际输出间存在 2ϵ 的偏差.



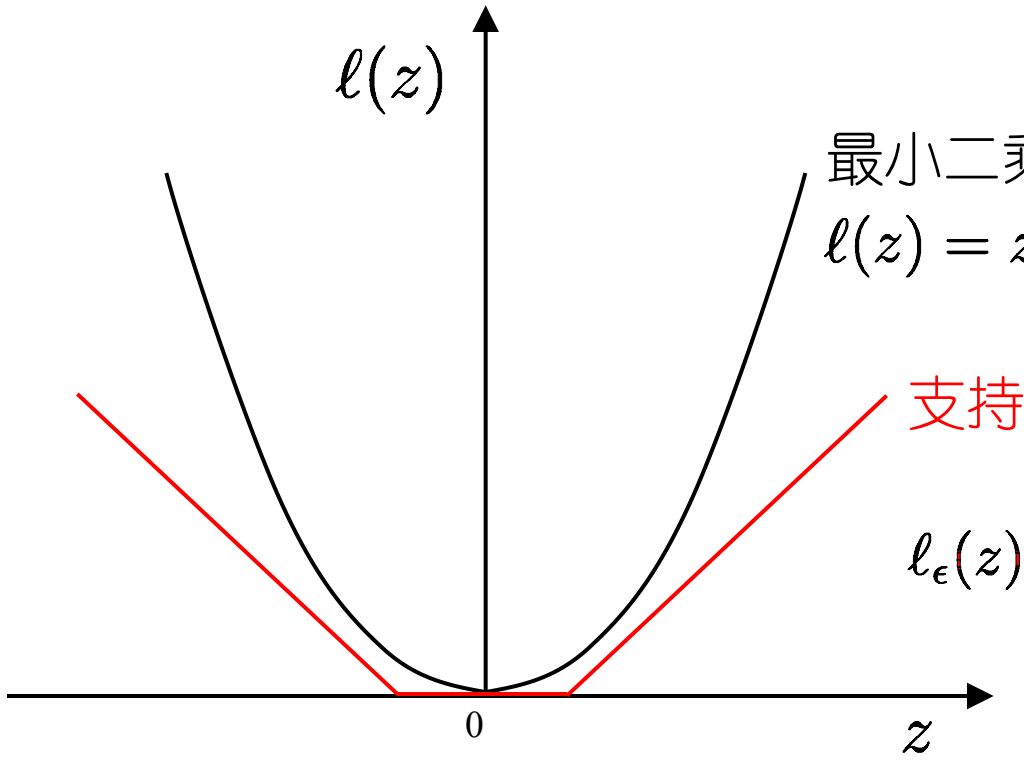
红色显示出 ϵ-间隔带，落入其中的样本不计算损失

支持向量回归

对样本 $(\boldsymbol{x}, y)$, 传统回归模型通常直接基于模型输出 $f(\boldsymbol{x})$ 与真实输出 y 之间的差别来计算损失, 当且仅当 $f(\boldsymbol{x})$ 与 y 完全相同时, 损失才为零. 与此不同, 支持向量回归(Support Vector Regression, 简称 SVR)假设我们能容忍 $f(\boldsymbol{x})$ 与 y 之间最多有 ϵ 的偏差, 即仅当 $f(\boldsymbol{x})$ 与 y 之间的差别绝对值大于 ϵ 时才计算损失. 如图 6.6 所示, 这相当于以 $f(\boldsymbol{x})$ 为中心, 构建了一个宽度为 2ϵ 的间隔带, 若训练样本落入此间隔带, 则认为是被预测正确的.

损失函数

落入中间 2ϵ 间隔带的样本不计算损失，从而使得模型获得稀疏性.



最小二乘损失函数

$$\ell(z) = z^2$$

支持向量回归损失函数

$$\ell_\epsilon(z) = \begin{cases} 0 & \text{if } |z| \leq \epsilon \\ |z| - \epsilon & \text{otherwise} \end{cases}$$

形式化

参考 $\arg\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2$

s.t. $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1,\ i = 1, 2, \ldots, m.$

原始问题

$$\begin{aligned} \min_{\boldsymbol{w},b,\xi_i,\hat{\xi}_i} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}(\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \boldsymbol{w}^\top \phi(\boldsymbol{x}_i) - b \leq \epsilon + \xi_i, \\ & y_i - \boldsymbol{w}^\top \phi(\boldsymbol{x}_i) - b \geq -\epsilon - \hat{\xi}_i, \\ & \xi_i \geq 0,\ \hat{\xi}_i \geq 0,\ i = 1, 2, \ldots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\boldsymbol{\alpha},\hat{\boldsymbol{\alpha}}} \quad & \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}(\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j)\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) + \sum_{i=1}^{m}(\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^{m}(\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \leq \alpha_i \leq C,\ 0 \leq \hat{\alpha}_i \leq C. \end{aligned}$$

预测 $$f(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)y_i\kappa(\boldsymbol{x}_i, \boldsymbol{x}) + b$$

推导SVR

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}, \hat{\boldsymbol{\alpha}}, \boldsymbol{\xi}, \hat{\boldsymbol{\xi}}, \boldsymbol{\mu}, \hat{\boldsymbol{\mu}})$$

$$= \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}(\xi_i + \hat{\xi}_i) - \sum_{i=1}^{m}\mu_i\xi_i - \sum_{i=1}^{m}\hat{\mu}_i\hat{\xi}_i$$

$$+ \sum_{i=1}^{m}\alpha_i\left(f\left(\boldsymbol{x}_i\right) - y_i - \epsilon - \xi_i\right) + \sum_{i=1}^{m}\hat{\alpha}_i\left(y_i - f\left(\boldsymbol{x}_i\right) - \epsilon - \hat{\xi}_i\right)$$

推导SVR

令 $L(\boldsymbol{w}, b, \boldsymbol{\alpha}, \hat{\boldsymbol{\alpha}}, \boldsymbol{\xi}, \hat{\boldsymbol{\xi}}, \boldsymbol{\mu}, \hat{\boldsymbol{\mu}})$ 对 $\boldsymbol{w}$, b, ξ_i 和 $\hat{\xi}_i$ 的偏导为零可得

$$\boldsymbol{w} = \sum_{i=1}^{m} (\hat{\alpha}_i - \alpha_i)\boldsymbol{x}_i \ , \tag{6.47}$$

$$0 = \sum_{i=1}^{m} (\hat{\alpha}_i - \alpha_i) \ , \tag{6.48}$$

$$C = \alpha_i + \mu_i \ , \tag{6.49}$$

$$C = \hat{\alpha}_i + \hat{\mu}_i \ . \tag{6.50}$$

推导SVR

将式(6.47)–(6.50)代入式(6.46), 即可得到 SVR 的对偶问题

$$\max_{\boldsymbol{\alpha},\hat{\boldsymbol{\alpha}}} \quad \sum_{i=1}^{m} y_i(\hat{\alpha}_i - \alpha_i) - \epsilon(\hat{\alpha}_i + \alpha_i)$$

$$-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}(\hat{\alpha}_i - \alpha_i)(\hat{\alpha}_j - \alpha_j)\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i) = 0 \ ,$$

$$0 \leqslant \alpha_i, \hat{\alpha}_i \leqslant C \ .$$

推导SVR

上述过程中需满足 KKT 条件, 即要求

$$\begin{cases} \alpha_i(f(\boldsymbol{x}_i) - y_i - \epsilon - \xi_i) = 0 \ , \\ \hat{\alpha}_i(y_i - f(\boldsymbol{x}_i) - \epsilon - \hat{\xi}_i) = 0 \ , \\ \alpha_i\hat{\alpha}_i = 0 \ , \ \xi_i\hat{\xi}_i = 0 \ , \\ (C - \alpha_i)\xi_i = 0 \ , \ (C - \hat{\alpha}_i)\hat{\xi}_i = 0 \ . \end{cases} \tag{6.52}$$

可以看出, 当且仅当 $f(\boldsymbol{x}_i) - y_i - \epsilon - \xi_i = 0$ 时 α_i 能取非零值, 当且仅当 $y_i - f(\boldsymbol{x}_i) - \epsilon - \hat{\xi}_i = 0$ 时 $\hat{\alpha}_i$ 能取非零值. 换言之, 仅当样本 $(\boldsymbol{x}_i, y_i)$ 不落入 ϵ-间隔带中, 相应的 α_i 和 $\hat{\alpha}_i$ 才能取非零值. 此外, 约束 $f(\boldsymbol{x}_i) - y_i - \epsilon - \xi_i = 0$ 和 $y_i - f(\boldsymbol{x}_i) - \epsilon - \hat{\xi}_i = 0$ 不能同时成立, 因此 α_i 和 $\hat{\alpha}_i$ 中至少有一个为零.

推导SVR

则 SVR 的解形如

$$f(\boldsymbol{x}) = \sum_{i=1}^{m} (\hat{\alpha}_i - \alpha_i) \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x} + b \ .$$

能使式(6.53)中的 $(\hat{\alpha}_i - \alpha_i) \neq 0$ 的样本即为 SVR 的支持向量, 它们必落在 ϵ-间隔带之外. 显然, SVR 的支持向量仅是训练样本的一部分, 即其解仍具有稀疏性.

推导SVR

由 KKT 条件(6.52)可看出, 对每个样本 $(\boldsymbol{x}_i, y_i)$ 都有 $(C-\alpha_i)\xi_i = 0$ 且 $\alpha_i(f(\boldsymbol{x}_i) - y_i - \epsilon - \xi_i) = 0$. 于是, 在得到 α_i 后, 若 $0 < \alpha_i < C$, 则必有 $\xi_i = 0$, 进而有

$$b = y_i + \epsilon - \sum_{i=1}^{m} (\hat{\alpha}_i - \alpha_i)\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x} \ . \tag{6.54}$$

因此, 在求解式(6.51)得到 α_i 后, 理论上来说, 可任意选取满足 $0 < \alpha_i < C$ 的样本通过式(6.54)求得 b. 实践中常采用一种更鲁棒的办法: 选取多个(或所有)满足条件 $0 < \alpha_i < C$ 的样本求解 b 后取平均值.

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法

表示定理

支持向量机 $$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\phi(\boldsymbol{x}) + b = \sum_{i=1}^{m} \alpha_i y_i \kappa(\boldsymbol{x}_i, \boldsymbol{x}) + b$$

支持向量回归 $$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\phi(\boldsymbol{x}) + b = \sum_{i=1}^{m} (\hat{\alpha}_i - \alpha_i) y_i \kappa(\boldsymbol{x}_i, \boldsymbol{x}) + b$$

结论：无论是支持向量机还是支持向量回归，学得的模型总可以表示成核函数的线性组合.

更一般的结论(表示定理)：对于任意单调增函数Ω和任意非负损失函数l，优化问题

$$\min_{h \in \mathbb{H}} \quad F(h) = \Omega(\|h\|_{\mathbb{H}}) + l(h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_m))$$

的解总可以写为 $$h^*(\boldsymbol{x}) = \sum_{i=1}^{m} \alpha_i \kappa(\boldsymbol{x}, \boldsymbol{x}_i)$$

核线性判别分析

- 通过表示定理可以得到很多线性模型的"核化"版本
  - 核SVM
  - 核LDA
  - 核PCA
  - ……
- 核LDA：先将样本映射到高维特征空间，然后在此特征空间中做线性判别分析

$$\max_{\boldsymbol{w}} J(\boldsymbol{w}) = \frac{\boldsymbol{w}^\top \boldsymbol{S}_b^{\boldsymbol{\phi}} \boldsymbol{w}}{\boldsymbol{w}^\top \boldsymbol{S}_w^{\boldsymbol{\phi}} \boldsymbol{w}}$$

$$h(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) = \sum_{i=1}^{m} \alpha_i \kappa(\boldsymbol{x}_i, \boldsymbol{x})$$

$$\max_{\boldsymbol{\alpha}} J(\boldsymbol{\alpha}) = \frac{\boldsymbol{\alpha}^\top \boldsymbol{M} \boldsymbol{\alpha}}{\boldsymbol{\alpha}^\top \boldsymbol{N} \boldsymbol{\alpha}}$$

Take Home Message

- 支持向量机的"最大间隔"思想
- 对偶问题及其解的稀疏性
- 通过向高维空间映射解决线性不可分的问题
- 引入"软间隔"缓解特征空间中线性不可分的问题
- 将支持向量的思想应用到回归问题上得到支持向量回归
- 将核方法推广到其他学习模型

成熟的SVM软件包

- LIBSVM
  http://www.csie.ntu.edu.tw/~cjlin/libsvm/
- LIBLINEAR
  http://www.csie.ntu.edu.tw/~cjlin/liblinear/
- SVM^{light}、SVM^{perf}、SVM^{struct}
  http://svmlight.joachims.org/svm_struct.html
- Pegasos
  http://www.cs.huji.ac.il/~shais/code/index.html

思考题

1. 以下说法错误的是：

A、支持向量机可以处理二分类问题

B、支持向量机既可以处理线性可分的问题，也可以处理非线性可分的问题

C、核函数本质是把两个数据从低维空间投影到高维的空间再进行内积

D、支持向量机是一种支持向量运算的机器

2. 用自己的话解释如何从公式（6.5）得到公式（6.8）以及（6.11）。

提示：在（6.8）到（6.11）的过程中，$\|w\|^2 = w^T w$

前往第七站……



致谢：南京大学周志华教授