第九章：聚类

大纲

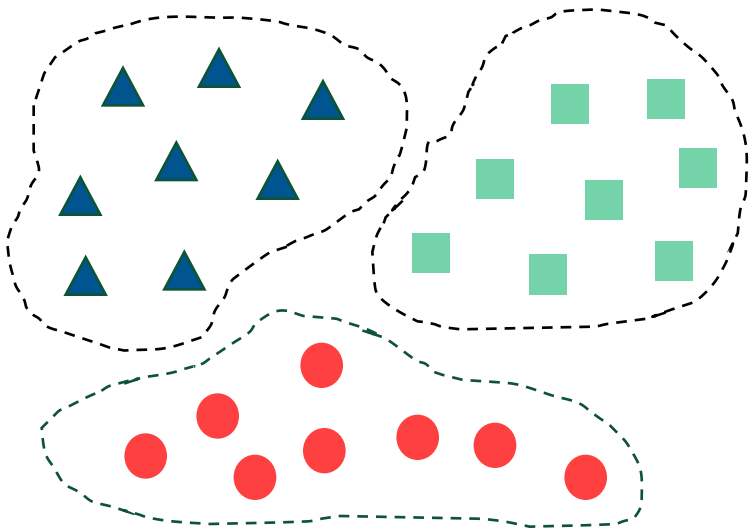
- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

聚类任务

- 在“无监督学习”任务中研究最多、应用最广.
- 聚类目标：将数据集中的样本划分为若干个通常不相交的子集（“簇”，cluster）.
- 聚类既可以作为一个单独过程（用于找寻数据内在的分布结构），也可作为分类等其他学习任务的前驱过程.



聚类任务

- 形式化描述

假定样本集 $D = \{x_1, x_2, \cdots, x_m\}$ 包含m个无标记样本,每个样本 $x_i = (x_{i1}; x_{i2}; \cdots; x_{in})$ 是一个n 维的特征向量，聚类算法将样本集 D 划分成 k 个不相交的簇$\{C_l | l = 1, 2, ..., k\}$ 。其中$C_{l'} \bigcap_{l' \neq l} C_l = \phi$，且 $D = \bigcup_{l=1}^{k} C_l$。

相应地，用$\lambda_j \in \{1, 2, \cdots, k\}$表示样本$x_j$的“簇标记”（即cluster label）,即 $x_j \in C_{\lambda_j}$。于是，聚类的结果可用包含 m 个元素的簇标记向量 $\lambda = \{\lambda_1; \lambda_2; \cdots; \lambda_m\}$ 表示。

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

性能度量

- 聚类性能度量，亦称为聚类“有效性指标”（validity index）
- 直观来讲：

我们希望“物以类聚”，即同一簇的样本尽可能彼此相似，不同簇的样本尽可能不同。换言之，聚类结果的“簇内相似度”（intra-cluster similarity）高，且“簇间相似度”（inter-cluster similarity）低，这样的聚类效果较好.

性能度量

- 聚类性能度量：
  - 外部指标 (external index)
    将聚类结果与某个“参考模型” (reference model)进行比较。
  - 内部指标 (internal index)
    直接考察聚类结果而不用任何参考模型。

性能度量

对数据集 $D=\{x_1,x_2,\ldots,x_m\}$，假定通过聚类得到的簇划分为 $C=\{C_1,C_2,\ldots,C_k\}$，参考模型给出的簇划分为 $C^*=\{C_1^*,C_2^*,\ldots,C_s^*\}$.相应地，令 λ 与 λ^* 分别表示与 C 和 C^* 对应的簇标记向量.

我们将样本两两配对考虑，定义

$$a=|SS|,SS=\{(x_i,x_j)|\lambda_i=\lambda_j,\lambda_i^*=\lambda_j^*,i<j\}$$
$$b=|SD|,SD=\{(x_i,x_j)|\lambda_i=\lambda_j,\lambda_i^*\neq\lambda_j^*,i<j\}$$
$$c=|DS|,DS=\{(x_i,x_j)|\lambda_i\neq\lambda_j,\lambda_i^*=\lambda_j^*,i<j\}$$
$$d=|DD|,DD=\{(x_i,x_j)|\lambda_i\neq\lambda_j,\lambda_i^*\neq\lambda_j^*,i<j\}$$

性能度量 - 外部指标

$$a = |SS|, SS = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$$
$$b = |SD|, SD = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$
$$c = |DS|, DS = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$$
$$d = |DD|, DD = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$

- Jaccard系数（Jaccard Coefficient, JC）

$$JC = \frac{a}{a+b+c}$$

- FM指数（Fowlkes and Mallows Index, FMI）

$$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$$

- Rand指数（Rand Index, RI）

$$RI = \frac{2(a+b)}{m(m-1)}$$

[0,1]区间内，越大越好.

性能度量 – 内部指标

$$\mathbf{B}=\begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mm} \end{pmatrix}$$

- 考虑聚类结果的簇划分 $\mathcal{C}=\{C_1, C_2, \ldots, C_k\}$, 定义

$$\mathrm{avg}(C)=\frac{2}{|C|(|C|-1)}\sum_{1\leqslant i<j\leqslant |C|}\mathrm{dist}(\boldsymbol{x}_i,\boldsymbol{x}_j)\ ,$$

$$\mathrm{diam}(C)=\max_{1\leqslant i<j\leqslant |C|}\mathrm{dist}(\boldsymbol{x}_i,\boldsymbol{x}_j)\ ,$$

$$d_{\min}(C_i,C_j)=\min_{\boldsymbol{x}_i\in C_i,\boldsymbol{x}_j\in C_j}\mathrm{dist}(\boldsymbol{x}_i,\boldsymbol{x}_j)\ ,$$

$$d_{\mathrm{cen}}(C_i,C_j)=\mathrm{dist}(\boldsymbol{\mu}_i,\boldsymbol{\mu}_j)\ ,$$

性能度量 – 内部指标

$$\mathrm{avg}(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leqslant i < j \leqslant |C|} \mathrm{dist}(\boldsymbol{x}_i, \boldsymbol{x}_j) ,$$

$$\mathrm{diam}(C) = \max_{1 \leqslant i < j \leqslant |C|} \mathrm{dist}(\boldsymbol{x}_i, \boldsymbol{x}_j) ,$$

$$d_{\min}(C_i, C_j) = \min_{\boldsymbol{x}_i \in C_i, \boldsymbol{x}_j \in C_j} \mathrm{dist}(\boldsymbol{x}_i, \boldsymbol{x}_j) ,$$

$$d_{\mathrm{cen}}(C_i, C_j) = \mathrm{dist}(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j) ,$$

- DB指数（Davies-Bouldin Index, DBI）

$$DBI = \frac{1}{k} \sum_{i=1}^{k} \max_{j \neq i} \left(\frac{avg(C_i) + avg(C_j)}{d_{cen}(\mu_i, \mu_j)} \right)$$

越小越好.

- Dunn指数（Dunn Index, DI）

$$DI = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left(\frac{d_{min}(C_i, C_j)}{\max_{1 \leq l \leq k} diam(C_l)} \right) \right\}$$

越大越好.

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

距离计算

- 距离度量的性质：

  非负性：$dist(x_i, x_j) \geq 0$

  同一性：$dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$

  对称性：$dist(x_i, x_j) = dist(x_j, x_i)$

  直递性：$dist(x_i, x_j) \leq dist(x_i, x_k) + dist(x_k, x_j)$

距离计算

- 距离度量的性质：

  非负性：$dist(x_i, x_j) \geq 0$

  同一性：$dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$

  对称性：$dist(x_i, x_j) = dist(x_j, x_i)$

  直递性：$dist(x_i, x_j) \leq dist(x_i, x_k) + dist(x_k, x_j)$

- 常用距离：

  闵可夫斯基距离（Minkowski distance）：

$$dist(x_i, x_j) = \left(\sum_{u=1}^{n} |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$

  p=2：欧氏距离（Euclidean distance）.

  p=1：曼哈顿距离（Manhattan distance）.

- 加权距离（样本中不同属性的重要性不同时）：

$$dist(x_i, x_j) = (\omega_1 \cdot |x_{i1} - x_{j1}|^p + \cdots + \omega_n \cdot |x_{in} - x_{jn}|^p)^{\frac{1}{p}}$$

$$\omega_i \geq 0, \sum_{i=1}^{n} \omega_i = 1$$

距离计算

- 属性介绍
  - 连续属性 (continuous attribute)
    在定义域上有无穷多个可能的取值
  - 离散属性 (categorical attribute)
    在定义域上是有限个可能的取值

距离计算

- 属性介绍
  - 连续属性 (continuous attribute)
    在定义域上有无穷多个可能的取值
  - 离散属性 (categorical attribute)
    在定义域上是有限个可能的取值
  - 有序属性 (ordinal attribute)
    例如定义域为{1,2,3}的离散属性，“1”与“2”比较接近、与“3”比较远，称为“有序属性”。
  - 无序属性 (non-ordinal attribute)
    例如定义域为{飞机，火车，轮船}这样的离散属性，不能直接在属性值上进行计算，称为“无序属性”。

无序属性的距离度量

- Value Difference Metric, VDM（处理无序属性）：

令 $m_{u,a}$ 表示属性 u 上取值为 a 的样本数，$m_{u,a,i}$ 表示在第 i 个样本簇中在属性 u 上取值为 a 的样本数，k 为样本数，则属性 u 上两个离散值 a 与 b 之间的VDM距离为

$$VDM_p(a,b) = \sum_{i=1}^{k} \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

混合属性的距离度量

- MinkovDMp（处理混合属性）：

$$MinkovDM_p(x_i, x_j) = \left(\sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^{n} VDM_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$$

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

原型聚类

- 原型聚类

  也称为“基于原型的聚类”（prototype-based clustering），此类算法假设聚类结构能通过一组原型刻画。

- 算法过程：

  通常情况下，算法先对原型进行初始化，再对原型进行迭代更新求解。

- 接下来，介绍几种著名的原型聚类算法

  k均值算法、学习向量量化算法、高斯混合聚类算法。

原型聚类 – k均值算法

给定数据集 $D = \{x_1, x_2, \cdots, x_m\}$， k均值算法针对聚类所得簇划分 $C = \{C_1, C_2, \cdots, C_k\}$ 最小化平方误差

$$E = \sum_{i=1}^{k} \sum_{x \in C_j} \|x - \mu_i\|_2^2$$

其中，μ_i 是簇 C_i 的均值向量。

E 值在一定程度上刻画了簇内样本围绕簇均值向量的紧密程度，E 值越小，则簇内样本相似度越高。

原型聚类 – k均值算法

给定数据集 $D = \{x_1, x_2, \cdots, x_m\}$， k均值算法针对聚类所得簇划分 $C = \{C_1, C_2, \cdots, C_k\}$ 最小化平方误差

$$E = \sum_{i=1}^{k} \sum_{x \in C_j} \|x - \mu_i\|_2^2$$

其中，μ_i 是簇 C_i 的均值向量。

E 值在一定程度上刻画了簇内样本围绕簇均值向量的紧密程度，E 值越小，则簇内样本相似度越高。

- 算法流程（迭代优化）：

  初始化每个簇的均值向量

  repeat

  1. （更新）簇划分；
  2. 计算每个簇的均值向量

  until 当前均值向量均未更新

原型聚类 – k均值算法

- 算法伪代码：

输入： 样本集$D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
聚类簇数k.

过程：

从D中随机选择k个样本作为初始均值向量$\{\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \ldots, \boldsymbol{\mu}_k\}$
repeat
  令$C_i = \emptyset \ (1 \leq i \leq k)$
  for $j = 1, \ldots, m$ **do**
    计算样本$\boldsymbol{x}_j$与各均值向量$\boldsymbol{\mu}_i \ (1 \leq i \leq k)$的距离：$d_{ji} = ||\boldsymbol{x}_j - \boldsymbol{\mu}_i||_2$;
    根据距离最近的均值向量确定$\boldsymbol{x}_j$的簇标记：$\lambda_j = \arg\min_{i \in \{1,2,\ldots,k\}} d_{ji}$;
    将样本$\boldsymbol{x}_j$划入相应的簇：$C_{\lambda_j} = C_{\lambda_j} \bigcup \{\boldsymbol{x}_j\}$;
  end for
  for $i = 1, \ldots, k$ **do**
    计算新均值向量：$\boldsymbol{\mu}'_i = \frac{1}{|C_i|} \sum_{\boldsymbol{x} \in C_i} \boldsymbol{x}$;
    if $\boldsymbol{\mu}'_i \neq \boldsymbol{\mu}_i$ **then**
      将当前均值向量$\boldsymbol{\mu}_i$更新为$\boldsymbol{\mu}'_i$
    else
      保持当前均值向量不变
    end if
  end for
until 当前均值向量均未更新
return 簇划分结果

输出： 簇划分$\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

原型聚类 – k均值算法

- 代码示例：

```
>>> from sklearn.cluster import Kmeans
>>> import numpy as np
>>> X = np.array([[1, 2], [1, 4], [1, 0], ... [10, 2], [10, 4], [10, 0]])
>>> kmeans = KMeans(n_clusters=2, random_state=0).fit(X)
>>> kmeans.labels_ array([1, 1, 1, 0, 0, 0], dtype=int32)
>>> kmeans.predict([[0, 0], [12, 3]]) array([1, 0], dtype=int32)
>>> kmeans.cluster_centers_ array([[10., 2.], [ 1., 2.]])
```

`predict(self, X, sample_weight=None)`

Predict the closest cluster each sample in X belongs to.

In the vector quantization literature, `cluster_centers_` is called the code book and each value returne of the closest code in the code book.

Parameters:	**X :** ***(array-like, sparse matrix) of shape (n_samples, n_features)*** New data to predict. **sample_weight :** ***array-like, shape (n_samples,), optional*** The weights for each observation in X. If None, all observations are assigned equa
Returns:	**labels :** ***array, shape [n_samples,]*** Index of the cluster each sample belongs to.

n_clusters : *int, default=8*

The number of clusters to form as well as the number of centroids to generate.

random_state : *int, RandomState instance, default=None*

Determines random number generation for centroid initialization. Use an int to make the randomness deterministic. See Glossary.

https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

原型聚类 – k均值算法

- k均值算法实例

接下来以表9-1的西瓜数据集4.0为例，来演示k均值算法的学习过程。将编号为i的样本称为x_i.

编号	密度	含糖率	编号	密度	含糖率	编号	密度	含糖率
1	0.697	0.460	11	0.245	0.057	21	0.748	0.232
2	0.774	0.376	12	0.343	0.099	22	0.714	0.346
3	0.634	0.264	13	0.639	0.161	23	0.483	0.312
4	0.608	0.318	14	0.657	0.198	24	0.478	0.437
5	0.556	0.215	15	0.360	0.370	25	0.525	0.369
6	0.403	0.237	16	0.593	0.042	26	0.751	0.489
7	0.481	0.149	17	0.719	0.103	27	0.532	0.472
8	0.437	0.211	18	0.359	0.188	28	0.473	0.376
9	0.666	0.091	19	0.339	0.241	29	0.725	0.445
10	0.243	0.267	20	0.282	0.257	30	0.446	0.459

原型聚类 – k均值算法

- k均值算法实例

假定聚类簇数k =3，算法开始时，随机选择3个样本 x_6, x_{12}, x_{27}作为初始均值向量，即$\mu_1 = (0.403; 0.237), \mu_2 = (0.343; 0.099), \mu_3 = (0.533; 0.472)$ 。

考察样本 $x_1 = (0.697; 0.460)$ ，它与当前均值向量 μ_1, μ_2, μ_3 的距离分别为0.369，0.506，0.166，因此x_1 将被划入簇C_3 中。类似的，对数据集中的所有样本考察一遍后，可得当前簇划分为

$$C_1 = \{x_5, x_6, x_7, x_8, x_9, x_{10}, x_{13}, x_{14}, x_{15}, x_{17}, x_{18}, x_{19}, x_{20}, x_{23}\}$$

$$C_2 = \{x_{11}, x_{12}, x_{16}\}$$

$$C_3 = \{x_1, x_2, x_3, x_4, x_{21}, x_{22}, x_{24}, x_{25}, x_{26}, x_{27}, x_{28}, x_{29}, x_{30}\}$$

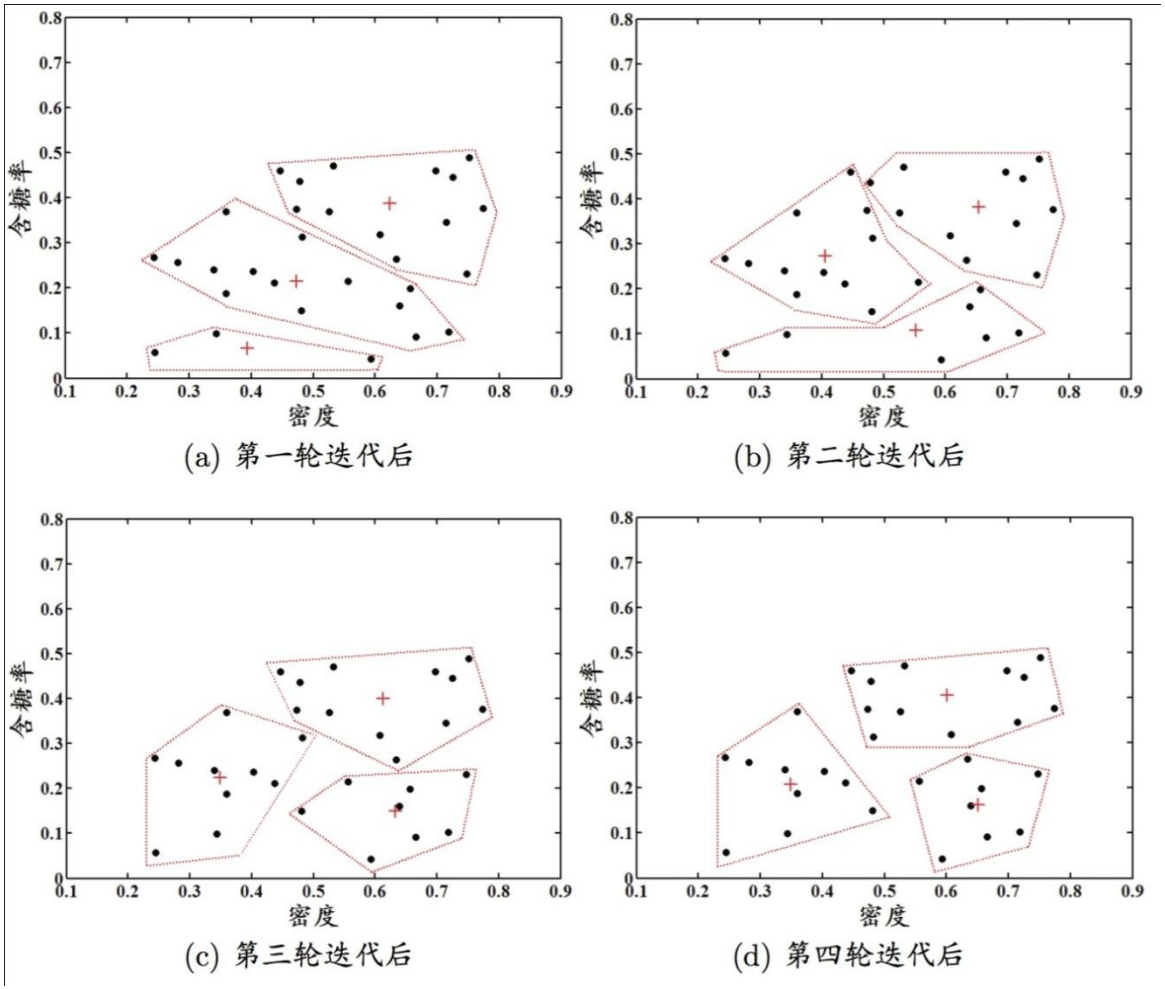
于是，可以从分别求得新的均值向量

$$\mu_1' = (0.473; 0.214), \mu_2' = (0.394; 0.066), \mu_3' = (0.623; 0.388)$$

不断重复上述过程，如下图所示。

原型聚类 – k均值算法

- 聚类结果：



原型聚类 – 高斯混合聚类

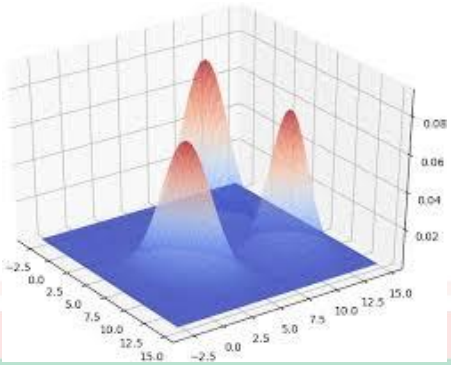
与k均值、LVQ用原型向量来刻画聚类结构不同，高斯混合聚类（Mixture-of-Gaussian）采用概率模型来表达聚类原型：

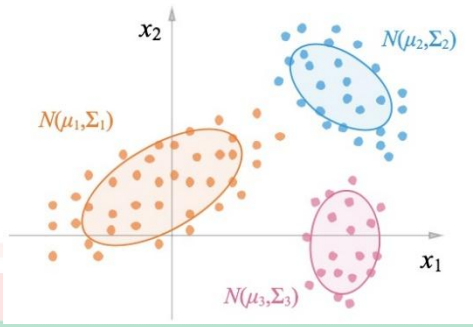
- 多元高斯分布的定义

对n维样本空间中的随机向量x，若x服从高斯分布，其概率密度函数为

$$p(x) = \frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$$

其中μ是n维均值向量，Σ是$n \times n$的协方差矩阵。也可将概率密度函数记作$p(x|\mu,\Sigma)$。





原型聚类 – 高斯混合聚类

- 高斯混合分布的定义

$$p_M(x) = \sum_{i=1}^{k} \alpha_i p(x|\mu_i, \Sigma_i)$$

该分布由 k 个混合分布组成，每个分布对应一个高斯分布。其中，μ_i 与 Σ_i 是第 i 个高斯混合成分的参数。而 $\alpha_i > 0$ 为相应的“混合系数”，$\sum_{i=1}^{k} \alpha_i = 1$

i

原型聚类 – 高斯混合聚类

- 假设样本的生成过程由高斯混合分布给出：

首先，根据 $\alpha_1, \alpha_2, \cdots, \alpha_k$ 定义的先验分布选择高斯混合成分，其中 α_i 为选择第 i 个混合成分的概率；

然后，根据被选择的混合成分的概率密度函数进行采样，从而生成相应的样本。

原型聚类 – 高斯混合聚类

- 模型求解：最大化（对数）似然

$$LL(D) = \ln\left(\prod_{j=1}^{m} p_M(x_j)\right)$$

$$= \sum_{j=1}^{m} \ln\left(\sum_{i=1}^{k} \alpha_i \cdot p\left(x_j|\mu_i, \Sigma_i\right)\right)$$

令：

$$\frac{\partial LL(D)}{\partial \mu_i} = 0 \quad \longrightarrow \quad \mu_i = \frac{\sum_{j=1}^{m} \gamma_{ji} x_j}{\sum_{j=1}^{m} \gamma_{ji}}$$

高斯混合聚类 – 模型求解（续）

令：

$$\frac{\partial LL(D)}{\partial \Sigma_i} = 0 \quad \Longrightarrow \quad \Sigma_i = \frac{\sum_{j=1}^{m} \gamma_{ji}(x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^{m} \gamma_{ji}}$$

矩阵微分公式 $\frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = |\mathbf{X}| \cdot (\mathbf{X}^{-1})^T, \frac{\partial \boldsymbol{a}^T \mathbf{X}^{-1} \boldsymbol{b}}{\partial \mathbf{X}} = -\mathbf{X}^{-T} \boldsymbol{a} \boldsymbol{b}^T \mathbf{X}^{-T}$

https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf

高斯混合聚类

- 算法伪代码：

输入： 样本集$D=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\ldots,\boldsymbol{x}_m\}$;
高斯混合成分个数k.

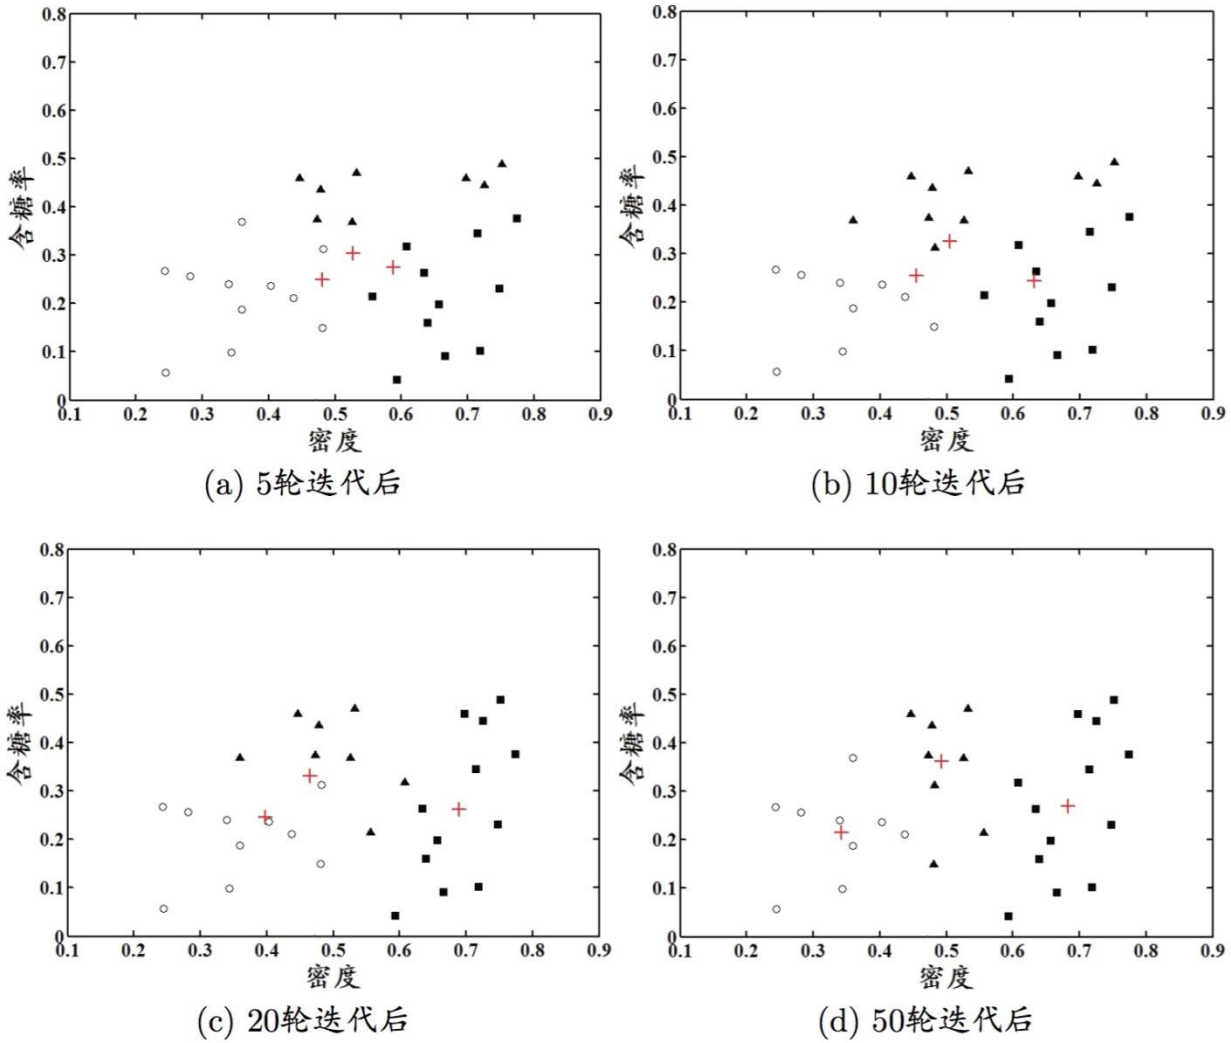
过程：

初始化高斯混合分布的模型参数$\{(\alpha_i,\boldsymbol{\mu}_i,\boldsymbol{\Sigma}_i)\mid 1\leq i\leq k\}$
repeat
  for $j=1,\ldots,m$ **do**
    根据(9.30)计算$\boldsymbol{x}_j$由各混合成分生成的后验概率, 即
    $\gamma_{ji}=p_{\mathcal{M}}(z_j=i\mid \boldsymbol{x}_j)\ (1\leq i\leq k)$
  end for
  for $i=1,\ldots,k$ **do**
    计算新均值向量：$\boldsymbol{\mu}_i'=\frac{\sum_{j=1}^{m}\gamma_{ji}\boldsymbol{x}_j}{\sum_{j=1}^{m}\gamma_{ji}}$;
    计算新协方差矩阵：$\boldsymbol{\Sigma}_i'=\frac{\sum_{j=1}^{m}\gamma_{ji}(\boldsymbol{x}_j-\boldsymbol{\mu}_i')(\boldsymbol{x}_j-\boldsymbol{\mu}_i')^{\top}}{\sum_{j=1}^{m}\gamma_{ji}}$;
    计算新混合系数：$\alpha_i'=\frac{\sum_{j=1}^{m}\gamma_{ji}}{m}$;
  end for
  将模型参数$\{(\alpha_i,\boldsymbol{\mu}_i,\boldsymbol{\Sigma}_i)\mid 1\leq i\leq k\}$更新为$\{(\alpha_i',\boldsymbol{\mu}_i',\boldsymbol{\Sigma}_i')\mid 1\leq i\leq k\}$
until 满足停止条件
$C_i=\emptyset\ (1\leq i\leq k)$
for $j=1,\ldots,m$ **do**
  根据(9.31)确定$\boldsymbol{x}_j$的簇标记λ_j;
  将$\boldsymbol{x}_j$划入相应的簇：$C_{\lambda_j}=C_{\lambda_j}\bigcup\{\boldsymbol{x}_j\}$
end for
return 簇划分结果

输出： 簇划分$\mathcal{C}=\{C_1,C_2,\ldots,C_k\}$

高斯混合聚类

- 聚类效果：



(a) 5轮迭代后　(b) 10轮迭代后

(c) 20轮迭代后　(d) 50轮迭代后

原型聚类 – 学习向量量化

- 学习向量量化（Learning Vector Quantization, LVQ）

与一般聚类算法不同的是，LVQ假设数据样本带有类别标记，学习过程中利用样本的这些监督信息来辅助聚类.

给定样本集 $D=\{(x_1,y_1),(x_2,y_2),\cdots,(x_m,y_m)\}$，LVQ的目标是学得一组$n$维原型向量$\{p_1,p_2,\cdots,p_q\}$，每个原型向量代表一个聚类簇。

t_i为第i个数据的簇标记。

原型聚类 – 学习向量量化

- 算法伪代码：

输入： 样本集$D = \{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_m, y_m)\}$;
原型向量个数q, 各原型向量预设的类别标记$\{t_1, t_2, \ldots, t_q\}$;
学习率$\eta \in (0, 1)$.

过程：

初始化一组原型向量$\{\boldsymbol{p}_1, \boldsymbol{p}_2, \ldots, \boldsymbol{p}_q\}$
repeat
  从样本集D随机选取样本$(\boldsymbol{x}_j, y_j)$;
  计算样本$\boldsymbol{x}_j$与$\boldsymbol{p}_i$ $(1 \leq i \leq q)$的距离：$d_{ji} = ||\boldsymbol{x}_j - \boldsymbol{p}_i||_2$;
  找出与$\boldsymbol{x}_j$距离最近的原型向量; $i^* = \arg\min_{i \in \{1,2,\ldots,q\}} d_{ji}$;
  if $y_j = t_{i^*}$ **then**
    $\boldsymbol{p}' = \boldsymbol{p}_{i^*} + \eta \cdot (\boldsymbol{x}_j - \boldsymbol{p}_{i^*})$
  else
    $\boldsymbol{p}' = \boldsymbol{p}_{i^*} - \eta \cdot (\boldsymbol{x}_j - \boldsymbol{p}_{i^*})$
  end if
  将原型向量$\boldsymbol{p}_{i^*}$更新为$\boldsymbol{p}'$
until 满足停止条件
return 当前原型向量

输出： 原型向量$\{\boldsymbol{p}_1, \boldsymbol{p}_2, \ldots, \boldsymbol{p}_q\}$

原型聚类 – 学习向量量化

- 聚类效果：

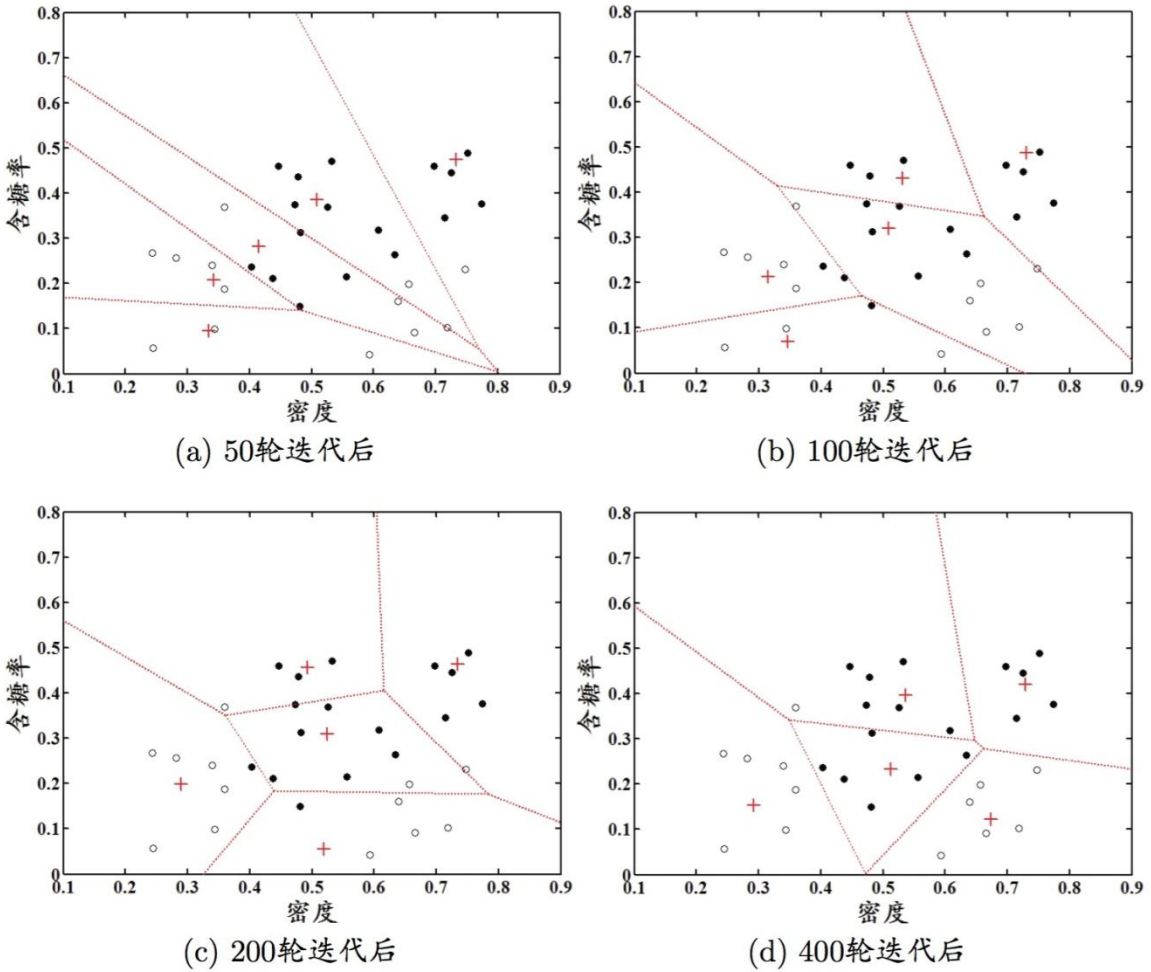


图 9.5 西瓜数据集 4.0 上 LVQ 算法($q = 5$)在不同轮数迭代后的聚类结果. c_1, c_2 类样本点与原型向量分别用"•", "○"与"+"表示, 红色虚线显示出聚类形成的 Voronoi 剖分.

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

密度聚类

- 密度聚类的定义

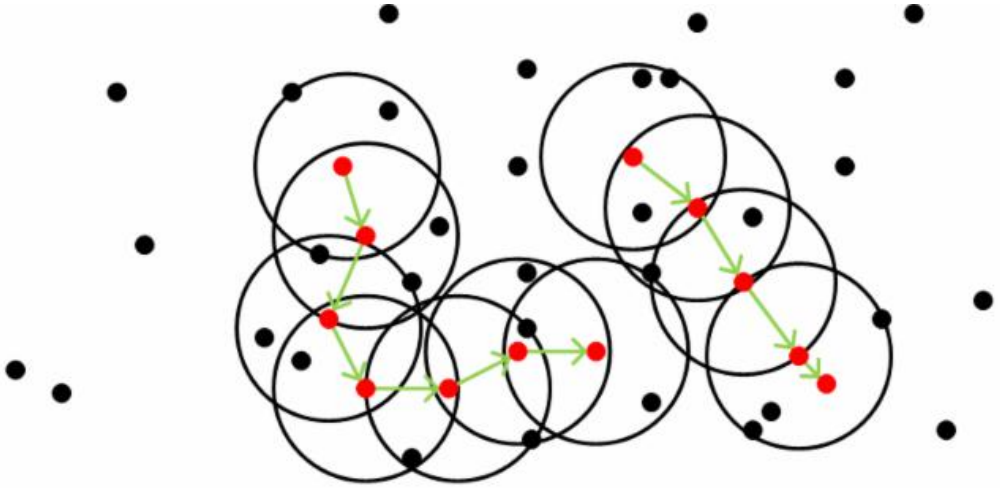
密度聚类也称为“基于密度的聚类” (density-based clustering)。

此类算法假设聚类结构能通过样本分布的紧密程度来确定。

通常情况下，密度聚类算法从样本密度的角度来考察样本之间的可连接性，并基于可连接样本不断扩展聚类簇来获得最终的聚类结果。

接下来介绍DBSCAN这一密度聚类算法。

密度聚类



- DBSCAN算法：基于一组“邻域”参数 $(\epsilon, MinPts)$ 来刻画样本分布的紧密程度。
- 基本概念：
  - ϵ 邻域：对样本 $x_j \in D$，其 ϵ 邻域包含样本集 D 中与 x_j 的距离不大于 ϵ 的样本；
  - 核心对象：若样本 x_j 的 ϵ 邻域至少包含MinPts个样本，则该样本点为一个核心对象；
  - 密度直达：若样本 x_j 位于样本 x_i 的 ϵ 邻域中，且 x_i 是一个核心对象，则称样本 x_j 由 x_i 密度直达；
  - 密度可达：对样本 x_i 与 x_j，若存在样本序列 $p_1, p_2, \cdots, p_n$，其中 $p_1 = x_i, p_n = x_j$ 且 p_{i+1} 由 p_i 密度直达，则该两样本密度可达；
  - 密度相连：对样本 x_i 与 x_j，若存在样本 x_k 使得两样本均由 x_k 密度可达，则称该两样本密度相连。

密度聚类

- 一个例子

  令$MinPts = 3$，则

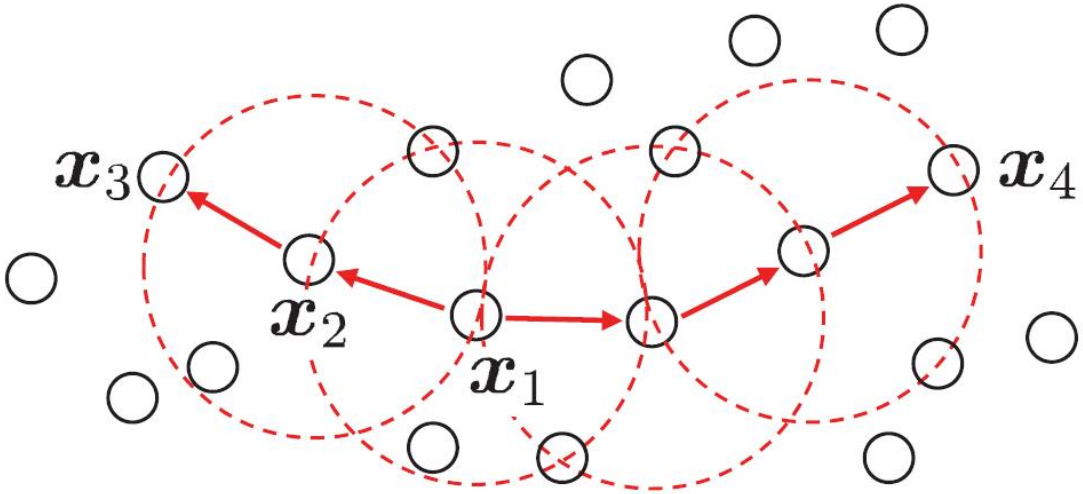
  虚线显示出ϵ领域。

  x_1是核心对象。

  x_2由x_1密度直达。

  x_3由x_1密度可达。

  x_3与x_4密度相连。



密度聚类

- 对“簇”的定义

  由密度可达关系导出的最大密度相连样本集合。

- 对“簇”的形式化描述

  给定领域参数，簇是满足以下性质的非空样本子集：

  连接性：$x_i \in C, x_j \in C \Rightarrow x_i$ 与 x_j 密度相连

  最大性：$x_i \in C$，x_i 与 x_j 密度可达 $\Rightarrow x_j \in C$

实际上，若x为核心对象，由x密度可达的所有样本组成的集合记为$X = \{x' \in D \mid x'$由x密度可达$\}$，则X为满足连接性与最大性的簇。

密度聚类

- DBSCAN算法伪代码：

输入： 样本集$D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
邻域参数$(\epsilon, MinPts)$.

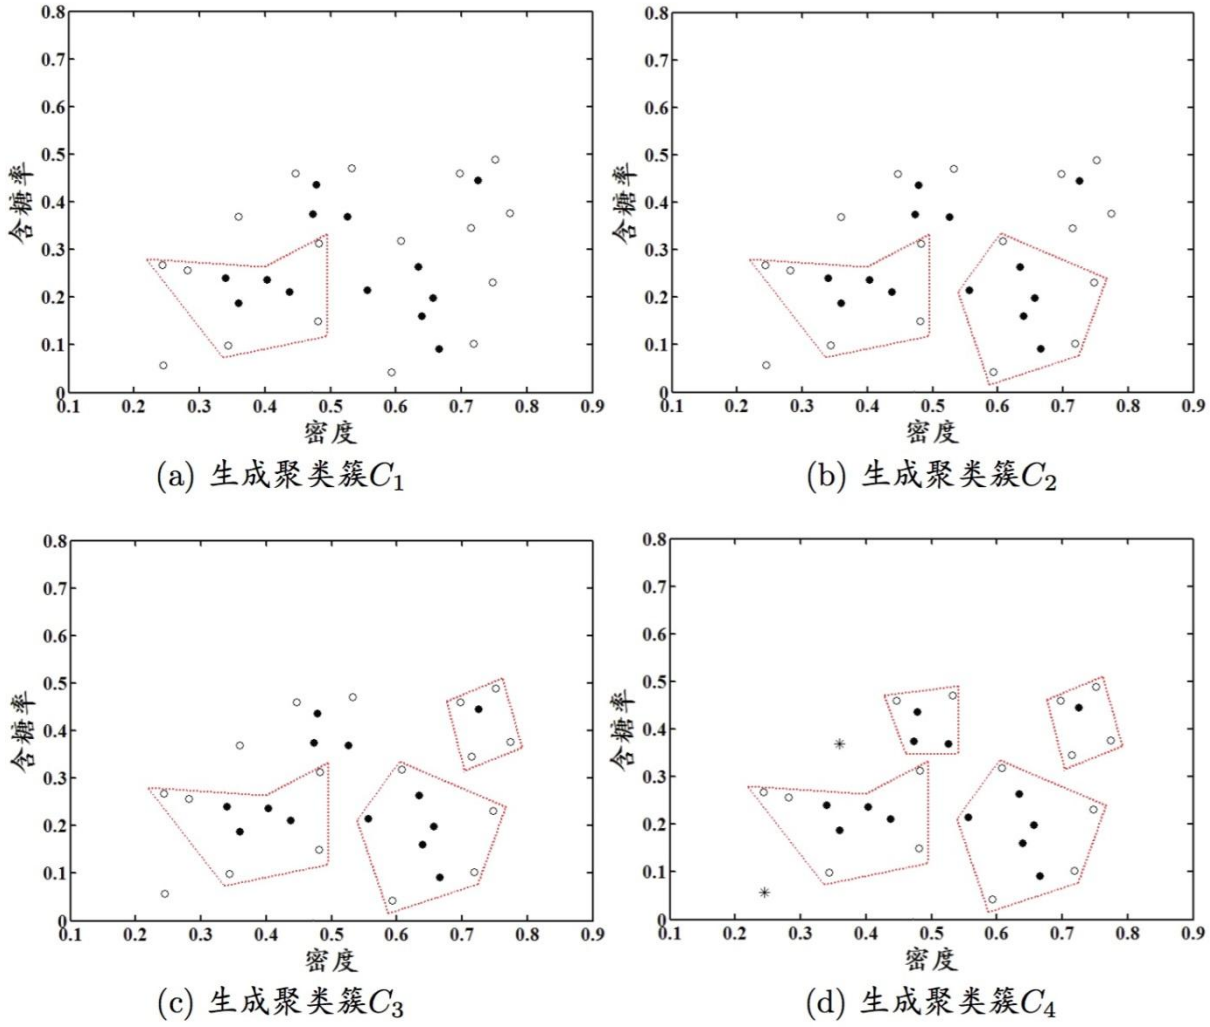
过程：

初始化核心对象集合：$\Omega = \emptyset$
for $j = 1, \ldots, m$ **do**
  确定样本$\boldsymbol{x}_j$的ϵ-邻域$N_\epsilon(\boldsymbol{x}_j)$;
  if $|N_\epsilon(\boldsymbol{x}_j)| \geq MinPts$ **then**
    将样本$\boldsymbol{x}_j$加入核心对象集合：$\Omega = \Omega \bigcup \{\boldsymbol{x}_j\}$
  end if
end for
初始化聚类簇数：$k = 0$
初始化未访问样本集合：$\Gamma = D$
while $\Omega \neq \emptyset$ **do**
  记录当前未访问样本集合：$\Gamma_{\text{old}} = \Gamma$;
  随机选取一个核心对象$\boldsymbol{o} \in \Omega$, 初始化队列 $Q =< \boldsymbol{o} >$;
  $\Gamma = \Gamma \setminus \{\boldsymbol{o}\}$;
  while $Q \neq \emptyset$ **do**
    取出队列Q中的首个样本$\boldsymbol{q}$;
    if $|N_\epsilon(\boldsymbol{q})| \geq MinPts$ **then**
      令$\Delta = N_\epsilon(\boldsymbol{q}) \bigcap \Gamma$;
      将Δ中的样本加入队列Q;
      $\Gamma = \Gamma \setminus \Delta$;
    end if
  end while
  $k = k + 1$, 生成聚类簇$C_k = \Gamma_{\text{old}} \setminus \Gamma$;
  $\Omega = \Omega \setminus C_k$
end while
return 簇划分结果

输出： 簇划分$\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

密度聚类

- 聚类效果：



(a) 生成聚类簇C_1　(b) 生成聚类簇C_2

(c) 生成聚类簇C_3　(d) 生成聚类簇C_4

大纲

- 聚类任务
- 性能度量
- 距离计算
- 原型聚类
- 密度聚类
- 层次聚类

层次聚类

- 层次聚类试图在不同层次对数据集进行划分，从而形成树形的聚类结构。数据集划分既可采用“自底向上”的聚合策略，也可采用“自顶向下”的分拆策略。
- AGNES算法（自底向上的层次聚类算法）

首先，将样本中的每一个样本看做一个初始聚类簇，然后在算法运行的每一步中找出距离最近的两个聚类簇进行合并，该过程不断重复，直到达到预设的聚类簇的个数。

这里两个聚类簇 C_i 和 C_j 的距离，可以有3种度量方式。

层次聚类

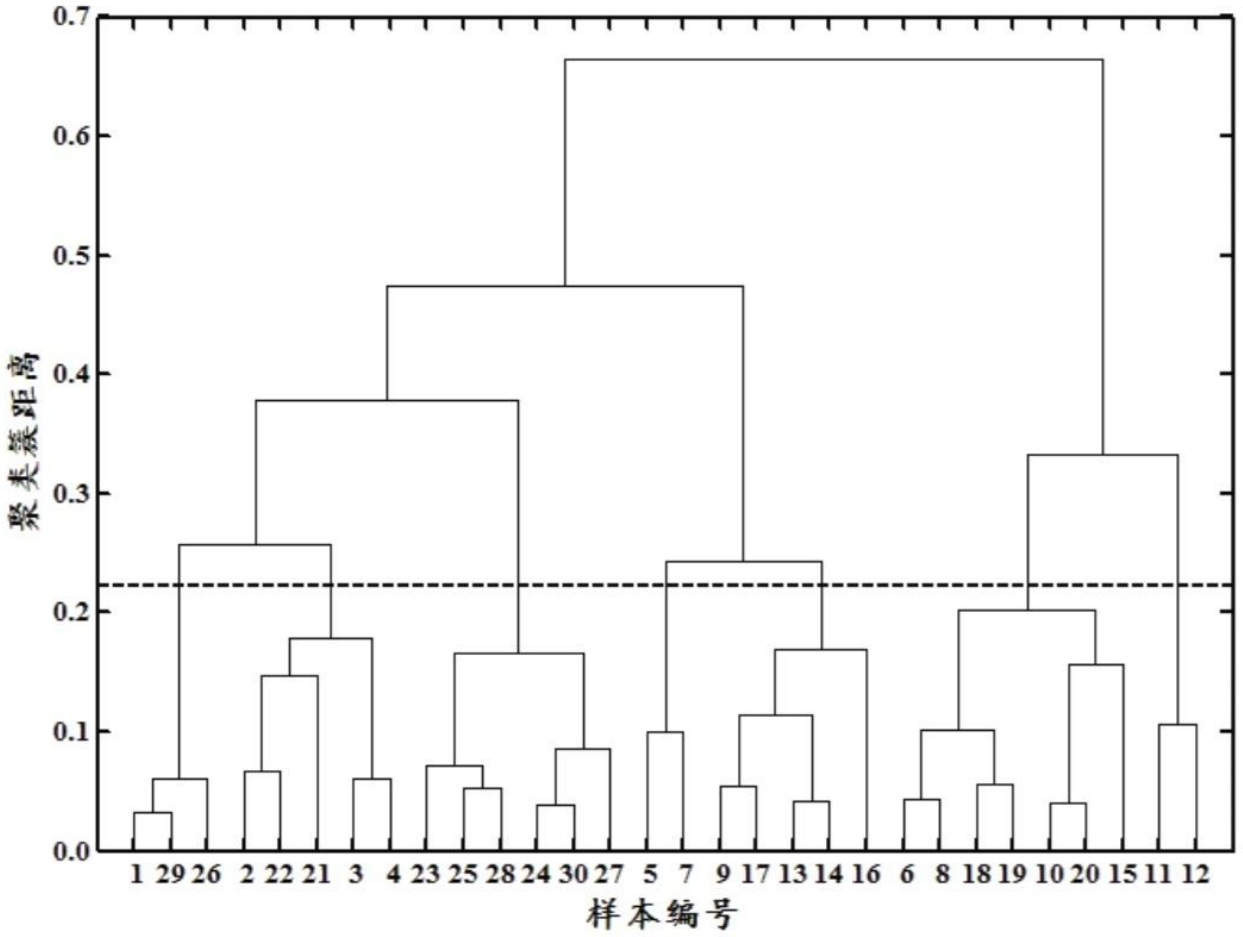
最小距离：
$$d_{min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} dist(x, z)$$

最大距离：
$$d_{max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} dist(x, z)$$

平均距离：
$$d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} dist(x, z)$$

层次聚类 – 树状图

- AGNES算法树状图：



层次聚类 – AGNES算法

- AGNES算法伪代码：

输入： 样本集$D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
聚类簇距离度量函数$d \in \{d_{\min}, d_{\max}, d_{\text{avg}}\}$;
聚类簇数k.

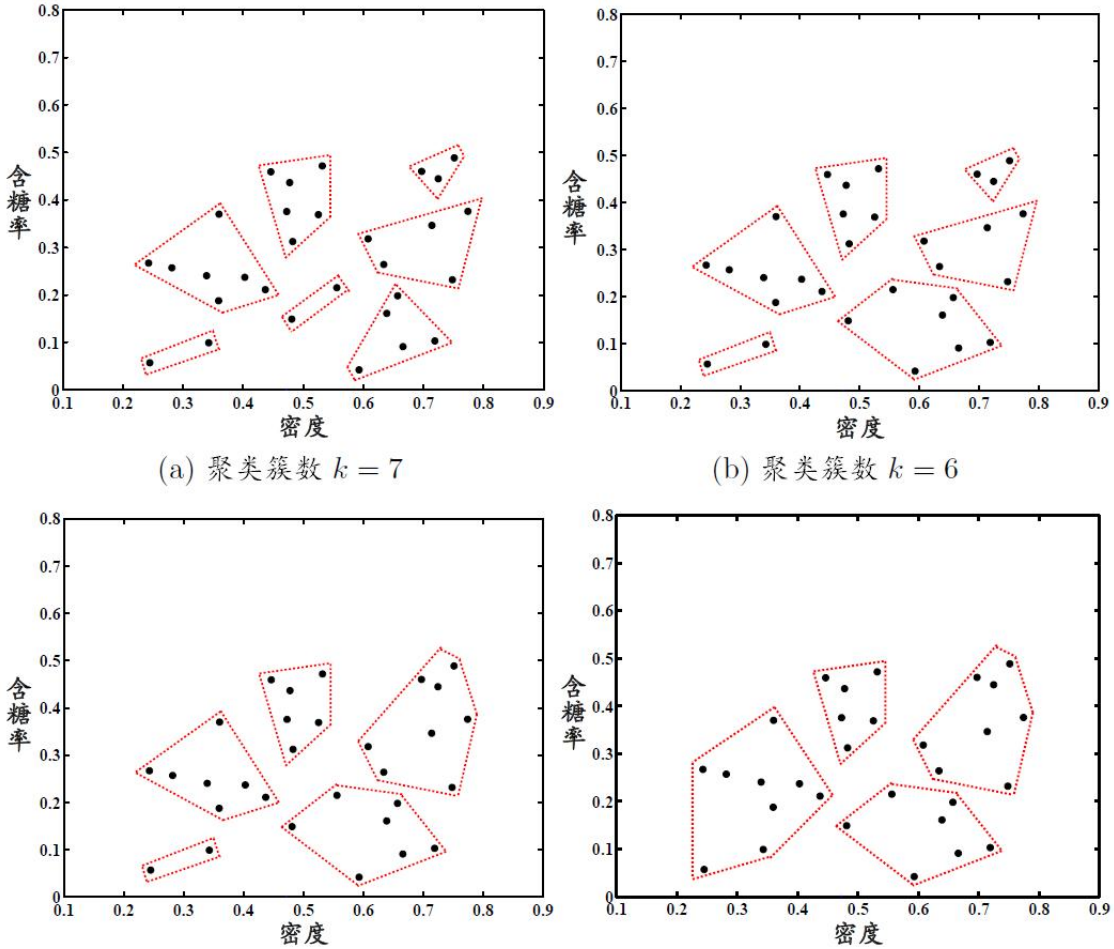
过程：

```
for j = 1,...,m do
    C_j = {x_j}
end for
for i = 1,...,m do
    for j = i,...,m do
        M(i,j) = d(C_i, C_j);
        M(j,i) = M(i,j)
    end for
end for
设置当前聚类簇个数：q = m
while q > k do
    找出距离最近的两个聚类簇(C_{i*}, C_{j*});
    合并(C_{i*}, C_{j*})：C_{i*} = C_{i*} ⋃ C_{j*};
    for j = j* + 1,...,q do
        将聚类簇C_j重编号为C_{j-1}
    end for
    删除距离矩阵M的第j*行与第j*列;
    for j = 1,...,q - 1 do
        M(i*,j) = d(C_{i*}, C_j);
        M(j, i*) = M(i*,j)
    end for
    q = q - 1
end while
return 簇划分结果
```

输出： 簇划分$\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

层次聚类

- AGNES算法聚类效果：



(a) 聚类簇数 $k = 7$　　(b) 聚类簇数 $k = 6$

(c) 聚类簇数 $k = 5$　　(d) 聚类簇数 $k = 4$

思考题

1. 以下说法错误的是

A、K均值算法计算时会不断更新簇的均值。

B、高斯混合聚类假设每一簇数据服从高斯分布。

C、基于密度的聚类方法结果会出现不属于任何簇的数据。

D、聚类是一种有监督算法。

2. 层次聚类的计算顺序是_____，_____，_____，重新计算簇间距离，……（循环至收敛）
（填入：计算簇间的距离，以每个样本为一个簇，合并距离相近的簇，计算簇内的距离）

3. 可否将K均值聚类算法看作是高斯混合聚类算法的一种特殊情况（例如，若高斯混合算法第4行中的只能取0或1，以及增加其他约束条件，可否使后者等价于前者）？用自己的话描述理由。

思考题

输入: 样本集 $D=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\ldots,\boldsymbol{x}_m\}$;
聚类簇数 k.

过程:

从 D 中随机选择 k 个样本作为初始均值向量 $\{\boldsymbol{\mu}_1,\boldsymbol{\mu}_2,\ldots,\boldsymbol{\mu}_k\}$
repeat
  令 $C_i=\varnothing\ (1\leqslant i\leqslant k)$
  for $j=1,2,\ldots,m$ **do**
    计算样本 $\boldsymbol{x}_j$ 与各均值向量 $\boldsymbol{\mu}_i\ (1\leqslant i\leqslant k)$ 的距离: $d_{ji}=\|\boldsymbol{x}_j-\boldsymbol{\mu}_i\|_2$;
    根据距离最近的均值向量确定 $\boldsymbol{x}_j$ 的簇标记: $\lambda_j=\arg\min_{i\in\{1,2,\ldots,k\}} d_{ji}$;
    将样本 $\boldsymbol{x}_j$ 划入相应的簇: $C_{\lambda_j}=C_{\lambda_j}\bigcup\{\boldsymbol{x}_j\}$;
  end for
  for $i=1,2,\ldots,k$ **do**
    计算新均值向量: $\boldsymbol{\mu}_i'=\frac{1}{|C_i|}\sum_{\boldsymbol{x}\in C_i}\boldsymbol{x}$;
    if $\boldsymbol{\mu}_i'\neq\boldsymbol{\mu}_i$ **then**
      将当前均值向量 $\boldsymbol{\mu}_i$ 更新为 $\boldsymbol{\mu}_i'$
    else
      保持当前均值向量不变
    end if
  end for
until 当前均值向量均未更新

输出: 簇划分 $\mathcal{C}=\{C_1,C_2,\ldots,C_k\}$

图 9.2 k 均值算法

EM 算法的 E步.

EM 算法的 M步.

例如达到最大迭代轮数.

输入: 样本集 $D=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\ldots,\boldsymbol{x}_m\}$;
高斯混合成分个数 k.

过程:

初始化高斯混合分布的模型参数 $\{(\alpha_i,\boldsymbol{\mu}_i,\boldsymbol{\Sigma}_i)\mid 1\leqslant i\leqslant k\}$
repeat
  for $j=1,2,\ldots,m$ **do**
    根据式(9.30)计算 $\boldsymbol{x}_j$ 由各混合成分生成的后验概率, 即
    $\gamma_{ji}=p_{\mathcal{M}}(z_j=i\mid\boldsymbol{x}_j)\ (1\leqslant i\leqslant k)$
  end for
  for $i=1,2,\ldots,k$ **do**
    计算新均值向量: $\boldsymbol{\mu}_i'=\frac{\sum_{j=1}^m\gamma_{ji}\boldsymbol{x}_j}{\sum_{j=1}^m\gamma_{ji}}$;
    计算新协方差矩阵: $\boldsymbol{\Sigma}_i'=\frac{\sum_{j=1}^m\gamma_{ji}(\boldsymbol{x}_j-\boldsymbol{\mu}_i')(\boldsymbol{x}_j-\boldsymbol{\mu}_i')^{\mathrm{T}}}{\sum_{j=1}^m\gamma_{ji}}$;
    计算新混合系数: $\alpha_i'=\frac{\sum_{j=1}^m\gamma_{ji}}{m}$;
  end for
  将模型参数 $\{(\alpha_i,\boldsymbol{\mu}_i,\boldsymbol{\Sigma}_i)\mid 1\leqslant i\leqslant k\}$ 更新为 $\{(\alpha_i',\boldsymbol{\mu}_i',\boldsymbol{\Sigma}_i')\mid 1\leqslant i\leqslant k\}$
until 满足停止条件
$C_i=\varnothing\ (1\leqslant i\leqslant k)$
for $j=1,2,\ldots,m$ **do**
  根据式(9.31)确定 $\boldsymbol{x}_j$ 的簇标记 λ_j;
  将 $\boldsymbol{x}_j$ 划入相应的簇: $C_{\lambda_j}=C_{\lambda_j}\bigcup\{\boldsymbol{x}_j\}$
end for

输出: 簇划分 $\mathcal{C}=\{C_1,C_2,\ldots,C_k\}$

图 9.6 高斯混合聚类算法

前往第十站 ……



致谢：南京大学周志华教授及其课件制作团队