实验五 SVM 支持向量机实验指导书

姓名　顾凯琪

学号　226001624

学院 信息学院

专业班级 计算机 2 班

一、 实验目的

1. 学习掌握支持向量机的基本实现原理，包括其最大间隔思想，并掌握使用拉格朗日乘子法求解 SVM 的优化问题的基本方法与推导过程；
2. 学习掌握软间隔、正则化等方法的概念与使用场景；
3. 学习了解使用核技巧来解决线性不可分的分类问题，了解几种常见的核函数；
4. 熟悉一个分类任务的基本流程，即数据获取、数据探索、数据清洗、特征选择、模型训练、模型评估等基本步骤；
5. 用 SVM 进行乳腺癌检测,要求掌握分类任务的从头到尾的流程。

二、 实验环境

操作系统：

Windows 11

集成开发环境：

1. Anaconda3
2. PyCharm 2022.2.2

相关 Python 库：

1. python3.9
2. numpy
3. matplotlib
4. sklearn

三、 实验内容

1. 基于 sklearn 框架利用 SVM 支持向量机进行乳腺癌检测任务；
2. 熟悉一个分类任务的基本流程，即数据获取—>数据探索—>数据清洗—> 特征选择—>模型训练—>模型评估；
3. 熟悉 SVM 类中核函数使用方式及相关参数；

四、 实验步骤：

1. 数据集加载

实验所用数据由实验指导文件给出，为一个 csv 文件，使用 pandas 进行数据的导入与基本处理。

2. 数据探索与分析

对于所用数据，进行数据的适当处理与分析，例如去除无用特征，分析数据特征的组成，诊断结果的分布状况，特征相关性等，并进行绘图分析。

3. 特征选择

基于数据的分析结果筛选所选用的特征，并说明选择依据，同时分析可能的备选特征选择方案。

4. 使用 SVM 模型进行训练

对处理好的数据集进行训练集、测试集划分，并使用 sklearn 库中的 SVM 模型实例在训练集上进行训练，随后在测试集上进行验证，给出模型的分类准确率。

5. 适当调整模型参数

适当对 SVM 的参数进行调整，例如所用的核函数、惩罚因子的调整，也可以使用其它的特征选择方案，并重复对模型的训练与评估，使模型具有更好的准确率。(Baseline 为 0.921052)

五、 代码提交

```
"""
-------导入涉及到的头文件与库函数-----
"""
```

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn import svm
from sklearn.preprocessing import StandardScaler
from sklearn import metrics
pd.set_option('display.max_columns',None)
```

```
"""
-------导入数据并打印属性信息-----
"""
```

```
data = pd.read_csv('./data.csv')
print(data.columns)
print(data.describe())
```

```
"""
-------特征的分类----
"""
```

```
feature_mean = list(data.columns[2:12])
feature_se = list(data.columns[12:22])
feature_worst = list(data.columns[22:32])
feature_mean,feature_se,feature_worst
```

```
"""
-------数据的清洗处理和绘图---
"""
```

```
data.drop('id', axis=1, inplace=True)
data['diagnosis']=data['diagnosis'].map({'M':1,'B':0})
sns.countplot(data['diagnosis'],label='count')
plt.show()
```

```
"""
-------相关矩阵的绘制----
"""
```

```
corr = data[feature_mean].corr()
# corr = data[feature_se].corr()
# corr = data[feature_worst].corr() # 每类特征都进行绘图分析
plt.figure(figsize=(14,14))
sns.heatmap(corr, annot=True)
plt.show()
```

```
"""
-------特征选择与数据集划分----
"""
```

```
feature_remain = ['radius_mean','texture_mean','smoothness_mean','comp
actness_mean','symmetry_mean','fractal_dimension_mean']
train, test = train_test_split(data, test_size=0.2)
```

```
"""
-------处理样本特征和标签----
"""
```

```
train_X = train[feature_remain]
train_y = train['diagnosis']
test_X = test[feature_remain]
test_y = test['diagnosis']
```

```
"""
-------数据归一化---
"""
```

```
print(train_X['radius_mean'].std(), train_X['radius_mean'].mean())
ss = StandardScaler()
train_X = ss.fit_transform(train_X)
test_X = ss.fit_transform(test_X)
print(train_X[:,0].std(), train_X[:,0].mean())
```

```
"""
-------基于 sklearn 的 SVM 模型定义与训练----
"""
```

```
model = svm.SVC(kernel='rbf',C=1,degree=3)
model.fit(train_X,train_y)
```

```
"""
-------模型的评估---
"""
```

```
prediction = model.predict(test_X)
print('acc:',metrics.accuracy_score(prediction,test_y))
```

六、 实验结果与分析（必填）

1. 数据的导入与分析

导入数据，查看属性名称，如图 1 所示。可以看到共有 32 个属性，其中 id 为样本编号，diagnosis 为诊断结果，剩下三十个为属性为样本的具体的特征，并每十个为一组，分别代表特征的均值、最大值和标准差。实际上共有 10 类特

征值：radius、texture、perimeter、area、smoothness、compactness、concavity、concave points、symmetry、fractal_dimension_mean。

其中 id 属性对分类器的训练并没有帮助，可以将其舍去，对于诊断结果 diagnosis，初始值为 M 或者 B，需要转换为 1/0 以供模型的训练。

```
Index(['id', 'diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean',
       'area_mean', 'smoothness_mean', 'compactness_mean', 'concavity_mean',
       'concave points_mean', 'symmetry_mean', 'fractal_dimension_mean',
       'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se',
       'compactness_se', 'concavity_se', 'concave points_se', 'symmetry_se',
       'fractal_dimension_se', 'radius_worst', 'texture_worst',
       'perimeter_worst', 'area_worst', 'smoothness_worst',
       'compactness_worst', 'concavity_worst', 'concave points_worst',
       'symmetry_worst', 'fractal_dimension_worst'],
      dtype='object')
```

图 1. 数据的属性名称输出

绘制标签（即诊断结果）的分布图，如图 2 所示。可以看到，正例约为 200 例，反例约为 350 例，整体不存在正反例分布不均匀的情况。

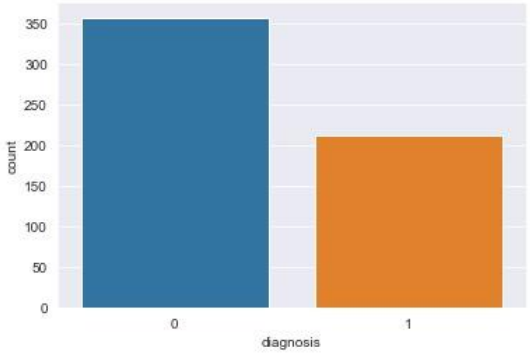


图 2. 诊断结果的分布情况

2. 特征的筛选

由于原始的数据特征数量较大，直接使用全部的特征会导致模型的训练难度加大，同时可能会导致模型的过拟合，因此需要进行数据特征的筛选。考虑每个特征之间的相关性，使用热力图进行呈现，如图 3 所示，优先考虑选择特征的均值信息，相对更具有代表性。

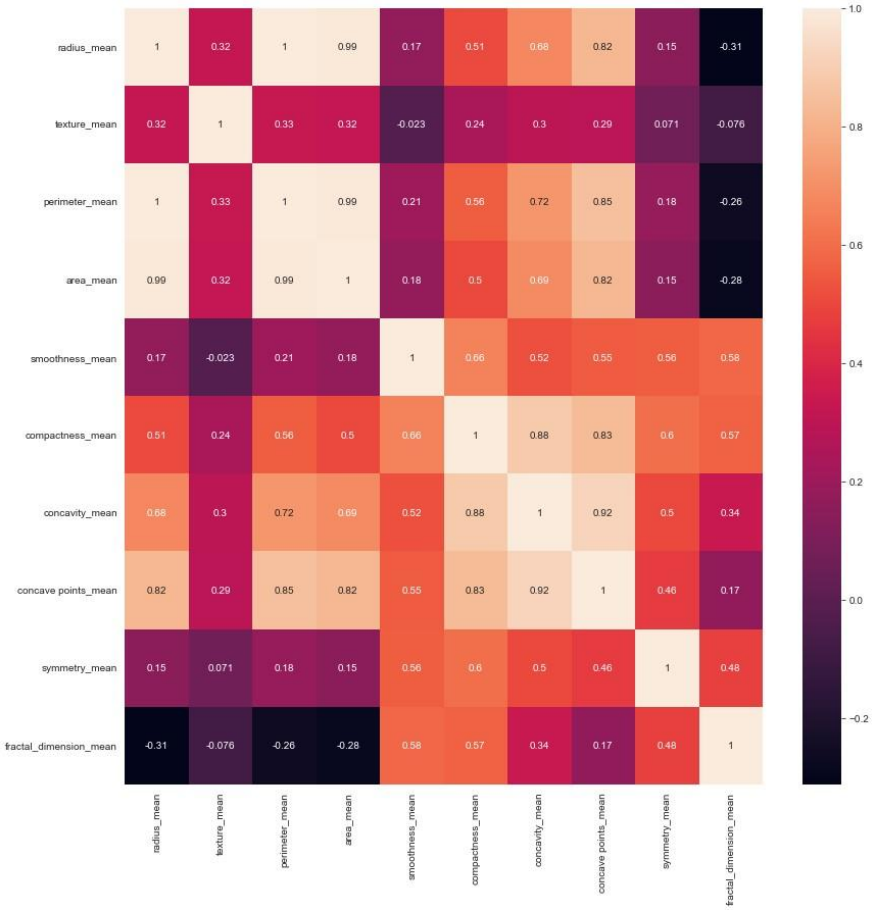


图 3. 均值特征的相关性

观察特征之间的相关性可以发现，特征“radius_mean”和“perimeter_metr”之间具有高度的相关性，达到了 1，因此可以考虑选定其中一种特征即可，同理“radius_mean”和“area_mean”之前也具有较高的关联性，可以考虑舍弃其中一种特征。通过类似上述的分析过程，考虑各特征之间的关联性以减少特征的数量，最终选定的特征为:“radius_mean”、“texture_mean”、“smoothness_mean”、“fractal_dimension_mean”、“compactness_mean”、“symmetry_mean”。

3. 特征的归一化

归一化的过程是将特征在数值上减去均值并除以标准差，以使得样本特征值的均值为 0，方差为 1，从而使得模型更容易收敛，可以使用 sklearn 库中的 StandardScaler 实现，代码的运行结果如下图 4 所示，可以看到成功实现了数据的归一化操作。

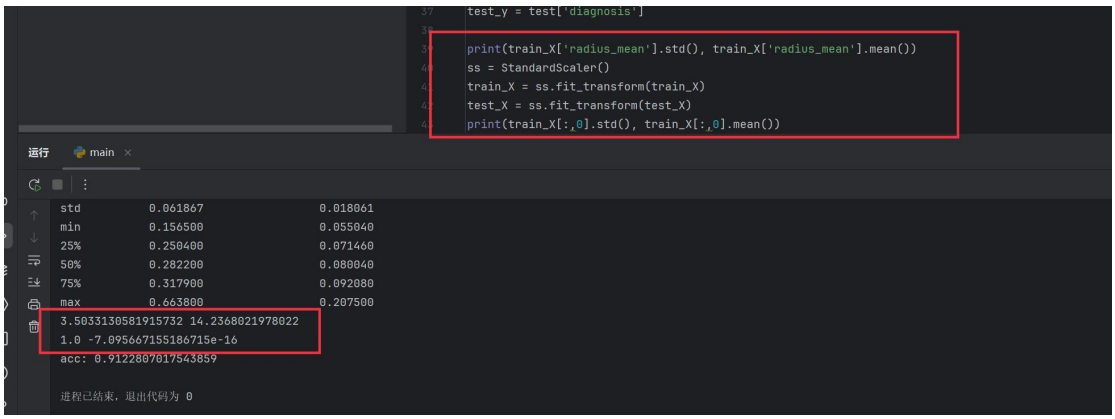


图 4. 数据的归一化

4. 模型的训练与测试

使用 sklearn 中实现的 SVM 模型对数据进行训练，并在测试集上进行模型的验证，初始选用高斯核，设置惩罚系数为 1，训练与测试结果如下图 5 所示。

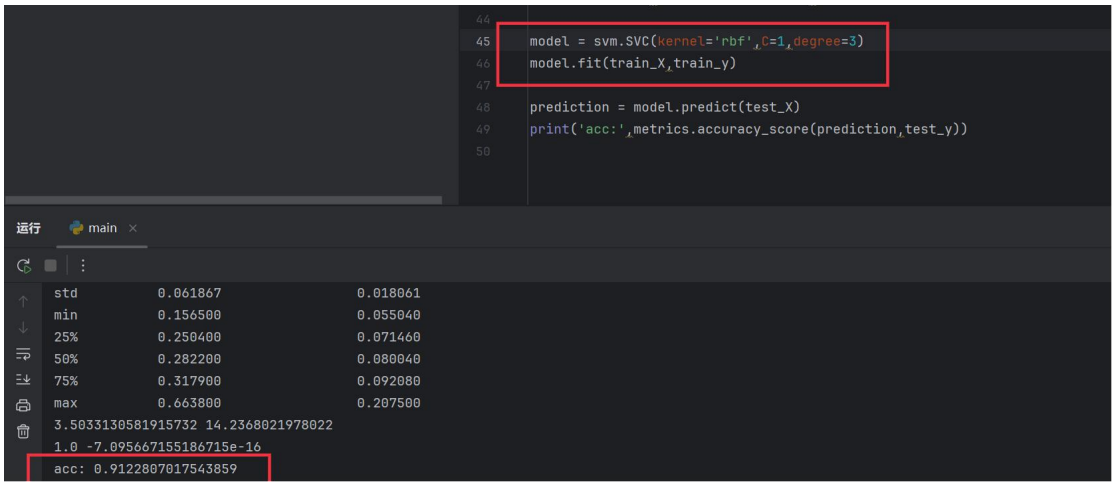


图 5. SVM 的训练与测试（高斯核+惩罚系数 1）

由于惩罚系数为 1，模型将在训练集上尽可能的实现划分，这将导致模型的泛化能力降低，从而在测试集上表现不佳，因此考虑降低惩罚因子，将其设置为 0.5，重新进行模型的训练与验证，结果如图 6 所示。

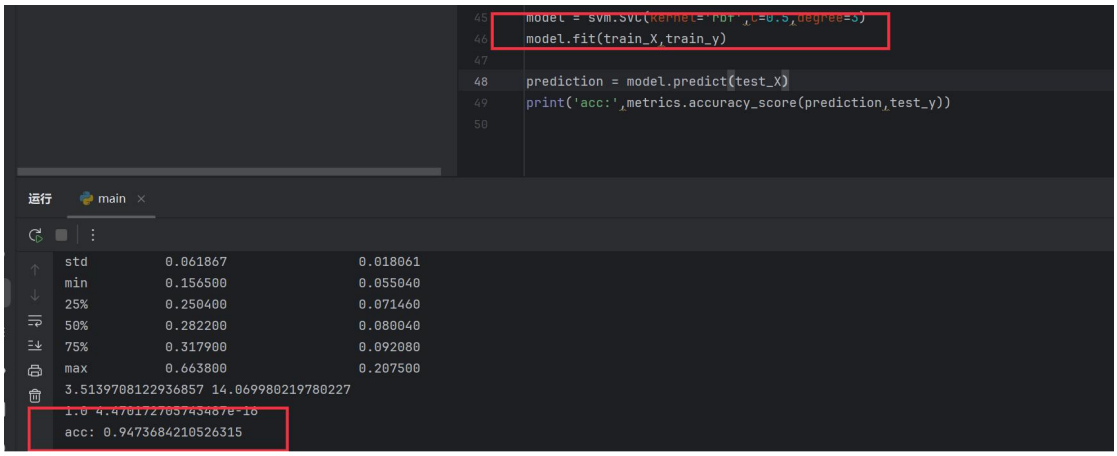


图 6. SVM 的训练与测试（高斯核+惩罚系数 0.5）

除此之外，特征的选择对于模型的训练结果也有明显的影响，在原选定特征的基础上增加一个特征“concave points_mean”，并重新进行模型的训练，结果如图 7 所示，可以看到模型在测试集上的表现进一步提高。

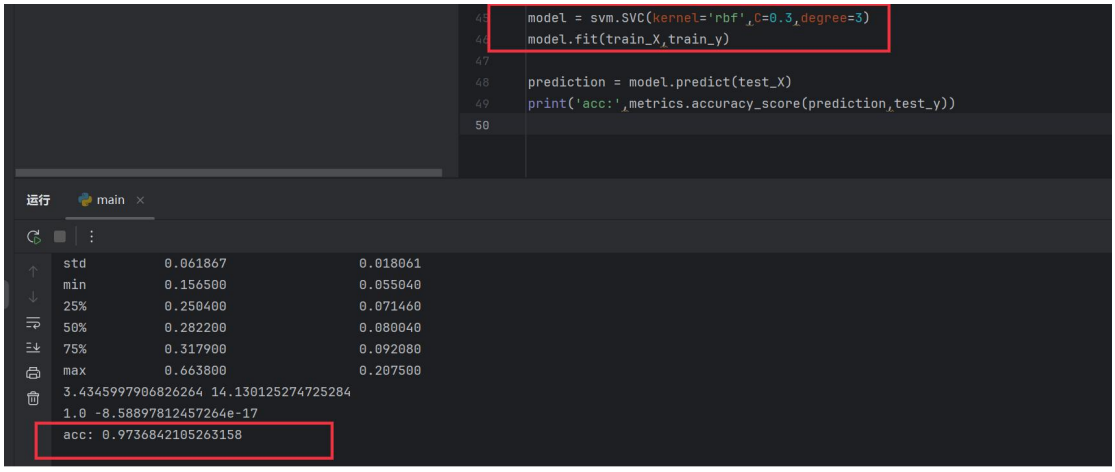


图 7. SVM 的训练与测试（增加特征+高斯核+惩罚系数 0.3）

尝试使用多项式核和线性核，模型表现均弱于高斯核。

七、 讨论、心得

本次实验基于 sklearn 库实现了通过 SVM 进行乳腺癌检测，通过核函数的选定与惩罚因子的调整，模型最终在测试集上达到了 **94.7%**的准确率。整个实 验依次进行了数据导入、数据特征分析、特征选择、数据归一化、模型训练、模型验证，最终实现目标，除此之外，通过对 SVM 的核函数（例如高斯核、多项式核、线性核）的调整选择，发现高斯核在本次实验的场景中具有更好的泛化性能，在

此基础上对惩罚因子进行了调整，并发现如果惩罚因子的数值过大，会导致模型在训练集上出现过拟合的现象，同时在测试集上表现较差，通过试验，发现当惩罚因子选定为 0.5 左右时，模型的泛化性能更好，最后也尝试调整了特征的选择策略，通过增加一些特征使得模型的准确率更好，但随之带来的代价是更长的训练时间与可能出现的过拟合现象。