论文汇报

宁波大学 NINGBO UNIVERSITY

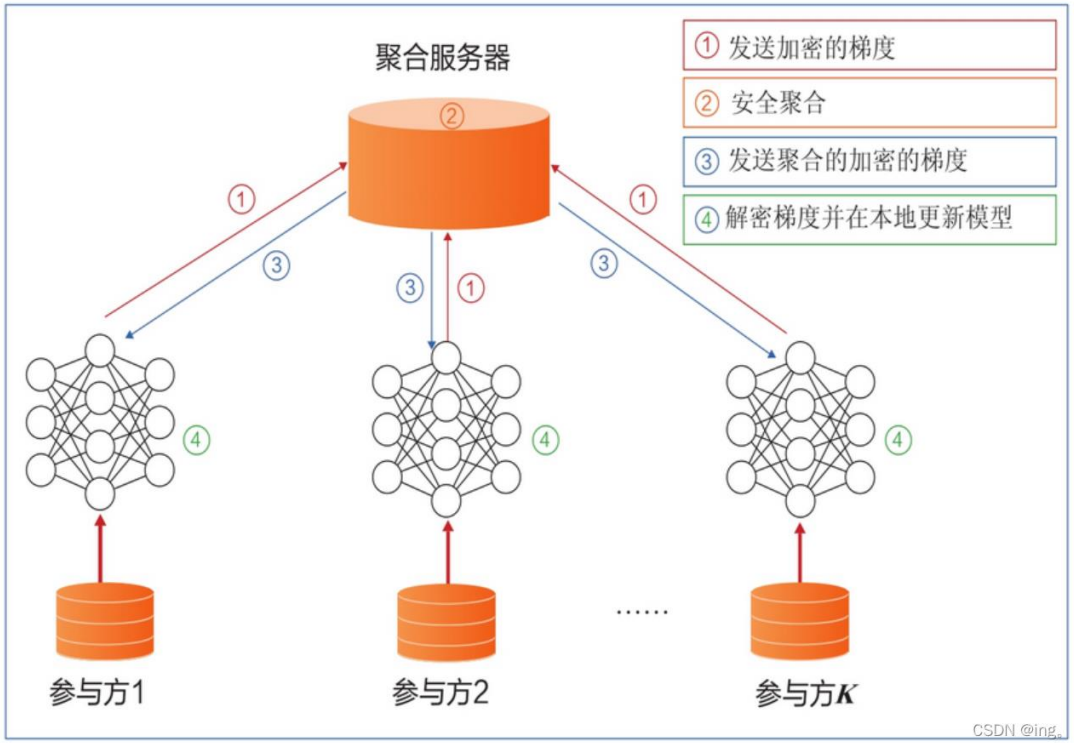
Personalized Edge Intelligence via Federated Self-Knowledge Distillation

Hai Jin , Fellow, IEEE, Dongshan Bai, Dezhong Yao , Member, IEEE, Yutong Dai, Lin Gu , Chen Yu , and Lichao Sun

IEEE TRANSACTIONS ON PARALLEL AND DISTRIBUTED SYSTEMS, VOL. 34, NO. 2, FEBRUARY 2023

汇报人：刘星宇

联邦学习Federated Learning (FL)



联邦学习是一种分布式机器学习方法，它允许多个设备或机构在**不共享数据**的情况下协同训练一个机器学习模型。传统的机器学习方法通常依赖于将数据集中到一个中央服务器进行训练，而联邦学习打破了这一范式，通过让设备在本地保留数据，仅共享模型参数或更新信息，从而实现**隐私保护和数据安全**。

联邦学习在边缘计算中的应用

在智能城市、智能交通系统等场景中，边缘服务器可以部署在靠近数据源的地方（如街道、车载设备等）。联邦学习可以帮助这些边缘服务器在**不共享数据**的情况下，**共同训练**交通管理模型、能耗优化模型等。例如：

- **智能交通管理**：边缘服务器可以根据实时的交通数据进行本地模型训练，而这些数据不需要集中到中央服务器，从而提高交通模型的时效性和隐私性。
- **工业物联网（IIoT）**：边缘服务器可以在工业场景中收集机器数据，使用联邦学习来训练设备故障预测模型，从而提高生产效率和设备的可靠性。

知识蒸馏（Knowledge Distillation）

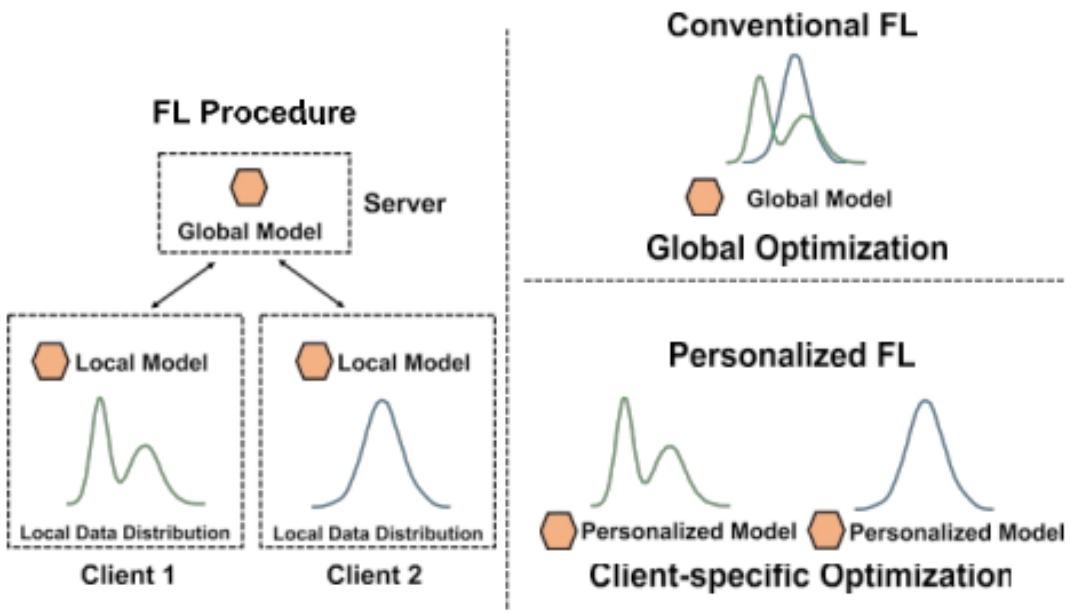
知识蒸馏是指将大型、复杂的**教师模型**的知识传递给较小的**学生模型**。学生模型学习教师模型的输出（如软标签），模仿其行为。
具有以下优点：

- **模型压缩**：在保持性能的同时，降低模型的复杂度和大小。
- **加速推理**：提高模型的运行速度，适合部署在资源受限的设备上。

自知识蒸馏（Self-Knowledge Distillation）是指无需教师模型，模型从自身的预测中学习。使用模型当前迭代的输出作为下一次训练的参考。通过数据增强等方式，让模型自我提升。
具有以下优点：

- **简化训练过程**：不需要额外的教师模型，节省资源。
- **提升性能**：增强模型的泛化能力，减少过拟合。

问题陈述



传统FL与个性化FL的区别

传统联邦学习方法通常学习一个共享的全局模型，适用于所有客户端。然而，当客户端的数据分布存在差异，即非独立同分布（non-IID）情况或任务不同，全局模型的表现往往较差，无法满足个性化需求。而这也更符合现实世界的情况。

本文工作

本文是通过一种名为自知识蒸馏（Self-Knowledge Distillation）的技术，开发一个能够在不遗忘历史个性化知识的前提下加快个性化训练过程的联邦学习框架——pFedSD。

pFedSD的设计理念是通过自知识蒸馏的方式，让每个客户端能够从自己的历史个性化模型中提取知识，减少因为每轮通信需要初始化全局模型产生的遗忘问题。同时在局部模型和全局模型之间找到更好的平衡。

相关工作

个性化联邦学习（FL）

传统FL模式，保留**一个**单一的全局模型。
个性化模型制定方法：

- 局部微调
- 正则化
- 模型插值
- 元学习
- 模型混合/参数解耦

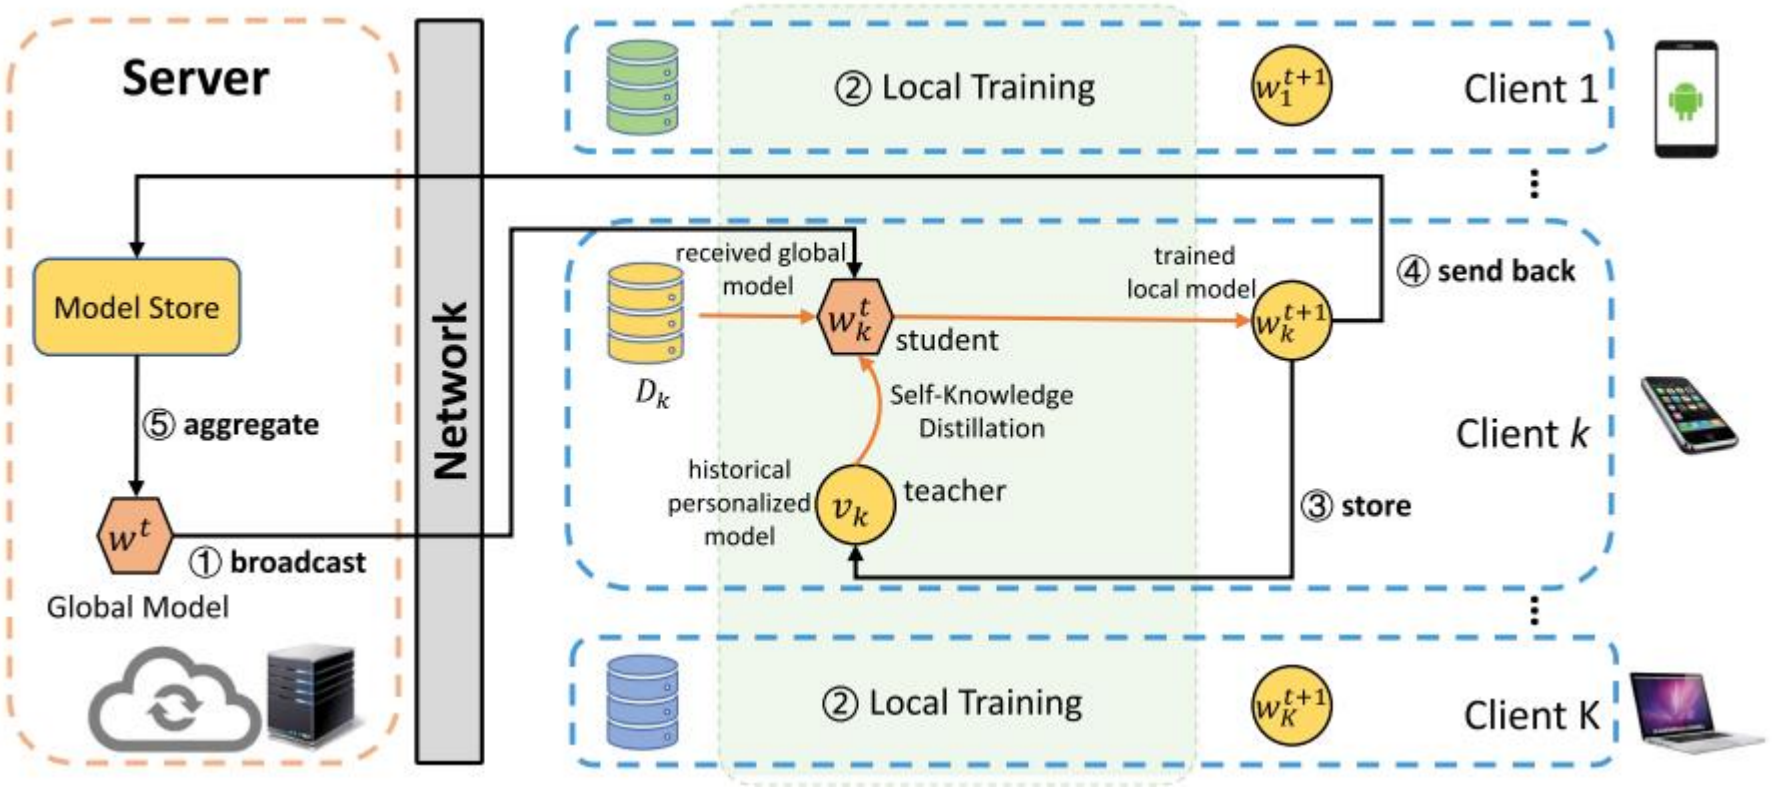
新型FL模式，保留**多个**全局模型，实现细粒度泛化。

- 基于**聚类**的联邦学习方法将客户分组进行开发每个组对应的全局模型
- **FedAMP**在服务器上为每个客户保留个性化云模型元学习和模型混合/参数解耦
- **FedFomo**允许客户下载其他客户的模型，并使用本地验证数据计算个性化加权组合

联邦学习中的知识蒸馏

- 传统知识蒸馏
- 客户端到服务器的知识蒸馏
- 联合蒸馏
- FedGen、FML、FedGKT、FedLSD等

模型构建



pFedSD工作流程示意图

核心思想

整个模型的核心思想是通过自知识蒸馏（Self-Knowledge Distillation）保留客户端模型的历史个性化知识，从而提升联邦学习系统中每个客户端在处理本地任务时的个性化效果。

损失函数：

$$\boldsymbol{\Phi}_{k(w_k^t)} = F_{k(w_k^t)} + \lambda \mathcal{L}_{\mathrm{KL}}\left(q(v_k)||q(w_k^t)\right)$$

其中，前半部分表示客户端的经验风险，即标准的监督学习损失函数。后者表示知识蒸馏损失，表示当前局部模型 θ 与上一轮个性化模型的输出之间的差异。使用Kullback-Leibler散度（KL散度）度量这一差异。这一项通过保留个性化知识，减少每轮更新时模型的遗忘现象。超参数 λ 控制了两部分损失的权重平衡。

算法实现

服务器端算法

Algorithm 1. pFedSD Algorithm: Server Side

Input: participation ratio r, communication rounds T
Output: local personalized models $\{v_k\}_{k\in[K]}$

procedure ServerExecute
  Initialize model w^0
  for $t = 1, \ldots, T$ communication rounds **do**
    Sample a subset S^t of clients of size rK (via Device Sampler)
    Send global model w^t to all clients in S^t (via Communication Manager)
    for each client $k \in S^t$ **in parallel do**
      $w_k^{t+1} \leftarrow ClientLocalUpdate(k, w^t)$
    end for
    $w^{t+1} \leftarrow \sum_{k\in S^t} \frac{w_k^{t+1}}{|S|}$ (via Aggregator)
  end for
end procedure

客户端算法

Algorithm 2. pFedSD Algorithm: Client Side

Input: learning rate η, local batch size B, local epochs E
Output: local personalized models $\{v_k\}_{k\in[K]}$

procedure ClientLocalUpdatek, w^t
  Receive the global model (via Communication Manager)
  Initialize the local model (via Model Manager) $w_k^t \leftarrow w^t$
  Compute # of local iterations $I_k = \lceil \frac{|D_k|}{B} \rceil$
  for $i = 1, \ldots, E$ local epochs **do**
    for $j = 1, \ldots, I_k$ local iterations **do**
      $w_k^t \leftarrow w_k^t - \eta \nabla \Phi_k(w_k^t, v_k)$ ▷ Optimize Eq.(4) (via Training Optimizer)
    end for
  end for
  Store personalized model v_k with w_k^t (via Model Store)
  returnlocal model w_k^t (via Communication Manager)
end procedure

关键点

个性化联邦学习算法在个性化和泛化之间需要寻找**平衡点**。本文提出的方法以FedAvg作为基础，通过全局模型初始化局部模型，同时在局部训练中引入当前模型与上一轮个性化模型之间的正则化项，从而有效**保留历史个性化知识**并提升模型性能。与现有大多数优先关注局部个性化的算法不同，本文的方法在兼顾个性化的同时更注重全局模型的泛化能力，以实现更稳定的性能。

自知识蒸馏在 pFedSD 中发挥作用的核心原因在于，相比于其他联邦学习方法，pFedSD 的个性化模型能够通过蒸馏机制捕获本地数据的更多**多样化特征视图**，从而在本地适应性和全局协作性之间实现**动态平衡**。

实验

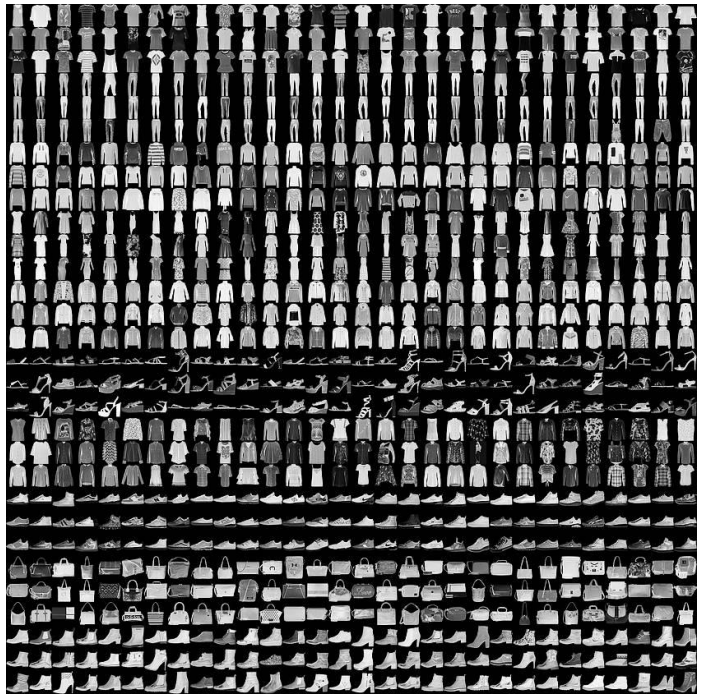
主要从以下几个方面来进行对比实验：

1、个性化精度

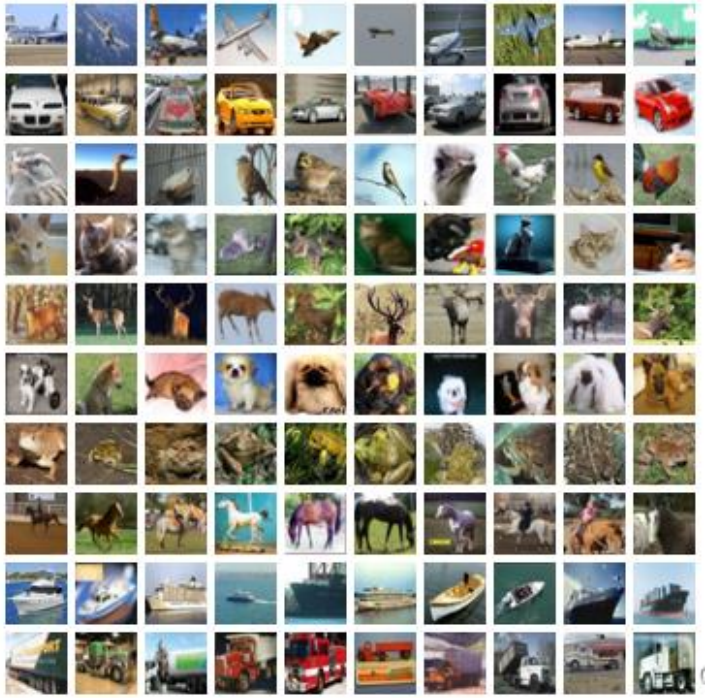
2、测试精度与通信轮次间关系

3、所有客户的测试精度分布

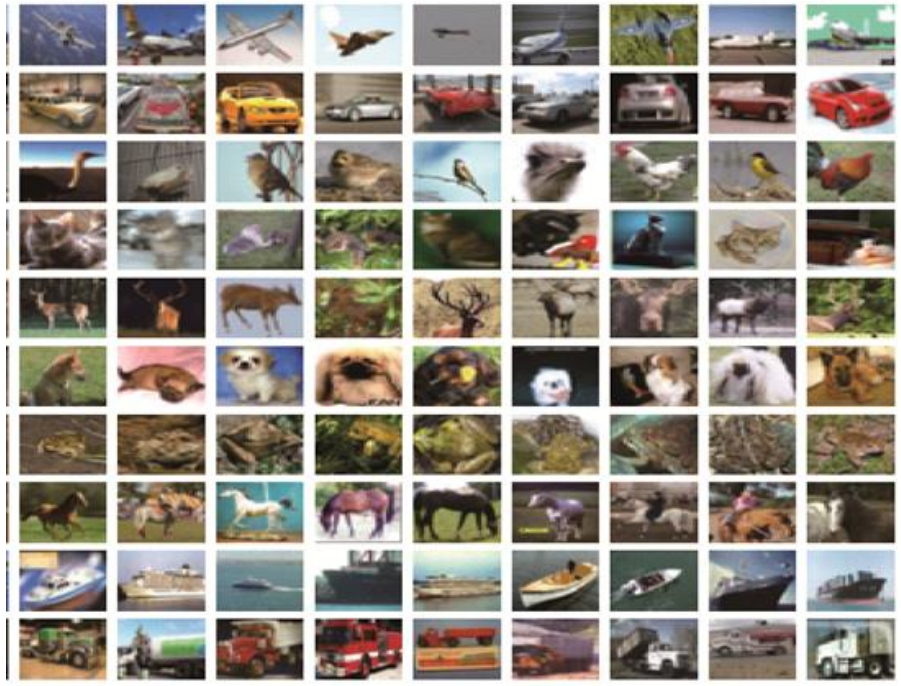
数据集介绍



Fashion-MNIST数据集中一共包括了10个类别，分别为T恤、裤子、套衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包和短靴。60000/10000 的训练测试数据划分，28x28 的灰度图片。



CIFAR-10是一个更接近普适物体的彩色图像数据集。一共包含10个类别的RGB 彩色图片：飞机、汽车、鸟类、猫、鹿、狗、蛙类、马、船和卡车。CIFAR-10数据集中每个图片的尺寸为32×32 ，每个类别有6000个图像，有50000 张训练图片和10000 张测试图片。



CIFAR-100类似于CIFAR-10，除了它有100个类，每个类包含600个图像。每类各有500个训练图像和100个测试图像。CIFAR-100中的100个类被分成20个超类。每个图像都带有一个“精细”标签（它所属的类）和一个“粗糙”标签（它所属的超类）。

个性化精度

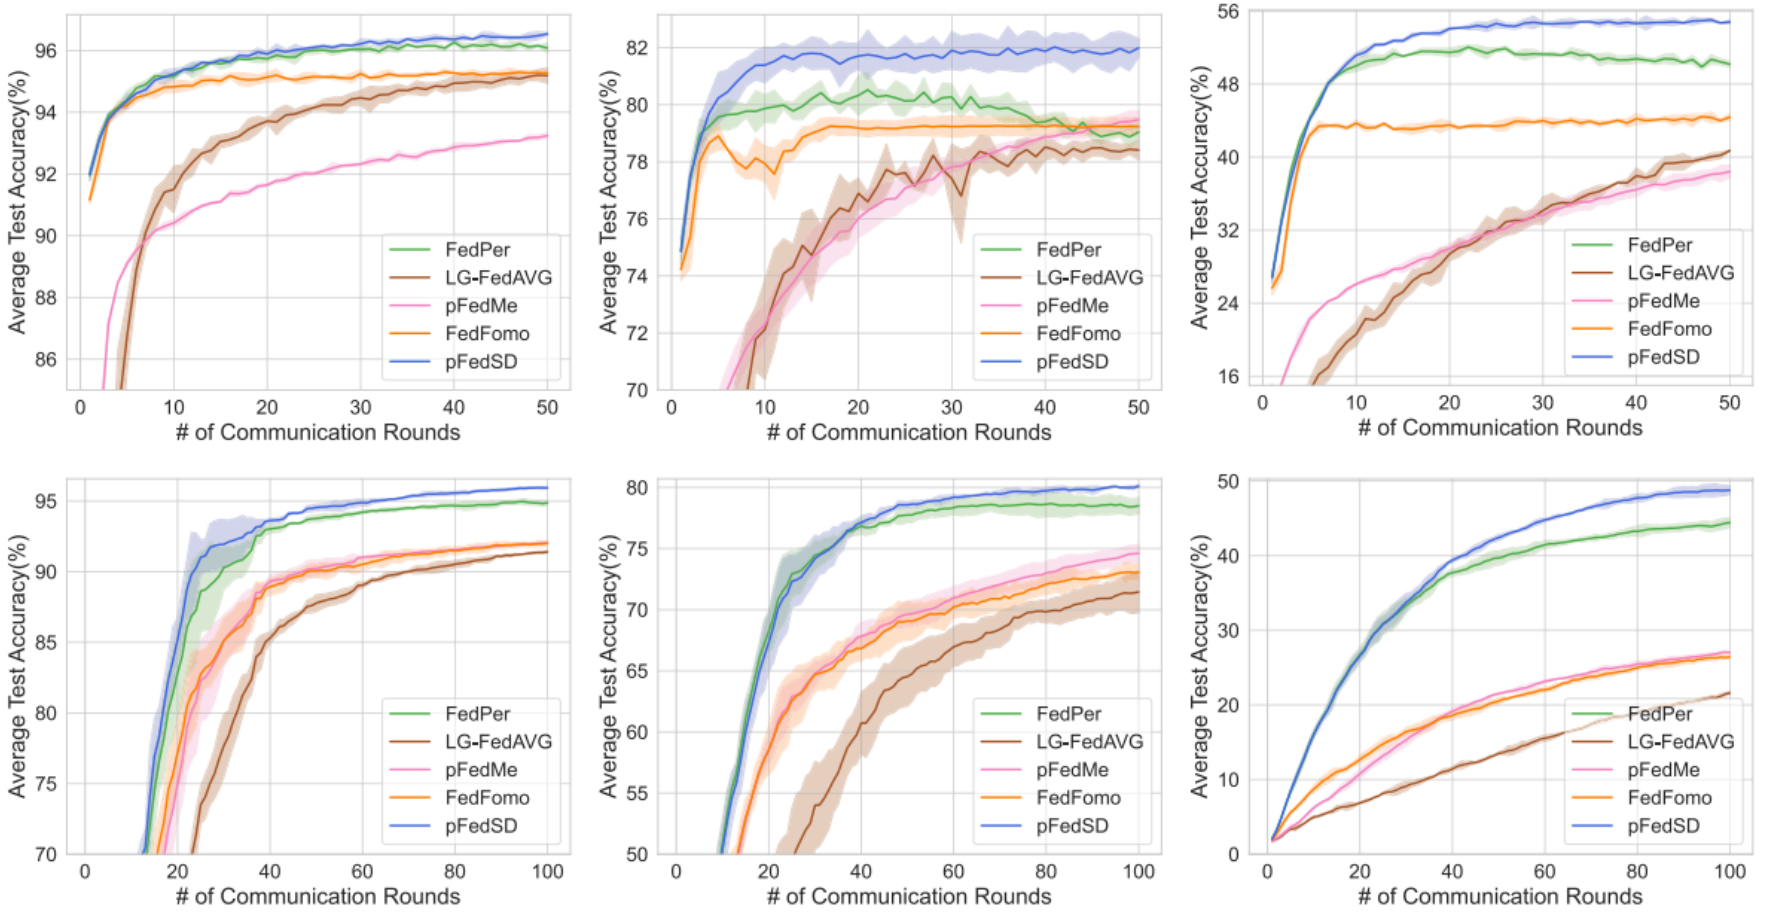
TABLE 2
Personalized Accuracy Overview With Dirichlet Distribution $\alpha = 0.1$

Datasets	Scale	FedAvg	FedProx	FedPer	LG-FedAvg	pFedMe	FedFomo	pFedSD
FMNIST	20 clients	90.15 ± 0.10	90.05 ± 0.13	96.30 ± 0.03	95.22 ± 0.22	93.24 ± 0.08	95.38 ± 0.04	$\mathbf{96.57 \pm 0.08}$
	100 clients	86.82 ± 0.39	76.78 ± 0.30	94.99 ± 0.17	91.41 ± 0.08	92.05 ± 0.08	92.06 ± 0.14	$\mathbf{95.97 \pm 0.06}$
CIFAR-10	20 clients	50.44 ± 0.68	50.50 ± 0.78	80.74 ± 0.47	78.61 ± 0.31	79.51 ± 0.28	79.29 ± 0.34	$\mathbf{82.08 \pm 0.46}$
	100 clients	49.04 ± 0.80	42.11 ± 0.95	78.89 ± 0.90	71.60 ± 1.52	74.62 ± 0.72	73.16 ± 0.65	$\mathbf{80.22 \pm 0.24}$
CIFAR-100	20 clients	32.24 ± 0.32	32.50 ± 0.55	52.12 ± 0.22	40.71 ± 0.05	38.42 ± 0.71	44.67 ± 0.37	$\mathbf{55.27 \pm 0.30}$
	100 clients	29.13 ± 0.18	14.27 ± 0.35	44.45 ± 0.64	21.61 ± 0.21	27.07 ± 0.25	26.48 ± 0.27	$\mathbf{48.91 \pm 0.77}$

TABLE 3
Personalized Accuracy Overview With Pathological Distribution

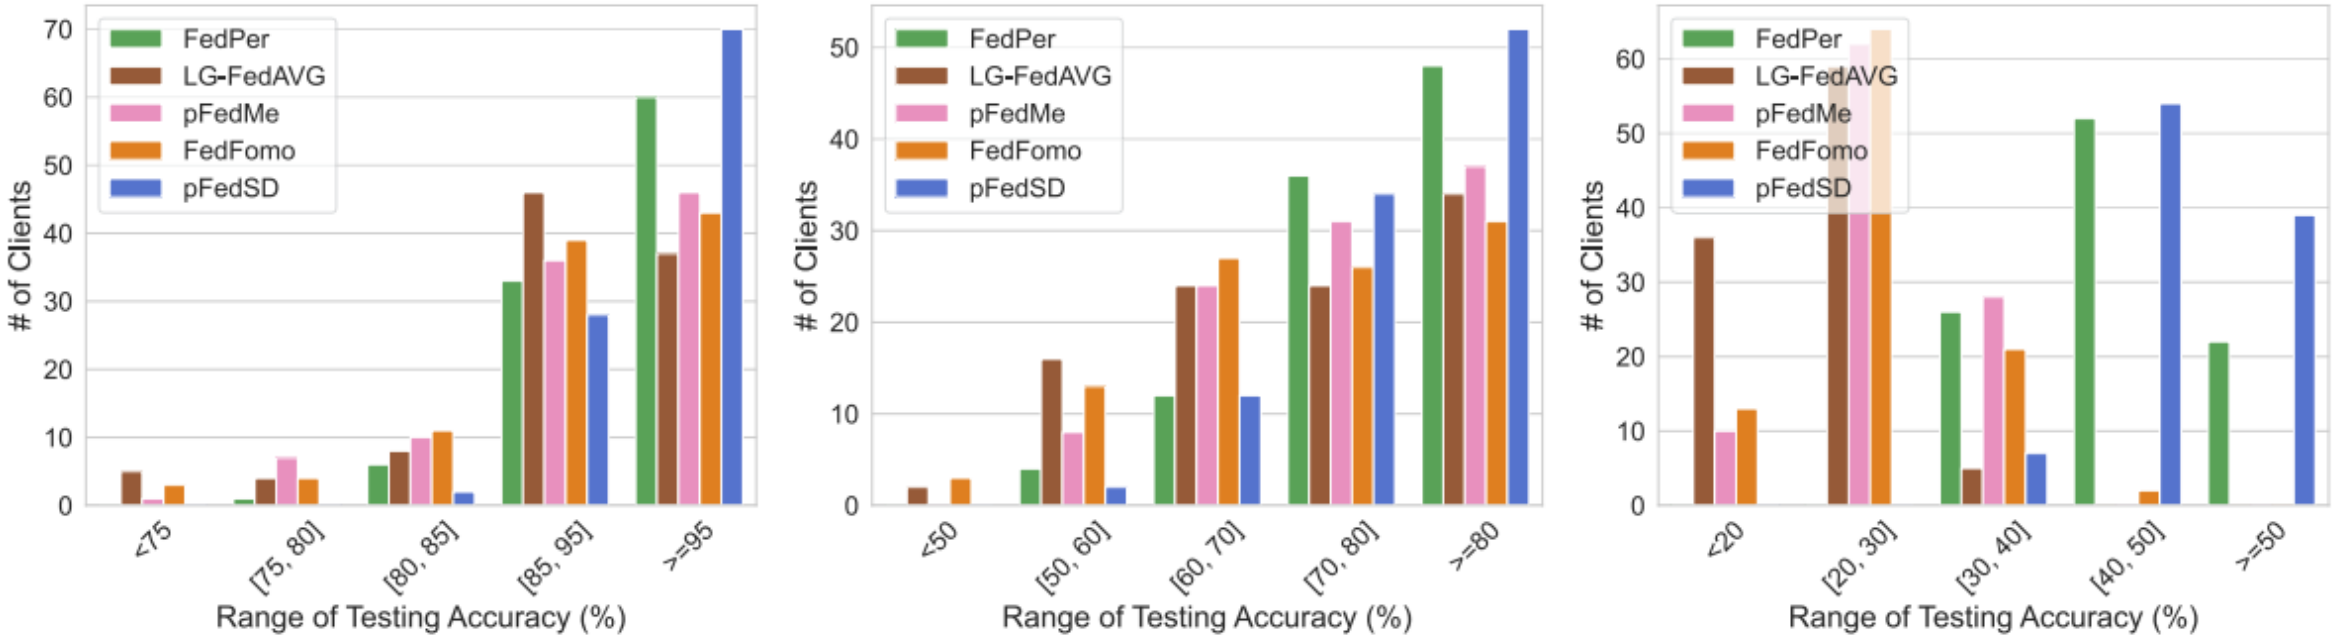
Datasets	Scale	FedAvg	FedProx	FedPer	LG-FedAvg	pFedMe	FedFomo	pFedSD
FMNIST	20 clients	75.71 ± 0.27	75.40 ± 1.06	99.42 ± 0.01	99.15 ± 0.04	98.76 ± 0.03	99.28 ± 0.01	$\mathbf{99.45 \pm 0.01}$
	100 clients	84.13 ± 0.44	74.38 ± 0.90	97.28 ± 0.12	95.70 ± 0.08	94.87 ± 0.03	96.14 ± 0.41	$\mathbf{97.42 \pm 0.04}$
CIFAR-10	20 clients	45.37 ± 0.53	45.86 ± 1.12	91.69 ± 0.10	92.21 ± 0.36	89.69 ± 0.39	91.66 ± 0.17	$\mathbf{92.52 \pm 0.24}$
	100 clients	43.52 ± 1.70	38.24 ± 1.39	86.66 ± 0.24	79.25 ± 1.63	80.47 ± 1.10	81.62 ± 0.54	$\mathbf{86.81 \pm 0.32}$
CIFAR-100	20 clients	31.92 ± 0.23	32.16 ± 0.32	55.57 ± 0.26	45.48 ± 0.63	38.66 ± 1.21	48.84 ± 0.11	$\mathbf{59.54 \pm 0.01}$
	100 clients	27.88 ± 0.35	13.32 ± 0.37	47.01 ± 0.50	18.96 ± 0.30	26.96 ± 0.30	25.21 ± 0.63	$\mathbf{50.99 \pm 0.43}$

测试精度与通信轮次间关系



(a) Fashion-MNIST (b) CIFAR-10 (c) CIFAR-100

所有客户的测试精度分布



(a) Fashion-MNIST (b) CIFAR-10 (c) CIFAR-100

Fig. 7. The testing accuracy distribution across all clients.

消融实验

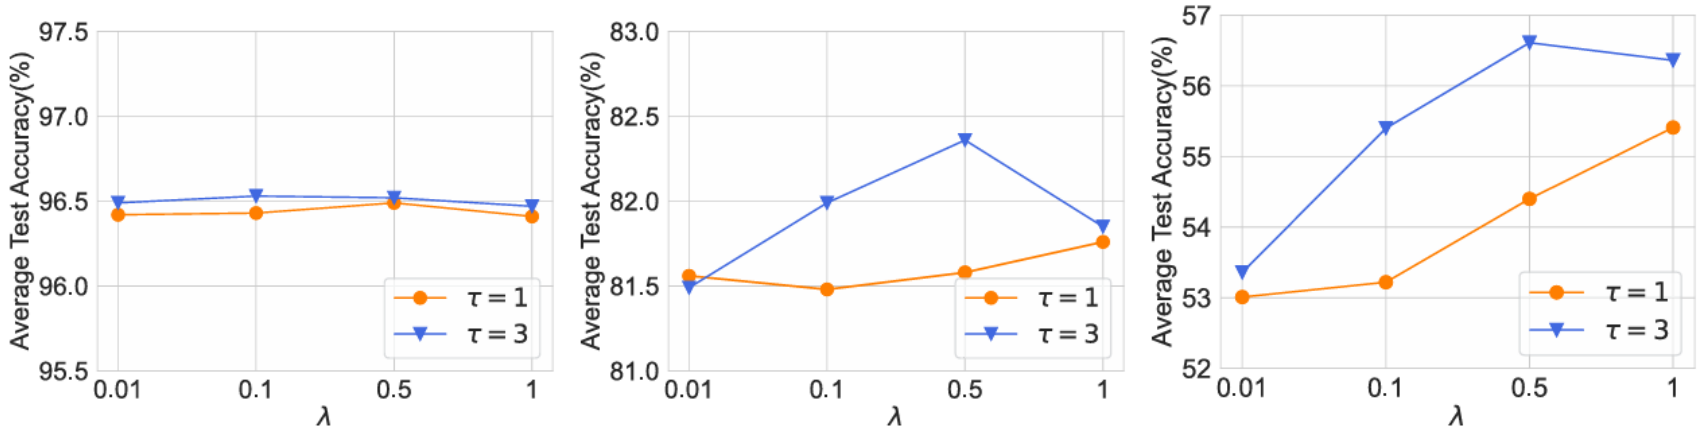
超参数的影响（λ 和 τ）

λ 是控制本地蒸馏损失的系数，用于平衡本地模型与全局模型的影响。

τ 是蒸馏温度参数，用于调整软目标分布的平滑程度。

在实验中，作者对λ的取值进行测试（0.01、0.1、0.5、1），同时测试了两种不同的蒸馏温度 τ 值（1 和 3）。结果表明，在较简单的任务上（如Fashion-MNIST），λ和τ的变化对模型的影响较小。而在更复杂的数据集上（如CIFAR-10和CIFAR-100），较高的温度 τ=3 和适中的 λ 值能够显著提高模型精度。

对于较简单的数据集（如Fashion-MNIST），λ和τ对性能的影响较小；而对于较复杂的数据集（如CIFAR-10和CIFAR-100），较高的蒸馏温度（τ=3）和适中的λ值能够显著提高测试精度。



(a) Fashion-MNIST (b) CIFAR-10 (c) CIFAR-100

Fig. 8. Effects of λ and τ.

消融实验

除了自知识蒸馏（self-knowledge distillation）外，还测试了不同的正则化方法，包括：

1、L2正则化：在本地模型与之前的个性化模型之间施加L2距离的正则化。

2、EWC（Elastic Weight Consolidation）：利用费舍尔信息矩阵来防止“灾难性遗忘”，通过限制对重要参数的变化来保护先前任务的知识。

3、使用MSE（均方误差）代替KL散度作为蒸馏损失。

结果显示，KL散度作为正则化项表现最佳，而L2和EWC在所有数据集上的表现显著逊色，说明自知识蒸馏的机制在捕获个性化知识和提升泛化能力方面更加有效。尽管MSE在Fashion-MNIST和CIFAR-10上的表现略优于KL散度，但在更复杂的CIFAR-100数据集上，KL散度表现更好，提升了近1%的精度 。

总结

结合个性化联邦学习和知识蒸馏的已有方法，pFedSD的主要改进点和优势如下：

一、解决个性化联邦学习方法的缺陷

1.避免个性化知识遗忘问题：

a) 传统方法（如FedAvg和FedProx）在每轮通信中初始化全局模型，忽略了客户端的历史个性化知识。

b) pFedSD通过自知识蒸馏保存历史个性化模型并在本地更新中进行知识迁移，从而缓解了个性化知识遗忘的现象。

2.增强个性化与泛化的平衡：

a) pFedSD在个性化和泛化之间建立了更好的平衡，使得模型在异质性数据分布下能够兼顾本地适应性和全局协作性。

3.提升训练稳定性与收敛速度：

a) 实验表明，pFedSD在通信轮次和个性化准确率之间表现出更快的收敛速度和更高的稳定性，尤其在数据异质性较高的场景中（如非IID分布）。

总结

二、改进知识蒸馏在联邦学习中的缺陷

1.摆脱对代理数据的依赖：

a) 传统知识蒸馏方法通常需要代理数据（proxy data）来在服务器端完成知识转移，但这些数据在实际中难以获取或生成。

b) pFedSD利用自知识蒸馏技术，仅依赖客户端的历史模型，无需额外的数据假设。

2.隐式集成多视角数据：

a) 通过自知识蒸馏，客户端模型可以从多视角数据中提取知识，实现类似“隐式集成”的效果，从而提高本地模型的泛化能力。

3.适应性强且计算开销小：

a) 相较于需要额外计算或存储成本的联合蒸馏或FedFomo，pFedSD在本地设备端的计算和存储开销较低，且可以灵活适配其他联邦学习算法。

感想

这篇文章将联邦学习和自知识蒸馏创造性地结合在一起，实现了既保留客户端模型个性化精度又兼顾全局模型泛化能力的目标，让我对这两种方法的应用有了更深的理解，从知识蒸馏到自知识蒸馏，从联邦学习到个性化联邦学习的演变也让我明白学术问题是从哪些角度提出和解决的。

学到更多的是如何去阅读一篇论文，梳理这篇论文的思考过程：如何发现问题、提出问题、解决问题……

感谢聆听